Konvergenz ethischer Werte in KI-Richtlinien der DAX-Unternehmen: Eine vergleichende Inhaltsanalyse und Governance-Bewertung

Autor: Florian Vesta

Adresse: Treskowallee 24A, 10318 Berlin

Matrikelnummer: 42305815

Studiengang: Marketingmanagement (M.A.)

Masterarbeit

Supervisor: Oliver Lonkwitz

Hochschule: IU International University of Applied Sciences (IU Internationale Hochschule GmbH), Juri-Gagarin-Ring 152, 99084 Erfurt.

Abgabedatum: Berlin, den 1. Mai 2026

Abstract

Vor dem Hintergrund, dass Unternehmen zwar normative KI-Richtlinien formulieren, deren tatsächliche organisatorische Verankerung jedoch bislang unklar ist, untersucht die vorliegende Arbeit die Konvergenz ethischer Werte in öffentlich zugänglichen KI-Richtlinien der DAX-40-Unternehmen sowie die Tiefe ihrer Governance-Operationalisierung. Methodisch basiert die Untersuchung auf einer Mixed-Methods-Vergleichsanalyse der öffentlich verfügbaren KI-Richtlinien der DAX-40-Unternehmen (qualitativ-quantitative Inhaltsanalyse). Dabei wurden die enthaltenen ethischen Kernwerte qualitativ kategorisiert und quantitativ erfasst. Gleichzeitig wurde ein Indikator zur Messung des Governance-Reifegrads der Umsetzung entwickelt. Die Ergebnisse zeigen, dass sich ein wiederkehrender Wertekanon - insbesondere Datenschutz, Fairness, Transparenz, Sicherheit und Rechtmäßigkeit - abzeichnet, wobei etwa ein Drittel der Unternehmen überhaupt keine kodierbaren Leitwerte öffentlich kommuniziert. Die Governance-Operationalisierung verläuft zudem deutlich heterogen: Unternehmensübergreifend dominieren grob formulierte Aufsichtsvorgaben und Hinweise auf Ethikkomitees. Konkrete Implementierungsmaßnahmen (etwa regelmäßige Audits oder klar definierte Verantwortlichkeiten) sind dagegen selten dokumentiert. Hierbei lassen sich grob zwei Unternehmensgruppen unterscheiden: Die einen weisen ein breites Werte-Engagement bei gleichzeitig relativ hoher Governance-Reife auf, die anderen verfügen über keine erkennbare KI-Normstruktur. Die Arbeit leistet damit einen Beitrag, indem sie normative KI-Richtlinien explizit mit praktischer Governance verknüpft, ein strukturiertes Bewertungsraster liefert und aufzeigt, wie ethische Prinzipien operativ gestaltet werden können.

Keywords: KI-Ethik, Corporate AI-Governance, DAX-Unternehmen, Inhaltsanalyse, Responsible AI.

Inhaltsverzeichnis

Abstract II
Abkürzungsverzeichnis VI
Tabellenverzeichnis VII
1. Einleitung 1
1.1 Problemstellung und Praxisrelevanz 1
1.2 Forschungsziel(e) und Forschungsfrage(n) 2
1.3 Beitrag der Arbeit 3
1.4 Aufbau der Arbeit 5
2. Theoretischer Rahmen und Literaturüberblick 6
2.1 Globale KI-Ethik 6
2.1.1 Terminologischer Rahmen: Werte, Prinzipien, Anforderungen 6
2.1.2 Normative Kernrahmen als Primäranker 7
2.1.3 Empirische Konsenskartierungen: Konvergenz in Wertlabels 8
2.1.4 Kritische Perspektiven: Konsens als begriffliche und praktische Illusion 10
2.2 Corporate AI-Governance 11
2.2.1 Begriff und Umfang: AI-Governance als System von Regeln, Praktiken und Prozessen 11
2.2.2 Der principle-to-practice gap als Kernproblem 12
2.2.3 Operationalisierung entlang des Lebenszyklus 13
2.2.4 Kritische Würdigung: Fragmentierung, Implementierungslücken und Kontextabhängigkeit 15
2.3 Forschungsstand zu Unternehmensrichtlinien 15
2.3.1 Corporate Policies zwischen Konvergenz und Umsetzungslücke 16
2.3.2 Audit-Zentrierung, Audit-Washing und Grenzen von Assurance 16
2.3.3 Ethics-Washing als Governance-Problem 17
2.3.4 Decoupling, Transparenz-Illusion und selektive Offenlegung als Analogie 17
2.3.5 GenAI als Richtlinien-Stresstest 18
2.4 Forschungslücke und abgeleitete Erwartungen 18
2.4.1 Forschungslücke 19
2.4.2 Abgeleitete Erwartungen/Hypothesen 19
3. Methode 20
3.1 Forschungsdesign 21
3.2 Quellenkorpus: Einschluss und Ausschluss 22
3.3 Datenerhebung und Dokumentenlog 24

3.4 Codebuch 25
3.4.1 Entwicklung und theoretische Anker des Codebuchs 26
3.4.2 Aufbau des Codebuchs und Codefamilien 26
3.4.3 Kodierregeln und Evidenzlogik 29
3.4.4 Pilotierung, Freeze-Logik und Umgang mit Grenzfällen 30
3.5 Konvergenz-Index und Operationalisierungs-Index 31
3.5.1 Konvergenz-Index für Werte (Unternehmensscore 0-1) 31
3.5.2 Konvergenz zwischen Unternehmen (Set-Ähnlichkeit) 32
3.5.3 Operationalisierungs-Index für Governance-Tiefe (0-100) 32
3.5.4 Sensitivitätsanalyse der Indexgewichte 32
3.6 Reliabilität, Validität und Bias-Mitigation 34
3.6.1 Reliabilität: Konsistenz der Kodierung 34
3.6.2 Validität: Konstrukt-, Inhalts- und Transparenzvalidität 34
3.6.3 Bias-Mitigation: Selektions- und Interpretationsrisiken 35
3.7 Datenanalyse 36
3.7.1 Deskriptive Analysen und Visualisierung 36
3.7.2 Clusteranalysen: Profilbildung nach Werten und Governance 36
3.7.3 Zusammenhangsanalysen: Konvergenz und Governance-Tiefe 37
3.7.4 Sensitivität und Robustheit der Muster 37
3.8 Limitationen der Methode 37
4. Ergebnisse 39
4.1 Stichprobenbeschreibung 39
4.2 Konvergenzbefunde 40
4.2.1 Prävalenz und Bindigkeit der Werte 41
4.2.2 Breite der Werteprofile auf Unternehmensebene 42
4.2.3 Paarweise Werte-Konvergenz 42
4.2.4 Clusteranalyse der Werteprofile 44
4.3 Governance-Tiefe 45
4.3.1 Verteilung der Governance-Kriterien 45
4.3.2 Governance-Tiefe auf Unternehmensebene 46
4.3.3 Branchenvergleich von Werte- und Governance-Index 46
4.3.4 Clusteranalyse der Governance-Profile 48
4.3.5 Zusammenhang zwischen Werte- und Governance-Index 48
4.4 Werte-Governance-Mapping 49
4.4.1 Bindigkeitsprofile als Operationalisierungssignal auf Werteebene 49

4.4.2 Governance-Kriterien als Operationalisierungsmechanik 50
4.4.3 Zuordnungsmuster zwischen Werte- und Governance-Clustern 51
4.5 Sensitivitätsanalysen 52
4.5.1 Variantenübersicht 52
4.5.2 Stabilität des Werteindex 53
4.5.3 Stabilität des Governance-Index 53
4.5.4 Stabilität der Clusterlösungen 54
4.6 Zusammenfassung 54
5. Diskussion 58
5.1 Einordnung in die Literatur 58
5.2 Praktische Implikationen 64
5.3 Regulatorische Anschlussfähigkeit 67
5.4 Limitationen und Ausblick 69
6. Fazit 72
Literaturverzeichnis 76
Anhang 80
Eidesstattliche Erklärung 526

Abkürzungsverzeichnis

AIA: Algorithmic Impact Assessments

AI: Artificial Intelligence

ARI: Adjusted Rand Index

BASF: Badische Anilin- und Soda-Fabrik*, Unternehmen*

BMW: Bayerische Motoren Werke*, Unternehmen*

DAX: Deutscher Aktienindex

EBA: Ethics-based Auditing

ESG: Environmental, Social and Governance

EU: Europäische Union

FRIA: Fundamental Rights Impact Assessment

GenAI: Generative Artificial Intelligence

GRI: Global Reporting Initiative

KI: Künstliche Intelligenz

ML: Machine Learning

NIST: National Institute of Standards and Technology

OECD: Organisation for Economic Co-operation and Development

QMS: Qualitätsmanagementsystem

RWE: Rheinisch-Westfälisches Elektrizitätswerk*, Unternehmen*

SAP: Systemanalyse Programmentwicklung*, Unternehmen*

UNESCO: United Nations Educational, Scientific and Cultural Organization

XAI: Explainable Artificial Intelligence

Tabellenverzeichnis

Tab. 2-1: Wiederkehrende Wertecluster in globalen KI-Ethik-Rahmenwerken und Meta-Analysen, eigene Darstellung auf Basis von EU HLEG, 2019, S. 2; OECD, 2019, S. 8-9; UNESCO, 2021, S. 20; Jobin et al., 2019, S. 1; Fjeld et al., 2020, S. 4; Corrêa et al., 2023, S. 1.

Tab. 2-2: Evidenzlogik zur Governance-Tiefe in Unternehmensrichtlinien (Rubrik 0-3), eigene Darstellung auf Basis von EU HLEG, 2019, S. 24-33; EU, 2024, S. 19-20, 27-29, 60-63, 69-70, 101-102; OECD, 2019, S. 8-9; UNESCO, 2021, S. 3; Birkstedt et al., 2023, S. 1-2; Morley et al., 2020, S. 2141; Mökander et al., 2021, S. 1.

Tab. 3-1: Wertekatalog, eigene Darstellung.

Tab. 3-2: Governancerubriken, eigene Darstellung.

Tab. 3-3: Bindigkeitsgewichte, eigene Darstellung.

Tab. 3-4: Coding-Protokoll (Kernregeln und Evidenzanforderungen für alle Protokollelemente), eigene Darstellung.

Tab. 3-5: Übersicht Rubriken und Indizes (Skalen und Berechnung), eigene Darstellung.

Tab. 4-1: Prävalenz und Bindungsniveaus der kodierten Werte über alle untersuchten Unternehmen, eigene Darstellung.

Tab. 4-2: Verteilung der Governance-Scores je Kriterium, eigene Darstellung.

Tab. 4-3: Branchenweise deskriptive Kennzahlen zu Wertepräsenz und Governance-Index, eigene Darstellung.

Tab. 4-4: Spearman-Rangkorrelation zwischen Werte- und Governance-Index, eigene Darstellung.

Tab. 4-5: Zusammenfassung der Ergebnisse pro Unternehmen, eigene Darstellung.

1. Einleitung

1.1 Problemstellung und Praxisrelevanz

Der Einsatz künstlicher Intelligenz (KI) in Unternehmen ist längst nicht mehr auf experimentelle Anwendungsfälle beschränkt, sondern durchdringt zentrale Wertschöpfungsprozesse, Entscheidungsroutinen und Kundeninteraktionen. Mit dieser technologischen Transformation gehen jedoch nicht nur Effizienz- und Innovationspotenziale einher, sondern ebenso grundlegende normative und governancebezogene Fragen. Unternehmen stehen vor der Herausforderung, den Einsatz von KI-Systemen so zu gestalten, dass er mit ethischen Prinzipien, regulatorischen Anforderungen und gesellschaftlichen Erwartungen vereinbar bleibt. Vor diesem Hintergrund haben zahlreiche Organisationen eigene KI-Richtlinien, KI-Prinzipien oder Digital-Ethics-Codices veröffentlicht, in denen sie zentrale Werte und Leitlinien für den verantwortungsvollen Umgang mit KI formulieren.

Diese normativen Dokumente enthalten typischerweise Aussagen zu Transparenz, Fairness, Nicht-Diskriminierung, Datenschutz, Sicherheit oder menschlicher Aufsicht. Sie fungieren als Orientierungsrahmen für Entwicklung, Implementierung und Nutzung von KI-Systemen und sollen nach innen wie außen signalisieren, dass technologische Innovation mit ethischer Verantwortung einhergeht. Insbesondere große, kapitalmarktorientierte Unternehmen - wie die im DAX gelisteten Konzerne - stehen dabei unter besonderer Beobachtung. Ihre Richtlinien entfalten nicht nur interne Steuerungswirkung, sondern wirken auch reputationsbildend, investorenseitig vertrauensstiftend und müssen regulatorisch anschlussfähig sein.

Gleichzeitig offenbart sich eine zentrale Spannung, die den Ausgangspunkt der vorliegenden Arbeit bildet: Zwischen der Benennung ethischer Werte auf Prinzipienebene und deren tatsächlicher organisatorischer Verankerung im Unternehmensalltag kann eine erhebliche Differenz bestehen. Die bloße Formulierung von Leitprinzipien garantiert noch keine systematische Umsetzung in Form klar definierter Verantwortlichkeiten, dokumentierter Prozesse, überprüfbarer Kontrollmechanismen oder verbindlicher Eskalationswege. Damit rückt die Frage in den Fokus, ob veröffentlichte KI-Richtlinien primär als normative Selbstverpflichtungen auf deklarativer Ebene fungieren oder ob sie Ausdruck einer substanziell implementierten ‚Corporate AI-Governance' sind.

Für die Unternehmenspraxis ist diese Differenz von erheblicher Bedeutung. Eine lediglich symbolische Wertekommunikation birgt Risiken im Hinblick auf Glaubwürdigkeit, Compliance und langfristige Vertrauensbildung. Umgekehrt kann eine strukturierte und nachvollziehbar operationalisierte KI-Governance dazu beitragen, Risiken systematisch zu identifizieren, Entscheidungsprozesse abzusichern und organisationale Lernprozesse zu fördern.

Insbesondere in großen, komplexen Konzernstrukturen stellt sich die Frage, wie ethische Leitprinzipien in konkrete Steuerungsinstrumente übersetzt werden und in welchem Umfang diese institutionell abgesichert sind.

Vor diesem Hintergrund gewinnt eine systematische, vergleichende Analyse öffentlich zugänglicher KI-Richtlinien großer deutscher Unternehmen an Relevanz. Während internationale Untersuchungen zu KI-Ethik-Rahmen existieren, fehlt für den deutschen Kontext (insbesondere bezogen auf die DAX-Unternehmen) eine strukturierte Gegenüberstellung, die sowohl die Werteebene als auch deren Operationalisierung in Governance-Strukturen integriert betrachtet. Die vorliegende Arbeit setzt an dieser Stelle an und adressiert die Lücke zwischen normativer Prinzipienrhetorik und organisatorischer Implementierung.

Damit wird die Problemstellung präzise konturiert: Es gilt zu untersuchen, ob sich in den KI-Richtlinien der DAX-Unternehmen ein gemeinsamer ethischer Kern erkennen lässt und in welchem Ausmaß diese Werte in überprüfbare, organisatorisch verankerte Governance-Mechanismen übersetzt sind.

1.2 Forschungsziel(e) und Forschungsfrage(n)

Ausgehend von der skizzierten Problemstellung verfolgt die vorliegende Arbeit das Ziel, die KI-Richtlinien der im DAX gelisteten Unternehmen systematisch zu erfassen, inhaltlich zu vergleichen und hinsichtlich ihrer Governance-Tiefe zu bewerten. Dabei werden zwei analytische Perspektiven miteinander verknüpft: die Konvergenz ethischer Kernwerte auf Prinzipienebene sowie die Tiefe ihrer Operationalisierung in konkreten organisatorischen Strukturen und Prozessen. Dieses Ziel ist bewusst zweidimensional gefasst, da die Arbeit einerseits die Werte- beziehungsweise Prinzipienebene als Ausdruck öffentlich artikulierter Normsemantik betrachtet und andererseits die Governanceebene als Frage nach der dokumentierten Übersetzung dieser Normen in organisationsfähige Mechanismen.

Im ersten Schritt zielt die Arbeit darauf ab, die in öffentlich zugänglichen KI-Richtlinien, KI-Prinzipien oder äquivalenten Dokumenten formulierten Werte zu kartieren und in eine vergleichbare Systematik zu überführen. Auf dieser Grundlage wird untersucht, in welchem Ausmaß sich über die Unternehmen hinweg eine Konvergenz zentraler ethischer Leitprinzipien feststellen lässt. Die Analyse konzentriert sich dabei nicht auf eine normative Bewertung einzelner Werte, sondern auf deren Präsenz, Gewichtung und strukturelle Ähnlichkeit im Unternehmensvergleich.

Im zweiten Schritt richtet sich der Blick auf die Operationalisierung dieser Werte. Hier steht die Frage im Zentrum, ob und in welcher Tiefe die benannten Prinzipien in dokumentierte Prozesse, klar zugewiesene Verantwortlichkeiten, definierte Prüfmechanismen, Schulungen,

Eskalationswege oder Berichtspflichten überführt sind. Damit wird die Governance-Dimension der KI-Richtlinien systematisch erfasst und quantifizierbar gemacht, ohne die qualitative Einbettung aus dem Blick zu verlieren.

Vor diesem Hintergrund lassen sich die leitenden Forschungsfragen der Arbeit wie folgt präzisieren:

Erstens: In welchem Ausmaß konvergieren die in öffentlich zugänglichen KI-Richtlinien der DAX-Unternehmen formulierten ethischen Kernwerte?

Zweitens: Wie tief sind diese Werte in konkrete organisatorische KI-Governance-Strukturen operationalisiert?

Drittens: In welchem Verhältnis stehen Werte-Konvergenz und Governance-Tiefe zueinander, und lassen sich im Unternehmensvergleich systematische Muster erkennen?

Mit diesen Fragestellungen verbindet die Arbeit eine deskriptiv-analytische Untersuchung mit einer strukturellen Bewertung der Governance-Ausgestaltung. Ziel ist es nicht, einzelne Unternehmen normativ zu beurteilen, sondern ein vergleichendes Gesamtbild des DAX-Kontexts zu zeichnen. Auf diese Weise soll nachvollziehbar werden, ob sich ein gemeinsamer Wertekanon herausbildet und in welchem Umfang dieser durch institutionelle Mechanismen unterlegt ist. Die leitende analytische Bewegung bleibt damit kontrolliert: Werte-Konvergenz wird als Muster normativer Sprache und Set-Überlappung auf der Dokumentenebene verstanden; Governance-Operationalisierung als Tiefe dokumentierter organisationaler Mechanismen, die eine Übersetzung in Praxis grundsätzlich ermöglichen. Die Arbeit zielt folglich darauf, die oftmals diskutierte Differenz zwischen dem ‚Was' der Prinzipien und dem ‚Wie' ihrer Umsetzung im Unternehmenskontext empirisch und vergleichend sichtbar zu machen, ohne diese Differenz bereits in der Einleitung als Ergebnis zu behaupten oder zu interpretieren.

1.3 Beitrag der Arbeit

Die vorliegende Arbeit leistet einen Beitrag sowohl zur wissenschaftlichen Diskussion um Corporate AI-Governance als auch zur praktischen Ausgestaltung verantwortungsvoller KI-Steuerung in Unternehmen.

Aus wissenschaftlicher Perspektive schließt diese Untersuchung eine identifizierte Lücke im deutschen Kontext. Während internationale Analysen eine Vielzahl von KI-Ethik-Rahmen und Unternehmensrichtlinien erfassen, fehlt bislang eine systematische, vergleichende Inhaltsanalyse der DAX-Unternehmen, die die Werteebene und deren Operationalisierung in integrierter Form betrachtet. Diese Arbeit setzt genau an dieser Leerstelle an, indem sie die

Konvergenz ethischer Kernwerte nicht isoliert betrachtet, sondern mit der Frage nach der organisatorischen Übersetzung verknüpft. Damit wird eine Perspektive gestärkt, die Corporate-KI-Ethik nicht primär als Sammlung abstrakter Leitprinzipien versteht, sondern als Governance-Phänomen, dessen Substanz sich gerade in der Operationalisierung - etwa in Zuständigkeiten, Prozessen, Instrumenten und Nachweispflichten - entscheidet.

Durch die Entwicklung und Anwendung eines strukturierten Bewertungsansatzes werden die öffentlich zugänglichen Dokumente nicht nur qualitativ beschrieben, sondern entlang nachvollziehbarer Kriterien vergleichbar gemacht. Die Arbeit trägt damit zur Operationalisierung des oftmals abstrakt diskutierten Begriffs der ‚Responsible AI' auf Unternehmensebene bei. Sie bietet ein systematisches Raster, mit dem sich normative Selbstverpflichtungen und deren institutionelle Umsetzung in Beziehung setzen lassen.

Für die Praxis eröffnet die Untersuchung eine Orientierungsfunktion. Die vergleichende Analyse ermöglicht es, typische Muster, Ausprägungen und Strukturmerkmale von KI-Governance im DAX-Kontext sichtbar zu machen. Unternehmen erhalten dadurch einen Referenzrahmen, innerhalb dessen sie die eigene Richtliniengestaltung einordnen können. Darüber hinaus lassen sich aus der strukturierten Gegenüberstellung Ansatzpunkte für Good-Practice-Bausteine ableiten, die eine stärkere Verknüpfung von Prinzipien und operativer Umsetzung unterstützen.

Insbesondere für Governance-Verantwortliche, Compliance-Funktionen, Ethikgremien und KI-Steuerungseinheiten kann die Arbeit einen Mehrwert bieten, indem sie aufzeigt, welche Elemente einer operationalisierten KI-Governance in der Praxis dokumentiert und institutionell verankert sind. Damit leistet die Untersuchung einen Beitrag zur Versachlichung der Debatte um ‚Ethics-Washing' und verantwortungsvolle KI, indem sie normative Rhetorik und organisatorische Umsetzung systematisch miteinander in Beziehung setzt.

Für das Studienfach Marketingmanagement ergibt sich der Mehrwert insbesondere aus der Verbindung von Governance und Glaubwürdigkeit. Die Arbeit macht deutlich, dass KI-Ethik nicht nur eine interne Steuerungsfrage ist, sondern zugleich eine Frage nachvollziehbarer, konsistenter und damit vertrauensfähiger Kommunikation nach außen. Die analytische Trennung von Wertekommunikation und Governance-Tiefe erlaubt es, potenzielle Spannungsfelder der Legitimitätsproduktion differenziert zu betrachten, ohne vorschnell moralische Etikettierungen vorzunehmen. Damit trägt die Arbeit dazu bei, Responsible-AI-Kommunikation nicht als isolierten Reputationsbaustein zu behandeln, sondern als Bestandteil einer Governance-Architektur, deren Sichtbarkeit und Belegbarkeit für Stakeholderbeziehungen und Vertrauen relevant sein kann.

Insgesamt zielt die Arbeit somit darauf ab, Transparenz in ein Feld zu bringen, das zwischen strategischer Kommunikation, regulatorischer Anschlussfähigkeit und tatsächlicher Organisationspraxis angesiedelt ist.

1.4 Aufbau der Arbeit

Der Aufbau der Arbeit folgt der dargestellten Argumentationslogik und führt schrittweise von der Problemöffnung über die konzeptionelle Rahmung zur methodischen Operationalisierung und anschließend zur empirischen Auswertung und Diskussion.

Kapitel 2 entwickelt den theoretischen Rahmen und gibt einen strukturierten Überblick über relevante KI-Ethik-Literatur sowie Konzepte der Corporate AI-Governance. Dabei werden zentrale Begrifflichkeiten geklärt und die Differenz zwischen normativer Prinzipienebene und organisatorischer Operationalisierung konzeptionell herausgearbeitet. Auf dieser Grundlage wird die Forschungslücke präzisiert, die den Ausgangspunkt der empirischen Untersuchung bildet.

Kapitel 3 erläutert das methodische Vorgehen der Arbeit. Es beschreibt das Forschungsdesign, die Auswahl der untersuchten Unternehmen und Dokumente sowie die Logik der Inhaltsanalyse. Darüber hinaus werden das entwickelte Codebuch, die Operationalisierung der Konvergenz- und Governance-Indizes sowie Maßnahmen zur Sicherung von Reliabilität und Validität dargestellt. Ziel dieses Kapitels ist es, die Transparenz und Nachvollziehbarkeit der empirischen Vorgehensweise sicherzustellen.

Kapitel 4 präsentiert die Ergebnisse der vergleichenden Analyse. Es werden zunächst die untersuchten KI-Richtlinien und deren Verteilung beschrieben, bevor die Befunde zur Werte-Konvergenz und zur Governance-Tiefe systematisch dargestellt werden. Die Analyse erfolgt sowohl deskriptiv als auch vergleichend und bildet die empirische Grundlage für die anschließende Diskussion.

Kapitel 5 ordnet die Ergebnisse in den theoretischen Kontext ein und diskutiert deren Bedeutung für Wissenschaft und Praxis. Dabei werden die Befunde im Hinblick auf die identifizierte Forschungslücke reflektiert, praktische Implikationen abgeleitet und Limitationen der Untersuchung benannt. Abschließend fasst Kapitel 6 die zentralen Erkenntnisse prägnant zusammen und beantwortet die leitenden Forschungsfragen in verdichteter Form.

Der Aufbau der Arbeit ist damit konsequent auf das zentrale Erkenntnisinteresse ausgerichtet: die systematische Analyse der Konvergenz ethischer Werte in KI-Richtlinien der DAX-Unternehmen und die Bewertung ihrer organisatorischen Governance-Tiefe.

2. Theoretischer Rahmen und Literaturüberblick

Dieses Kapitel entwickelt das theoretische Fundament für die Untersuchung der Konvergenz ethischer Werte in KI-Richtlinien von DAX-Unternehmen und deren Governance-Tiefe. Dazu werden zunächst globale KI-Ethik-Rahmen und empirische Konsenskartierungen als Referenz für ein international anschlussfähiges Werte-Codebuch verdichtet, anschließend Corporate AI-Governance als organisatorisches Umsetzungs- und Steuerungssystem konzeptualisiert, dann der Forschungsstand zu Unternehmensrichtlinien kritisch bilanziert und schließlich die Forschungslücke in Erwartungen/Hypothesen überführt.

2.1 Globale KI-Ethik

Die Diskussion um ‚ethische' bzw. ‚vertrauenswürdige' KI ist durch eine starke Proliferation von Prinzipiendokumenten geprägt, die als Soft-Law, Selbstverpflichtung oder policy-nahe Leitlinie fungieren und damit auch für Unternehmen einen zentralen Referenzrahmen bilden (beispielsweise EU HLEG, 2019, S. 2; OECD, 2019, S. 8-9; UNESCO, 2021, S. 18-20). Für eine vergleichende Inhaltsanalyse von Unternehmensrichtlinien ist diese globale Ebene aus zwei Gründen maßgeblich: Erstens schaffen internationale Rahmenwerke ein Minimum an normativer Vergleichbarkeit (welche Werte werden überhaupt erwartet). Zweitens zeigen Meta-Analysen, dass sich die Vielzahl an Dokumenten trotz unterschiedlicher Herausgeber in vielen Wertlabels annähert, gleichzeitig jedoch erhebliche Interpretations- und Umsetzungsdivergenzen bestehen (Jobin et al., 2019, S. 1; Fjeld et al., 2020, S. 4-5). Genau diese Doppelbewegung - Konvergenz in Begriffen, Divergenz in Bedeutungen und Praktiken - ist für das hier verfolgte Forschungsziel zentral, weil sie die Trennung zwischen Werteebene (Was wird beansprucht?) und Governance/Operationalisierung (Wie wird es organisatorisch umgesetzt?) begründet (Mittelstadt, 2019, S. 9-10; Hagendorff, 2020, S. 1-2).

2.1.1 Terminologischer Rahmen: Werte, Prinzipien, Anforderungen

Im weiteren Verlauf wird zwischen Werten, Prinzipien und Anforderungen unterschieden, weil Dokumente auf unterschiedlichen Abstraktionsstufen operieren. Werte fungieren als normative Leitideen (z. B. Menschenwürde, Gerechtigkeit), Prinzipien als generalisierte Handlungsnormen (z. B. fairness and non-discrimination), und Anforderungen als stärkere Konkretisierung, die sich eher in organisatorische Kontrollen, Prozesse oder artefaktbasierte Nachweise übersetzen lässt (EU HLEG, 2019, S. 2; UNESCO, 2021, S. 18-20). Diese Differenzierung ist empirisch wichtig: Eine Richtlinie kann auf Werte verweisen, ohne Prinzipien oder Anforderungen so zu spezifizieren, dass daraus Governance-Mechanismen ableitbar sind (Mittelstadt, 2019, S. 9). In der Unternehmenspraxis entsteht damit ein Risiko symbolischer Konformität: Wertlabels werden übernommen, während die operationalisierende Substanz unklar bleibt (Hagendorff, 2020, S. 6-8).

2.1.2 Normative Kernrahmen als Primäranker

EU-Rahmen: Trustworthy AI als mehrschichtiger Leitfaden. Die *Ethics Guidelines for Trustworthy AI* der EU-Expertengruppe definieren „Trustworthy AI“ über drei Komponenten, die über den gesamten Lebenszyklus erfüllt sein sollen: lawful, ethical und robust (EU HLEG, 2019, S. 2-5). Damit wird bereits eine systemische Perspektive angelegt: Ethik wird nicht isoliert, sondern als Zusammenspiel von Rechtskonformität, normativer Orientierung und technischer/sozialer Robustheit verstanden. Aus dieser Basis werden vier ethische Prinzipien abgeleitet - respect for human autonomy, prevention of harm, fairness, explicability - und ausdrücklich auf Spannungen bzw. Trade-offs zwischen ihnen hingewiesen (EU HLEG, 2019, S. 12-16). Für die Vergleichbarkeit von Unternehmensrichtlinien ist zudem bedeutsam, dass die EU-Guidelines den Schritt von Prinzipien zu sieben Anforderungen vollziehen (u. a. human agency and oversight, technical robustness and safety, privacy and data governance, transparency, diversity/non-discrimination/fairness, societal and environmental wellbeing, accountability) (EU HLEG, 2019, S. 14-21). Diese Anforderungen sind in ihrer Benennung bereits terminologisch anschlussfähig an viele Unternehmensdokumente und bieten zugleich einen Brückenkopf zur Operationalisierung, weil sie explizit mit technischen und nicht-technischen Methoden sowie einer (Pilot-)Assessment-Liste verknüpft werden (EU HLEG, 2019, S. 26-33).

OECD-Empfehlung: intergouvernementaler Mindestkonsens. Die OECD-Empfehlung operationalisiert Trustworthy AI als Gegenstand verantwortlicher ‚stewardship‘ und legt Grundprinzipien fest, die von Akteuren über den Lebenszyklus hinweg umzusetzen sind. Besonders prominent sind dabei (1) inclusive growth, sustainable development and well-being, (2) respect for the rule of law, human rights and democratic values, einschließlich fairness und privacy, (3) transparency and explainability, (4) robustness, security and safety sowie (5) accountability (OECD, 2019, S. 8-9). Im Unterschied zu rein ethischen Leitlinien ist dies insofern relevant, als die OECD zugleich Begriffe wie AI-System-Lifecycle definiert und damit die Anschlussfähigkeit an Governance-Logiken erhöht (OECD, 2019, S. 8). Für Unternehmensrichtlinien ist diese Kombination aus Wertbezug und prozessualer Orientierung von besonderer Bedeutung: Sie legt nahe, dass Werte nur dann als verantwortliche Steuerung gelten können, wenn sie entlang von Lebenszyklusphasen adressiert werden (OECD, 2019, S. 10-11).

UNESCO-Empfehlung: Werte- und Menschenrechtsorientierung mit Governance-Bezug. Die UNESCO-Empfehlung positioniert Werte explizit als Grundlage, aus der Prinzipien und Politikmaßnahmen folgen, und verknüpft diese mit menschenrechtlichen Verpflichtungen sowie Nachhaltigkeitszielen (UNESCO, 2021, S. 18-19). In den Prinzipienabschnitten finden sich u. a. Proportionality and Do No Harm, Safety and Security sowie Fairness and

Non-discrimination (UNESCO, 2021, S. 20). Die Empfehlung enthält darüber hinaus Bereiche der Policy-Action, in denen Themen wie Ethical Impact Assessment (EIA), Governance/Stewardship und Monitoring/Evaluation vorgesehen sind (UNESCO, 2021, S. 3). Für die spätere Operationalisierungsdiskussion ist dies bedeutsam, weil die UNESCO-Perspektive die Werteebene nicht als Endpunkt, sondern als Ausgangspunkt eines Governance-Zyklus (Assessment, Governance-Strukturen, Monitoring) rahmt (UNESCO, 2021, S. 9-10). Damit tritt (stärker als in vielen Unternehmensleitlinien) ein institutioneller Anspruch hervor: Werte sollen in Prüf- und Evaluationsmechanismen übersetzt werden, nicht nur kommunikativ bekundet werden.

2.1.3 Empirische Konsenskartierungen: Konvergenz in Wertlabels

Neben dem normativen Kernrahmen existiert eine wachsende Zahl an Meta-Analysen, die den Ethik-Diskurs empirisch kartieren. Diese Arbeiten sind für die Legitimation eines Werte-Codebuchs zentral, weil sie Konvergenz nicht nur als normative Setzung, sondern als beobachtetes Muster über Dokumentkorpora hinweg zeigen.

Jobin et al. (2019) analysieren ein globales Korpus von Prinzipien- und Guidelines-Dokumenten und berichten eine Konvergenz um fünf ethische Prinzipien (u. a. transparency; justice and fairness; non-maleficence; responsibility; privacy), zugleich aber substantielle Divergenzen in der Interpretation, Begründung, Adressierung sowie in der Frage der Implementierung (S. 3-7). Für die vorliegende Arbeit ist daran zweierlei wichtig. Erstens zeigt sich eine robuste Wiederkehr zentraler Wertecluster, die als Basiskategorien eines Codebuchs dienen können. Zweitens wird empirisch gestützt, dass Konvergenz in Überschriften nicht mit Einigkeit über konkrete Bedeutungen und Umsetzungspflichten gleichzusetzen ist (Jobin et al., 2019, S. 14-16).

Fjeld et al. (2020) entwickeln ein Mapping prominenter Prinzipien-Dokumente und identifizieren acht zentrale Themen, die in hoher Prävalenz auftreten: u. a. privacy, accountability, safety and security, transparency and explainability, fairness and non-discrimination sowie human control of technology (S. 4-6). Zugleich warnen sie vor einer Überinterpretation einzelner Dokumente: Der Kontext (kulturell, sprachlich, geografisch, organisatorisch) beeinflusse, welche Prinzipien relevant sind, und Prinzipien allein seien eher Ausgangspunkt als Endpunkt von Governance (Fjeld et al., 2020, S. 64-65). Damit liefert die Studie nicht nur eine inhaltliche Clusterlogik, sondern auch eine methodische Begründung, warum bei der Analyse von Unternehmensrichtlinien die Tiefe der Ausgestaltung neben der bloßen Nennung berücksichtigt werden muss.

Corrêa et al. (2023) berichten auf Basis einer Meta-Analyse von 200 Policies und Guidelines, dass mindestens 17 wiederkehrende Prinzipien identifizierbar sind und stellen zugleich

Limitationen globaler Korpusanalysen heraus (S. 13). Diese Befunde sind vor allem als Plausibilisierung relevant, dass der Kern an Werten zwar stabil ist, die Ränder aber ausdifferenziert und je nach Korpus, Sektor und Region variieren können. Für eine Unternehmensanalyse bedeutet dies: Ein Werte-Codebuch muss sowohl den Kernkonsens abbilden als auch Raum für differenzierte Ausprägungen lassen, ohne ausufernd zu werden.

Zur Verdichtung der wiederkehrenden Wertcluster werden die Kernbegriffe der globalen Rahmenwerke und Meta-Analysen in Tab. 2-1 zusammengeführt.

Wertecluster (Arbeitslabel)	**Typische Synonyme/Labels in der Literatur**	**Beispiele für Nennung in Rahmenwerken / Korpora**
Human Agency & Oversight	Autonomie, Human control, Human-in-the-loop	human autonomy (EU HLEG, 2019, S. 2); human control of technology (Fjeld et al., 2020, S. 4)
Fairness & Non-discrimination	Gerechtigkeit, Justice, Equity, Bias-Mitigation	fairness (EU HLEG, 2019, S. 2); fairness and non-discrimination (UNESCO, 2021, S. 20); justice and fairness (Jobin et al., 2019, S. 1)
Transparency & Explainability	Explicability, Erklärbarkeit, Disclosure	explicability (EU HLEG, 2019, S. 2); transparency and explainability (OECD, 2019, S. 8); transparency (Jobin et al., 2019, S. 1)
Privacy & Data Governance	Datenschutz, Data protection	privacy and data governance (EU HLEG, 2019, S. 2); privacy (Jobin et al., 2019, S. 1); rule of law… incl. privacy (OECD, 2019, S. 8)
Robustness, Safety & Security	Harm prevention, Non-maleficence, Reliability	prevention of harm (EU HLEG, 2019, S. 2); robustness, security and safety (OECD, 2019, S. 9); do no harm (UNESCO, 2021, S. 20)
Accountability & Responsibility	Verantwortlichkeit, Auditability, Redress	accountability (EU HLEG, 2019, S. 2; OECD, 2019, S. 9); responsibility (Jobin et al., 2019, S. 1); accountability (Fjeld et al., 2020, S. 4)
Societal/Environmental Well-being	Nachhaltigkeit, Sustainability, Common good	societal and environmental well-being (EU HLEG, 2019, S. 2); sustainable development and well-being (OECD, 2019, S. 8)

Tab. 2-1: Wiederkehrende Wertecluster in globalen KI-Ethik-Rahmenwerken und Meta-Analysen, eigene Darstellung auf Basis von EU HLEG, 2019, S. 2; OECD, 2019, S. 8-9; UNESCO, 2021, S. 20; Jobin et al., 2019, S. 1; Fjeld et al., 2020, S. 4; Corrêa et al., 2023, S. 1.

Die Tabelle zeigt: Trotz heterogener Entstehungskontexte lässt sich ein stabiler Kern an Werteclustern rekonstruieren. Für die vorliegende Arbeit legitimiert das die Entwicklung eines Werte-Codebuchs, das an internationalen Rahmenwerken anschlussfähig ist und zugleich empirisch beobachtete Konvergenzmuster abbildet (Jobin et al., 2019, S. 17-20; Fjeld et al., 2020, S. 66).

2.1.4 Kritische Perspektiven: Konsens als begriffliche und praktische Illusion

Der beobachtete Kernkonsens darf jedoch nicht vorschnell als substanzielle Einigkeit interpretiert werden. Drei Kritiklinien sind hierfür besonders relevant, weil sie die Logik getrennt zu betrachtender Indizes (Werte vs. Governance-Tiefe) stützen.

Erstens wird betont, dass Prinzipienlisten häufig vage bleiben und damit wenig handlungsleitend sind. Mittelstadt (2019) argumentiert, dass das Feld zwar eine globale Konvergenz um High-Level-Prinzipien aufweist, diese aber politische und normative Konflikte verdecken können; zudem fehle es (beispielsweise im Vergleich zur Medizinethik) unter anderem an gemeinsamen Zielen und Treuhandpflichten, an professionellen Normen, an bewährten Methoden zur Übersetzung von Prinzipien in Praxis sowie an robusten Rechenschaftsmechanismen (S. 5-8). Diese Diagnose ist für Unternehmensrichtlinien unmittelbar anschlussfähig: Selbst wenn Werte benannt werden, ist unklar, ob und wie sie in Organisationsstruktur, Prozesse und Nachweise übersetzt werden.

Zweitens problematisiert Hagendorff (2020) die Wirksamkeit von Ethik-Guidelines. Er hebt hervor, dass Ethik in vielen Fällen keine starken Durchsetzungsmechanismen besitzt und gerade deshalb für Organisationen attraktiv sein kann, weil ethische Selbstverpflichtungen regulatorische Initiativen entmutigen können; in seiner Einleitung beantwortet er die Frage nach dem tatsächlichen Einfluss vieler Leitlinien pointiert negativ („most often not“) (S. 1-2). Für eine governance-bezogene Bewertung impliziert das: Der Nachweis organisatorischer Mechanismen (z. B. Audits, Redress, Zuständigkeiten) ist zentraler als die Existenz von Leitbildformulierungen.

Drittens betonen Meta-Analysen selbst die Interpretationsdivergenz: Jobin et al. (2019) finden bei den fünf Kernprinzipien substanzielle Unterschiede in Interpretation und Implementierungslogik (S. 14-16); Fjeld et al. (2020) warnen, dass Prinzipien stark kontextabhängig sind und als Startpunkt von Governance verstanden werden sollten (S. 4-5). Damit ist eine Konvergenz in der Werteebene zwar plausibel, aber empirisch offen, ob sie in Governance-Strukturen überführt wird.

2.2 Corporate AI-Governance

Globale Ethik-Rahmen geben einen normativen Referenzpunkt, beantworten aber nur begrenzt die organisationspraktische Frage, wie ethische KI in Unternehmen systematisch erzeugt, abgesichert und verantwortet wird. Diese Umsetzungsebene wird im Governance-Begriff gebündelt. Für das Erkenntnisinteresse dieser Masterarbeit - Konvergenz ethischer Werte in KI-Richtlinien von DAX-Unternehmen und Governance-Bewertung - ist Corporate AI-Governance dabei nicht als Ethikstatement, sondern als organisationales Steuerungssystem zu fassen: Rollen, Routinen, Prozesse und Artefakte, die sicherstellen sollen, dass KI-Entwicklung und -Einsatz mit Zielen, Werten, Stakeholder-Erwartungen und rechtlichen Anforderungen kompatibel sind (Birkstedt et al., 2023, S. 2).

2.2.1 Begriff und Umfang: AI-Governance als System von Regeln, Praktiken und Prozessen

In der Governance-Literatur ist auffällig, dass explizite Definitionen lange Zeit rar waren und das Feld fragmentiert ist (Birkstedt et al., 2023, S. 1-2). Vor diesem Hintergrund schlagen Birkstedt et al. (2023) eine Arbeitsdefinition vor, wonach AI-Governance ein System aus Regeln, Praktiken, Prozessen (und teils technologischen Tools) ist, das die Nutzung von KI in Organisationen an Strategien, Zielen und Werten ausrichtet und zugleich rechtliche, ethische sowie stakeholderbezogene Anforderungen integriert (S. 2). Diese Definition ist aus methodischer Sicht hilfreich, weil sie Governance explizit von bloßen Prinzipienlisten trennt: Governance ist nicht der Inhalt einer Leitlinie, sondern die Architektur, in der Inhalte verbindlich gemacht, überprüfbar dokumentiert und im Lebenszyklus wirksam gehalten werden sollen.

Die Lebenszyklusorientierung ist dabei kein bloßes rhetorisches Element. Die OECD (2019) beschreibt einen typischen KI-Lebenszyklus als mehrphasigen Prozess (u. a. Planung/Design, Daten sammeln/aufbereiten, Modelle bauen/adaptieren, testen/validieren, deployment, Betrieb/Monitoring und ggf. Decommissioning), der iterativ verlaufen kann (S. 3). EU- und UNESCO-Rahmen verankern ihre Anforderungen ebenfalls ausdrücklich über den gesamten Systemlebenszyklus hinweg (EU HLEG, 2019, S. 2; UNESCO, 2021, S. 18-20). Corporate AI-Governance muss daher, wenn sie den internationalen Rahmenwerken entsprechen will, prinzipiell mehrere Phasen und Funktionsbereiche umfassen: von Produkt/IT über Recht/Compliance bis hin zu Risikomanagement, HR (Training) und ggf. Nachhaltigkeit.

Mit dem EU AI Act (Verordnung EU-2024/1689) verschiebt sich der Charakter von AI-Governance-Anforderungen von weitgehend freiwilligen Prinzipienrahmen hin zu verbindlichen Pflichten entlang der AI-Value-Chain (u.a. für Provider/Anbieter, Deployers/Betreiber, Importers/Distributors). Der Rechtsakt etabliert einen risikobasierten Rahmen (inkl. High-Risk AI Systems sowie spezifischen Regeln für General-Purpose-AI-Modelle) und übersetzt normative Leitideen (insb. Schutz von Gesundheit, Sicherheit und

Grundrechten) in prüf- und dokumentationsfähige Governance-Artefakte. So wird für High-Risk-Systeme ein kontinuierliches, iteratives Risikomanagement über den gesamten Lebenszyklus gefordert (EU, 2024, S. 19-20). Darüber hinaus verpflichtet der Rechtsakt Anbieter zu einem dokumentierten Quality-Management-System (QMS), das Governance-Bausteine wie Risikomanagement, Datenmanagement, Post-Market-Monitoring, Incident-Reporting und Record-Keeping umfasst (EU, 2024, S. 62-63). Er operationalisiert Human Oversight (inkl. Fähigkeit zum Override/Reverse sowie sicherer Unterbrechung/Stop) und adressiert Automation Bias (EU, 2024, S. 60-61). Für bestimmte Betreiber/Use-Cases wird eine Fundamental Rights Impact Assessment (FRIA) eingeführt, einschließlich Governance-Arrangements, Complaint Mechanisms und Meldepflichten (EU, 2024, S. 69-70). Schließlich werden Post-Market-Monitoring (technische Dokumentation) sowie die Meldung „serious incidents“ mit Fristen und Follow-up-Logik verbindlich geregelt (EU, 2024, S. 101-102). Für General-Purpose-AI-Modelle kommen u. a. Copyright-Compliance-Policy und eine öffentliche Beschreibung der Trainingsdaten-Content-Quellen hinzu; zudem wird eine Systemic-Risk-Logik diskutiert (EU, 2024, S. 27-29).

Für die vorliegende Arbeit ist der EU AI Act damit doppelt relevant: Erstens liefert er einen starken Werte- und Grundrechte-Referenzrahmen als Terminologie-Anker für die Werte-Taxonomie. Zweitens bietet er einen ‚Goldstandard‘ operationalisierter Governance (Rollenpflichten, Prozesse, Tools/Checks, Assessments, Monitoring und Reporting), der nahezu 1:1 auf eine Governance-Rubrik abbildbar ist und den principle-to-practice gap regulatorisch zuspitzt: Ethik/Grundrechte werden in Rollen-, Prozess- und Dokumentationspflichten übersetzt (z.B. QMS, Risk-Management, FRIA, Monitoring/Incidents).

2.2.2 Der principle-to-practice gap als Kernproblem

Die Literatur betont wiederholt eine Lücke zwischen dem ‚Was‘ (Prinzipien) und dem ‚Wie‘ (praktische Umsetzung). Morley et al. (2020) charakterisieren die Debatte als stark prinzipienzentriert und begründen die Notwendigkeit einer Typologie von Tools und Methoden, die Entwickler entlang der ML-Pipeline unterstützen sollen (S. 2154-2157). Inhaltlich korrespondiert diese Diagnose mit der Skepsis, dass Prinzipien ohne Übersetzungsmechanismen wenig Wirkung entfalten (Mittelstadt, 2019, S. 7-8). Governance ist damit nicht ‚nice to have‘, sondern die Bedingung dafür, dass Werte operationalisierbar werden: Ohne Prozesse, Verantwortlichkeiten, Werkzeuge und Nachweise bleibt Ethik häufig deklarativ.

Für die vorliegende Arbeit hat diese Literaturperspektive zwei Implikationen. Erstens müssen Unternehmensrichtlinien nicht nur auf Werte geprüft werden, sondern darauf, ob sie Operationalisierungswege benennen (z. B. Risiko-/Impact-Assessments, Audit-Prozesse,

Logging/Traceability, Eskalations- und Redress-Mechanismen). Zweitens ist die Tiefe dieser Operationalisierung graduell zu erfassen: Zwischen dem bloßen Benennen (‚Wir achten auf Fairness') und dem Nachweis implementierter Mechanismen (‚Wir führen regelmäßige Bias-Tests mit dokumentierten Kriterien durch und reporten Incidents') liegen relevante Abstufungen, die Governance-Reife anzeigen (EU HLEG, 2019, S. 24-33; Morley et al., 2020, S. 2149-2150).

2.2.3 Operationalisierung entlang des Lebenszyklus

Aus den verwendeten Quellen lassen sich wiederkehrende Mechanismen ableiten, die als Übersetzungsartefakte zwischen Prinzipien und Praxis fungieren können.

(1) Rollen, Zuständigkeiten und Oversight. Sowohl EU-Guidelines als auch OECD- und UNESCO-Rahmen verknüpfen Trustworthiness mit dem gesamten Lebenszyklus und implizieren damit Verantwortungsketten, die Rollen und Zuständigkeiten voraussetzen (EU HLEG, 2019, S. 2; OECD, 2019, S. 8; UNESCO, 2021, S. 18). In der Organisationsliteratur wird zudem die Notwendigkeit einer AI-Oversight-Einheit bzw. klarer Governance-Strukturen als künftige Agenda betont, um Prozesse verlässlich zu etablieren (Birkstedt et al., 2023, S. 25-26). Für Unternehmensrichtlinien ist daher relevant, ob Verantwortlichkeit als abstrakter Wert (‚Accountability') formuliert wird oder in konkrete Oversight-Strukturen überführt wird.

(2) Prozesse des Risiko- und Impact-Managements. Der OECD-Text fordert eine systematische, lebenszyklusbezogene Risikomanagement-Orientierung im Kontext von Accountability (OECD, 2019, S. 9). Die EU-Guidelines gehen noch weiter, indem sie Anforderungen nicht nur benennen, sondern über umsetzungsnahe Methoden und eine Assessment-Liste mit Kontrollfragen operationalisieren (EU HLEG, 2019, S. 26-33). UNESCO (2021) rahmt Werte/Prinzipien ebenfalls mit Assessment- und Monitoring-Logiken (S. 3). Governanceseitig sind damit formalisierte Prozesse adressiert: Risikoanalyse, Impact Assessments, Kontext- und Stakeholder-Analyse sowie Nachverfolgung über den Betrieb hinweg.

(3) Technische und nicht-technische Tools als Übersetzungsinstrumente. Morley et al. (2020) argumentieren, dass die Fähigkeit der Community, Risiken zu mitigieren, „at its infancy" sei und schlagen eine Typologie vor, die praxisnahen Akteuren hilft, Ethik entlang der ML-Entwicklung zu berücksichtigen (S. 2141). EU-Guidelines nennen beispielhaft technische und organisatorische Mittel wie Testing/Validation, Erklärbarkeitsverfahren, Logging/Traceability, aber auch Standards, Certification, Governance-Frameworks und Training (EU HLEG, 2019, S. 22-26). Díaz-Rodríguez et al. (2023) betonen in ihrer multidisziplinären Sicht, dass Anforderungen (z. B. Transparenz, Accountability) nicht nur definitorisch, sondern auch über ‚How'-Perspektiven adressiert werden müssen, und koppeln

verantwortliche Systeme an Audit-Prozesse (S. 18-19). Für die Bewertung von Unternehmensrichtlinien wird damit relevant, ob sie Tools/Prozesse tatsächlich als Governance-relevante Praktiken ausweisen oder nur auf abstrakter Ebene verbleiben.

(4) Auditing und Assurance als Governance-Mechanik. Audits werden in der Unternehmenspraxis häufig als sichtbares Signal von Rechenschaft inszeniert, sind aber in der Forschung als ambivalentes Instrument diskutiert. Mökander et al. (2021) definieren „ethics-based auditing“ (EBA) als strukturierten Prozess, der Verhalten bzw. Systeme auf Konsistenz mit relevanten Prinzipien/Normen prüft, und argumentieren, dass EBA Governance unterstützen kann, etwa über prozedurale Regelmäßigkeit und Transparenz (S. 1). Gleichzeitig werden technische, organisatorische und institutionelle Constraints systematisch herausgearbeitet, weshalb Auditing als Bestandteil „multifaceted approaches“ verstanden werden sollte, nicht als Allheilmittel (Mökander et al., 2021, S. 20-21, 23). Für Unternehmensrichtlinien bedeutet das: Die bloße Nennung von den Begriffen Audit bzw. Assessment ist kein ausreichender Indikator für tatsächliche Governance-Substanz; entscheidend ist, ob Verfahren, Kriterien, Unabhängigkeit, Frequenz, Scope und Anschlussprozesse (z. B. Remediation) beschrieben werden.

Diese Mechanismen lassen sich in eine Evidenz-Logik überführen, die später eine Governance-Bewertung ermöglicht. Tab. 2-2 verdichtet die im Literaturkorpus angelegte Kernidee, dass zwischen Benennung und nachweisbarer Implementierung unterschieden werden muss (EU HLEG, 2019, S. 24-33; EU, 2024, S. 19-20, 27-29, 60-63, 69-70,101-102; Birkstedt et al., 2023, S. 1-2; Morley et al., 2020, S. 2141; Mökander et al., 2021, S. 1).

Tiefe	**Indikator in Richtlinien (typische Evidenz)**	**Interpretation (Governance-Substanz)**
0 - nicht adressiert	Wert/Governance-Element fehlt oder bleibt implizit	Keine sichtbare Steuerungsabsicht bzw. keine kommunizierte Governance
1 - benannt	Element wird als Ziel/Prinzip erwähnt (z. B. „wir auditieren“, „wir führen Assessments durch“)	Symbolische/programmatische Setzung; Umsetzungsgrad offen
2 - dokumentiert	Prozesse, Rollen, Artefakte werden beschrieben (z. B. Zuständigkeit, Prozessschritte, Dokumentationspflicht)	Strukturelle Operationalisierungsabsicht; Nachweisbarkeit potenziell gegeben
3 - implementiert & nachweisbar	Konkrete Nachweise/Verfahrensdetails (Scope, Frequenz, Kriterien, Reporting, Eskalation/Redress)	Hohe Governance-Reife: von Prinzip zu kontrollierbarer Praxis übersetzt

Tab. 2- 2: Evidenzlogik zur Governance-Tiefe in Unternehmensrichtlinien (Rubrik 0-3), eigene Darstellung auf Basis von EU HLEG, 2019, S. 24-33; EU, 2024, S. 19-20, 27-29, 60-63, 69-70,101-102; OECD, 2019, S. 8-9; UNESCO, 2021, S. 3; Birkstedt et al., 2023, S. 1-2; Morley et al., 2020, S. 2141; Mökander et al., 2021, S. 1

Die Tabelle stellt keine empirischen Ergebnisse dar, sondern expliziert die aus der Literatur ableitbare Differenz: Governance kann als Grad der Übersetzung von Prinzipien in überprüfbare Organisationspraktiken verstanden werden. Diese Logik ist anschlussfähig an die EU-Assessment-Orientierung (EU HLEG, 2019, S. 26-33; EU, 2024, S. 69-70), an die Tool-Perspektive (Morley et al., 2020, S. 2141) und an die Audit-Debatte (Mökander et al., 2021, S. 1).

2.2.4 Kritische Würdigung: Fragmentierung, Implementierungslücken und Kontextabhängigkeit

Trotz konzeptioneller Fortschritte bleibt die Governance-Forschung von Unsicherheit geprägt. Birkstedt et al. (2023) identifizieren u. a. als zentrale Wissenslücken eine begrenzte empirische Kenntnis der Implementierung, unklare Effektivität von Prinzipien und Regulation sowie unzureichende Operationalisierung von Governance-Prozessen (S. 18-22). Diese Diagnose ist für eine DAX-AI-Policy-Analyse besonders relevant, weil öffentliche Unternehmensrichtlinien typischerweise nur einen Ausschnitt der tatsächlichen Governance-Strukturen abbilden: Selbst wenn intern Prozesse existieren, können diese selektiv oder vage offengelegt werden; umgekehrt kann eine detaillierte Policy auch ohne tiefgreifende Implementation existieren. Governance-Bewertung benötigt daher eine explizite Evidenzlogik und muss zugleich die Grenzen öffentlicher Dokumente reflektieren (Mökander et al., 2021, S. 23).

Wenn Corporate AI-Governance als System aus Rollen, Prozessen, Tools und Nachweisen verstanden wird, stellt sich empirisch die Frage, wie Unternehmen diese Logik in öffentlich zugänglichen Richtlinien tatsächlich abbilden. Der nächste Abschnitt bündelt daher den Forschungsstand zu Corporate Policies, typischen Lücken und der Kritik an symbolischer Konformität (washing, decoupling) und arbeitet heraus, warum Werte-Konvergenz nicht automatisch Governance-Tiefe bedeutet.

2.3 Forschungsstand zu Unternehmensrichtlinien

Die Forschung zu Unternehmensrichtlinien im KI-Kontext steht zwischen zwei Befundlinien: Auf der einen Seite wird eine starke Angleichung an wiederkehrende Prinzipienlabels dokumentiert (Jobin et al., 2019, S. 1; Fjeld et al., 2020, S. 4). Auf der anderen Seite findet sich wiederholt Kritik, dass solche Policies ohne belastbare Operationalisierung vor allem kommunikative Funktionen erfüllen können und in der Praxis nur begrenzt wirksam sind (Mittelstadt, 2019, S. 1; Hagendorff, 2020, S. 1-2). Für das Thema dieser Masterarbeit - Konvergenz ethischer Werte in KI-Richtlinien von DAX-Unternehmen und

Governance-Bewertung - ist genau diese Spannung der zentrale Ausgangspunkt: Nicht nur das ‚Welche Werte?', sondern das ‚Wie glaubwürdig operationalisiert?' wird zur entscheidenden Prüfgröße.

2.3.1 Corporate Policies zwischen Konvergenz und Umsetzungslücke

De Laat (2021) untersucht Unternehmen, die sich öffentlich zu Responsible-AI-Principles bekennen, und rahmt Responsible AI als Bündel von Eigenschaften (u. a. fairness/non-bias, transparency/explainability, security/safety, privacy, accountability, beneficence) (S. 1141-1145). Aus einer umfassenden Web-Recherche leitet er ab, dass, auch wenn viele Organisationen seit 2016 Prinzipien publizieren, nur ein Teil der untersuchten Unternehmen substanziellere Implementierungsschritte zeigt; außerdem hebt er hervor, dass insbesondere einige große Unternehmen durch die Entwicklung und Open-Sourcing von Tools „valuable steps" in Richtung Implementierung gehen, während gleichzeitig der Vorwurf des „Ethics-Washing" im Raum steht (de Laat, 2021, S. 1138, 1147, 1163-1166). Diese Befunde sind für eine Policy-Analyse doppelt relevant. Erstens stützen sie die Erwartung, dass Prinzipienkonvergenz kommunikativ leicht erreichbar ist (Publikation/Commitment), während Operationalisierung kosten- und kompetenzintensiv ist (Tools, Prozesse). Zweitens zeigen sie, dass sich ‚Implementierung' in öffentlich sichtbaren Aktivitäten (z. B. Tooling) manifestieren kann. Ein Hinweis, dass Governance-Tiefe in Richtlinien zumindest teilweise über konkrete Mechanismen fassbar sein sollte.

Parallel dazu unterstreicht Jobin et al. (2019) bereits auf Korpusebene, dass bei gleicher Prinzipienetikettierung erhebliche Unterschiede in Implementierungslogik bestehen (S. 14-16). Für Unternehmensrichtlinien bedeutet das: Selbst wenn DAX-Unternehmen ähnliche Wertecluster adressieren, ist offen, ob sie diese in vergleichbarer Weise definieren und organisatorisch absichern. Daraus folgt methodisch, dass eine reine Häufigkeitsanalyse von Wertnennungen zwar Konvergenz zeigen kann, aber ohne Governance-Bewertung riskiert, Interpretations- und Umsetzungsdifferenzen zu übersehen (Fjeld et al., 2020, S. 66).

2.3.2 Audit-Zentrierung, Audit-Washing und Grenzen von Assurance

In der Praxis werden Audits und Assessments häufig als Instrumente dargestellt, um verantwortungsbewusste KI-Implementierung nachweisbar zu machen. Forschungsliteratur spricht Auditing zwar eine wichtige Governance-Funktion zu, betont aber ebenso klare Grenzen. Mökander et al. (2021) definieren EBA als strukturierten Bewertungsprozess und stellen Kriterien für erfolgreiche Gestaltung sowie zahlreiche Bedingungen heraus (S. 4). In einer kritischen Lesart bedeutet dies: Audit-Rhetorik kann Governance-Substanz signalisieren, sie kann aber auch als Kontroll-Vokabular genutzt werden, ohne dass Scope, Unabhängigkeit oder Anschlussfähigkeit an Remediationprozesse transparent werden.

Gerade bei öffentlich zugänglichen Richtlinien ist diese Ambivalenz hoch, weil Audits als reputationswirksames Signal funktionieren, während Details der Audit-Praxis oft nicht offengelegt werden (Mökander et al., 2021, S. 17-21).

Diese Governance-Ambivalenz korrespondiert mit genereller Kritik an Prinzipienansätzen. Mittelstadt (2019) warnt, dass High-Level-Prinzipien konkrete Empfehlungen vermissen lassen und ohne robuste Accountability-Mechanismen eher zu „virtue signalling“ oder Selbstregulierung führen können (S. 9). Hagendorff (2020) argumentiert ähnlich, dass Ethik-Guidelines häufig nicht in wirksame Praxis übersetzt werden und damit häufig nur als PR-Instrument fungieren (S. 2). Für Unternehmensrichtlinien ergibt sich daraus eine klare Bewertungsnotwendigkeit: Audits/Assessments sollten nicht als binäres Vorhandensein, sondern als Grad der Spezifikation und Evidenz bewertet werden (vgl. Tab. 2-2).

2.3.3 Ethics-Washing als Governance-Problem

Der Begriff ‚Ethics-Washing‘ wird im KI-Diskurs als Parallelbegriff zu Greenwashing diskutiert, um die Überbetonung ethischer Kommunikation bei gleichzeitiger Umsetzungsunsicherheit zu beschreiben. Peukert und Kloker (2020) definieren „Ethics-Washing“ als Überzeichnung der Rolle von Ethik in Policy und Kultur und als Strategie, regulatorischen Druck zu beeinflussen oder zu vermeiden, und zeigen in einer Online-Studie, dass wahrgenommenes Ethics-Washing das Konsumentenvertrauen negativ beeinflussen kann (S. 1-4). Für eine Masterarbeit im Marketingmanagement ist dieser Befund besonders relevant, weil er den Governance-Diskurs mit marktorientierten Zielgrößen verbindet: Wenn Stakeholder Ethics-Washing wahrnehmen, kann dies Vertrauen unterminieren und damit die Legitimität vertrauensbasierter KI-Kommunikation schwächen.

Aus Governance-Perspektive folgt daraus eine zusätzliche Zuspitzung: Corporate AI-Policies sind nicht nur interne Steuerungsinstrumente, sondern auch externe Kommunikationsartefakte. Je stärker sie ethische Werte betonen, desto größer kann das Risiko sein, dass Stakeholder bei wahrgenommenen Lücken zwischen Rhetorik und sichtbarer Praxis Vertrauensverluste erleben (Peukert & Kloker, 2020, S. 8-11). Dies verstärkt die Relevanz einer Governance-Bewertung, die die Tiefe der Operationalisierung sichtbar macht.

2.3.4 Decoupling, Transparenz-Illusion und selektive Offenlegung als Analogie

Eine weitere kritische Perspektive liefert die Nachhaltigkeitsberichterstattung: Hier wird seit Jahren diskutiert, dass Berichte symbolisch sein können und tatsächliche Praktiken davon entkoppelt sind (decoupling). Roszkowska-Menkes et al. (2024) untersuchen selektive Offenlegung als Ausprägung von decoupling und berichten, dass über 69 % der untersuchten, negativen Ereignisse nur selektiv berichtet wurde; sie differenzieren Formen wie vage

disclosure, avoidance und hypocrisy und finden zudem, dass weder GRI-Guidelines noch Assurance-Maßnahmen selektive Offenlegung effektiv verhindern (S. 13). Diese Befunde sind für die AI-Policy-Analyse konzeptionell anschlussfähig: Auch KI-Richtlinien können selektiv offenlegen - etwa indem Werte breit benannt werden, während Prozesse, Incidents oder Audit-Ergebnisse unklar bleiben. Die Nachhaltigkeitsanalogie stützt damit die Annahme, dass Transparenz in Reporting-Artefakten nicht automatisch mit tatsächlicher Governance-Substanz gleichzusetzen ist (Roszkowska-Menkes et al., 2024, S. 18).

Für die vorliegende Arbeit wird dadurch eine wichtige Prüfperspektive begründet: Unternehmensrichtlinien sollten nicht nur auf positive Selbstbeschreibungen hin analysiert werden, sondern auf die Struktur der Offenlegung (z. B. konkrete Prozesse vs. vage Versprechen) und auf Indikatoren potenzieller Entkopplung, etwa wenn starke ethische Claims ohne korrespondierende Mechanismen oder Nachweise auftreten.

2.3.5 GenAI als Richtlinien-Stresstest

Die jüngsten Entwicklungen generativer KI (z. B. Konversationssysteme wie ChatGPT) verschieben die Risikolandschaft und können Corporate-Policy-Diskurse als Stresstest wirken lassen. Stahl und Eke (2024) identifizieren im Kontext von ChatGPT eine breite Palette ethischer Anliegen, u. a. Verantwortung, Inklusion, soziale Kohäsion, Autonomie, Safety, Bias, Accountability und Umweltwirkungen, und argumentieren, dass Organisationen verlässliche, breit fundierte Guidance benötigen (S. 9-10). Für Corporate Policies bedeutet dies: Selbst wenn Wertecluster stabil sind, kann die Priorisierung einzelner Risiken (z. B. Urheberschaft, Missinformation, neue Bias-Formen) dynamisch werden. Für eine DAX-Analyse ist dieser Punkt primär als Kontext relevant: Er erhöht die Wahrscheinlichkeit, dass Unternehmen Richtlinien aktualisieren, dass aber zugleich kurzfristige Policy-Reaktionen mit begrenzter Governance-Tiefe auftreten können, wenn organisatorische Strukturen nicht Schritt halten.

Der Forschungsstand zeigt damit eine robuste Werte-Konvergenz (Kerncluster) und zugleich erhebliche Unsicherheit, ob (und wie tief) Unternehmen diese Werte in Governance-Mechanismen übersetzen. Zusätzlich legen Konzepte wie Ethics-Washing und decoupling nahe, dass öffentliche Policies strategisch kommunizieren und selektiv offenlegen können. Daraus lässt sich eine präzise Forschungslücke ableiten, die im nächsten Abschnitt in Erwartungen/Hypothesen übersetzt wird.

2.4 Forschungslücke und abgeleitete Erwartungen

Die bisherige Literatur legt nahe, dass sich die normative Debatte zu KI-Ethik in wiederkehrenden Werteclustern stabilisiert hat, was durch globale Rahmenwerke (EU HLEG, OECD, UNESCO) und Meta-Analysen (Jobin et al.; Fjeld et al.; Corrêa et al.) gestützt wird (EU HLEG, 2019, S. 2; OECD, 2019, S. 8-9; UNESCO, 2021, S. 18-20; Jobin et al., 2019, S.

1; Fjeld et al., 2020, S. 4; Corrêa et al., 2023, S. 1). Gleichzeitig betonen kritische Arbeiten, dass Prinzipienkonvergenz wenig über tatsächliche Wirksamkeit aussagt und ohne Übersetzungsmechanismen in Praxis und Accountability leicht symbolisch bleiben kann (Mittelstadt, 2019, S. 1; Hagendorff, 2020, S. 1-2). Die Organisationsliteratur zu AI-Governance ist zudem im Aufbau begriffen und identifiziert Implementierung und Operationalisierung von Governance-Prozessen als wesentliche Wissenslücken (Birkstedt et al., 2023, S. 1).

2.4.1 Forschungslücke

Vor diesem Hintergrund lässt sich die Forschungslücke als Dualität von Konvergenz und Umsetzung präzisieren: Es fehlt eine vergleichende, systematische Betrachtung, die (a) die Konvergenz ethischer Wertlabels in Unternehmensrichtlinien empirisch erfasst und (b) zugleich die Governance-Tiefe dieser Richtlinien bewertet, also den Grad der Übersetzung von Werten in Rollen, Prozesse, Artefakte und Nachweise. Während viele Arbeiten Wertecluster kartieren (Jobin et al., 2019, S. 1; Fjeld et al., 2020, S. 4), bleibt in der öffentlichen Policy-Ebene von Unternehmen häufig offen, ob Governance-Mechanismen substanziell ausgeführt werden oder primär kommunikativ wirken (Mittelstadt, 2019, S. 1; Hagendorff, 2020, S. 1-2). Ergänzend deuten empirische Arbeiten zu Corporate Commitments darauf hin, dass Implementierungsschritte ungleich verteilt und oft nur bei wenigen Akteuren sichtbar sind (de Laat, 2021, S. 1153). Die Nachhaltigkeitsforschung zeigt zudem, dass Reporting-Artefakte selektiv und entkoppelt sein können, selbst wenn externe Leitlinien oder Assurance existieren (Roszkowska-Menkes et al., 2024, S. 14-15). Für KI-Richtlinien ist daher ein analytischer Zugang nötig, der Konvergenz nicht nur als Gleichheit der Labels misst, sondern als potenziell ‚dünne' Übereinstimmung ohne Governance-Substanz verstehen kann.

2.4.2 Abgeleitete Erwartungen/Hypothesen

Aus dem Literaturüberblick lassen sich - als theoretisch plausibilisierte Erwartungslage - folgende Hypothesen ableiten:

H1 (Konvergenz asymmetrisch): Die Konvergenz ethischer Wertlabels in Unternehmensrichtlinien ist stärker ausgeprägt als die Konvergenz (bzw. der durchschnittliche Ausprägungsgrad) der Governance-Tiefe.

Begründung: Meta-Analysen zeigen eine robuste Wiederkehr zentraler Prinzipiencluster (Jobin et al., 2019, S. 3-7; Fjeld et al., 2020, S. 4-6). Gleichzeitig betonen Mittelstadt und Hagendorff, dass Prinzipienlisten ohne Übersetzungsmechanismen häufig wenig Wirkung entfalten und Implementierungsmechanismen fehlen (Mittelstadt, 2019, S. 9; Hagendorff, 2020, S. 6-8). De Laat (2021) dokumentiert zudem, dass nur ein Teil der Unternehmen sichtbare Implementierungsschritte zeigt (S. 1147-1149). Zusammen impliziert dies: Werte

werden leichter vereinheitlicht kommuniziert als Governance-Mechanismen implementiert bzw. öffentlich dokumentiert.

H2 (Kontrollvokabular ohne Substanz): Audit-/Assessment-Sprache kann in Richtlinien auftreten, ohne dass entsprechende, nachweisbare Governance-Mechanismen in vergleichbarer Tiefe beschrieben werden (washing/decoupling-Risiko).

Begründung: Auditing ist als Governance-Mechanismus konzeptionell hilfreich, aber durch vielfältige constraints begrenzt; daher ist die bloße Nennung kein hinreichender Nachweis (Mökander et al., 2021, S. 3). Gleichzeitig zeigt die marketing-perspektivische Evidenz, dass Ethics-Washing als überzeichnete Ethikkommunikation verstanden wird und Vertrauen unterminieren kann (Peukert & Kloker, 2020, S. 8). Die Nachhaltigkeitsforschung stützt konzeptionell, dass Offenlegung selektiv sein kann und Assurance nicht zwingend decoupling verhindert (Roszkowska-Menkes et al., 2024, S. 13-15). Daraus folgt die Erwartung, dass Kontrollbegriffe in Richtlinien teilweise symbolisch verwendet werden können.

H3 (Regulations-/Standard-Pull): Stärkerer regulatorischer bzw. standardbezogener Druck wirkt als Pull-Faktor für die Operationalisierung, d. h. für die Ausgestaltung dokumentierter Governance-Mechanismen in Richtlinien.

Begründung: Globale Rahmenwerke koppeln Trustworthiness explizit an lebenszyklusbezogene Anforderungen, Accountability und Monitoring (EU HLEG, 2019, S. 2; OECD, 2019, S. 8-9; UNESCO, 2021, S. 3) In der Governance-Logik ist daher plausibel, dass Externalisierung von Anforderungen (Regulierung/Standards) die Wahrscheinlichkeit erhöht, dass Unternehmen Governance-Elemente nicht nur benennen, sondern dokumentieren.

Diese Hypothesen begründen die Notwendigkeit, in der empirischen Analyse (Kapitel 3 ff.) Werte-Konvergenz und Governance-Tiefe getrennt, aber verknüpft zu operationalisieren und vergleichend zu bewerten, ohne allein aus der Existenz von Prinzipien auf Implementierung zu schließen (Fjeld et al., 2020, S. 66; Mittelstadt, 2019, S. 9-10).

3. Methode

Nachfolgend wird das methodische Vorgehen zur Untersuchung der Konvergenz ethischer Werte in unternehmensbezogenen KI-Richtlinien der DAX-Unternehmen und zur Bewertung der Governance-Tiefe dieser Richtlinien vorgestellt. Ziel ist dabei eine replizier- und auditierbare ‚Bauanleitung': von der Materialbasis über das Codebuch und die Kodierlogik bis zur Indexbildung, dem Analyseplan und den Gütekriterien.

3.1 Forschungsdesign

Die Arbeit folgt einem Mixed-Methods-Design, das eine qualitative, vergleichende Inhaltsanalyse mit quantifizierenden Elementen kombiniert. Der qualitative Kern besteht in der systematischen Kodierung öffentlich zugänglicher Unternehmensdokumente (KI-Ethikrichtlinien bzw. äquivalente Textpassagen) entlang einer vorab definierten Wertetaxonomie und einer Governance-Rubrik. Die quantifizierende Erweiterung besteht darin, die qualitative Kodierung in zwei Indizes zu überführen: (a) einen Konvergenz-Index für Werte und (b) einen Operationalisierungs- bzw. Governance-Tiefenindex. Diese Kombination ist der wissenschaftliche Beitrag dieser Arbeit explizit als Antwort auf die in der Literatur diskutierte principle-to-practice-Lücke. Während viele Organisationen Leitlinienwerte und Prinzipien benennen, bleibt häufig offen, wie diese in verlässliche organisatorische Mechanismen übersetzt werden (Morley et al., 2020, S. 18-20).

Die Forschungslogik folgt dabei drei aufeinander aufbauenden Forschungsfragen: Erstens wird untersucht, welche ethischen Kernwerte in den Dokumenten erkennbar sind und wie stark die Werte-Sets zwischen Unternehmen konvergieren (RQ1). Zweitens wird erhoben, wie tief bzw. operationalisierungsnah diese Werte in Governance-Mechanismen übersetzt werden (RQ2). Drittens wird geprüft, ob ein Zusammenhang zwischen Werte-Konvergenz und Operationalisierungstiefe besteht und ob sich Unternehmensprofile (z. B. Cluster nach Wertemustern und Governance-Reife) identifizieren lassen (RQ3).

Konzeptionell stützt sich das Design auf die in Kapitel 2 verankerte Ebenenlogik von (abstrakten) Werten, (generalisierten) Prinzipien und (konkreteren) Anforderungen. Diese Unterscheidung ist für die Methode zentral, weil sie zwei Messdimensionen begründet, die analytisch getrennt bleiben müssen: (1) die Präsenz normativer Inhalte (Werte/Prinzipien) und (2) deren organisationaler ‚Durchgriff' in Richtung Prozesse, Rollen, Kontrollen und Nachweise (Governance). In der Terminologie der EU HLEG (2019) wird „Trustworthy AI" als Trias aus lawful, ethical und robust verstanden, die über den gesamten Lebenszyklus eines KI-Systems einzuhalten ist; die Leitlinien operationalisieren dies über Anforderungen (u. a. human agency/oversight, transparency, accountability) und flankierende Methoden (S. 4). Diese Struktur wird in der Arbeit als Referenzanker genutzt, um Werte und Governance-Anforderungen in ein kodierbares Konstrukt zu überführen.

Die Entscheidung für eine dokumentbasierte Inhaltsanalyse ist methodisch zweifach motiviert. Erstens ist der Untersuchungsgegenstand selbst dokumentär: Unternehmensrichtlinien, Codes, Responsible-AI-Principles oder KI-Ethikseiten sind kommunikative und normative Artefakte, über die Unternehmen Handlungsabsichten, Selbstbindungen und Governance-Arrangements adressieren. Zweitens erlaubt der dokumentbasierte Zugriff eine standardisierte, unternehmensvergleichende Beobachtung über einen definierten Stichtag

hinweg, ohne in die Unternehmen hineinzugreifen. Dieses Vorgehen ordnet sich in die Tradition von Guideline- und Policy-Analysen ein, die auch in der internationalen KI-Ethikdebatte genutzt werden, um Konvergenzen und Divergenzen von Prinzipienlandschaften zu kartieren (z. B. Jobin et al., 2019, S. 1; Fjeld et al., 2020, S. 4-6; Hagendorff, 2020, S. 1-2).

Die Analyseeinheit folgt dabei folgender Aggregationslogik: Primäre Analyseeinheit ist das Unternehmen (Company-level Scoring). Die Kodierbasis bilden Dokumente bzw. Textpassagen als Evidenzträger, die pro Unternehmen aggregiert werden. Damit wird ausdrücklich nicht die Qualität einzelner Dokumente bewertet, sondern die unternehmensweite Aussage darüber, welche Werte adressiert werden und wie verbindlich bzw. operationalisiert diese adressiert sind.

Die Gefahr, dass dokumentierte Werte primär symbolisch sind (Ethics-Washing bzw. decoupling), wird im Forschungsdesign nicht ignoriert, sondern als methodische Herausforderung antizipiert. Wertepräsenz soll deswegen nicht als gleichbedeutend mit wirksamer Umsetzung behandelt werden, sondern es gilt, die Operationalisierungstiefe separat zu messen. Dies entspricht der Literaturkritik, wonach Prinzipiendokumente häufig an Durchsetzung, Übersetzungstools und Accountability-Mechanismen fehlen und dadurch realweltliche Wirksamkeit begrenzt bleibt (Hagendorff, 2020, S. 6-8; Morley et al., 2020, S. 13-17; Bietti, 2021, S. 12-14).

Im Rahmen der vorliegenden Masterarbeit werden KI-gestützte Systeme in unterstützender Funktion eingesetzt. Die Nutzung umfasst insbesondere Brainstorming, Strukturierung von Arbeits- und Kapitelentwürfen, sprachliche Überarbeitung, die Aufbereitung von Literaturhinweisen sowie die methodische und formale Unterstützung einzelner empirischer Arbeitsschritte. Sämtliche verwendeten Quellen, Fakten, Kodierentscheidungen, Berechnungsschritte, Ergebnisse und Schlussfolgerungen werden vom Verfasser eigenständig anhand der Originalquellen bzw. der zugrunde liegenden Dokumente geprüft, validiert, ausgewählt und verantwortet. KI-generierte Inhalte werden weder ungeprüft übernommen noch als wissenschaftliche Quellen verwendet. Eine ausführlichere Dokumentation des unterstützenden KI-Einsatzes findet sich in Anhang A39.

3.2 Quellenkorpus: Einschluss und Ausschluss

Die Grundgesamtheit der Untersuchung umfasst die DAX-40-Unternehmen (Indexstand zum Erhebungsstichtag 04. Januar 2026). Alle Sampling- und Erhebungsentscheidungen beziehen sich auf diesen Stichtag; nachgelagerte Dokumentupdates werden in der Methode als potenzielle Verzerrungsquelle behandelt und durch eine Freeze- und Archivierungslogik mitigiert (siehe Abschnitt 3.3).

Als Untersuchungsmaterial werden öffentlich zugängliche Dokumente bzw. Textpassagen in öffentlich zugänglichen Dokumenten herangezogen, die normative Aussagen zur Entwicklung, zum Einsatz oder zur Governance von KI enthalten. Nach folgenden Dokumententypen wird in der initialen Recherche unterschieden: (1) eigenständige KI-Richtlinien, AI-Principles oder AI Ethics Policies; (2) Responsible-AI-Seiten bzw. KI-Ethikunterseiten auf offiziellen Unternehmenswebsites; (3) einschlägige Passagen in Corporate Policies und Codes (z. B. Code of Conduct), sofern ein expliziter KI-Bezug hergestellt wird; sowie (4) einschlägige Passagen in ESG-/Nachhaltigkeitsberichten oder vergleichbaren Governance-Dokumenten, sofern KI-bezogene Normen oder Mechanismen beschrieben werden.

Die Sprache der Dokumente ist Deutsch und/oder Englisch; andere Sprachen werden nicht einbezogen. Für bilinguale Artefakte (z. B. deutsch/englisch parallel) wird jeweils die Version herangezogen, die die höchste inhaltliche Dichte in Bezug auf normative Substanz aufweist; im Dokumentenlog (vgl. Anhang A2) wird die verwendete Sprachversion dokumentiert.

Die Auswahlstrategie verfolgt keine Vollerhebung aller potenziell relevanten Dokumente je Unternehmen, sondern eine fokussierte Dokumentpriorisierung: Pro Unternehmen werden für die Werterfassung 1-3 ‚stärkste' Dokumente ausgewählt und kodiert. ‚Stärke' ist hierbei subjektiv als inhaltliche Substanz definiert, d. h. Dokumente mit konkreten Normen, Mechanismen und Governance-Bausteinen (Rollen, Prozesse, Checks, Audit- oder Reportingelemente) werden gegenüber rein allgemeinen Leitbildformulierungen priorisiert. Diese Strategie begründet sich pragmatisch mit der Zielsetzung eines Company-level-Scores: Gemessen werden soll, ob ein Unternehmen Werte adressiert und wie verbindlich bzw. governance-nah diese adressiert sind; und eben nicht, wie viele Textartefakte überhaupt existieren. Die Priorisierung reduziert zugleich das Risiko, dass ein Unternehmen mit vielen, aber redundanten PR-Texten künstlich mehr Evidenz erzeugt.

Die Inklusions- und Exklusionslogik folgt einer klar strukturierten Operationalisierung: Ein Dokument bzw. Abschnitt gilt als ‚kodierfähig', wenn mindestens eines der folgenden Kriterien erfüllt ist: (a) deontische Sprache mit Regel- oder Pflichtcharakter (z. B. ‚must/shall/required' bzw. ‚muss/verpflichtend'), (b) Beschreibung von Governance-Mechanik (z. B. Rollen, Prozesse, Tools/Checks, Audits, Trainings, Eskalationswege, Reporting) oder (c) semantisch gehaltvolle Werteformulierung, in der Werte definiert bzw. konkretisiert werden (nicht nur Schlagwortlisten). Abschnitte werden hingegen als nicht ausreichend eingestuft, wenn sie ausschließlich Image- bzw. Marketingsprache verwenden (‚innovativ', ‚vertrauenswürdig') ohne (normative) KI-spezifische Konkretisierung oder ohne Erklärung, wie diese Eigenschaften erreicht werden sollen.

Diese Abgrenzung ist methodisch aus der Kritik an symbolischer Selbstregulierung abgeleitet. In der KI-Ethikdiskussion wird wiederholt problematisiert, dass Ethikvokabular strategisch

eingesetzt werden kann, um Regulierung abzuwehren oder Glaubwürdigkeit zu signalisieren, ohne belastbare Implementierungsmechanismen offenzulegen (Bietti, 2021, S. 1-3; Hagendorff, 2020, S. 1-2). Analog dazu zeigen empirische Arbeiten zur Nachhaltigkeitsberichterstattung, dass Unternehmen negative Ereignisse häufig selektiv, vage oder vermeidend berichten, was als Form von decoupling gelesen werden kann (Roszkowska-Menkes et al., 2024, S. 18). Diese Befundlage legitimiert es, die Einschlusskriterien nicht an der bloßen Existenz ethischer Buzzwords auszurichten, sondern an Evidenzmerkmalen von Normativität und Governance.

Regulatorische Anker fungieren in der Methode nicht als Ergebnismaßstab (Compliance-Check), sondern als Referenzrahmen dafür, welche Governance-Bausteine in einer fortgeschrittenen KI-Governance grundsätzlich erwartbar sind. Insbesondere der EU AI Act beschreibt für Hochrisiko-KI u. a. Anforderungen an ein Risikomanagementsystem, an Daten- und Risikogovernance sowie an Impact- und Dokumentationspflichten, die im Codebuch als Indikatorraum für Governance-Tiefe herangezogen werden können (EU, 2024, S. 19-20, 27-29, 60-63, 69-70, 101-102).

‚No findings' werden nicht als Missing Data kaschiert, sondern als analytisch relevante Beobachtung dokumentiert: Kann für ein Unternehmen im Rahmen der definierten Such- und Einschlusslogik kein kodierfähiges Dokument gefunden werden, wird dies im Dokumentenlog sinngemäß als ‚keine öffentlich auffindbare normative KI-Richtlinie zum Stichtag' festgehalten und in der Datengrundlage als Null-Evidenz behandelt (Score 0 in den jeweiligen Dimensionen, sofern keine Textbasis existiert). Damit bleibt die Erhebung auditierbar und vermeidet einen Selektionsbias durch stillschweigende Exklusion dokumentarisch ‚leiser' Unternehmen.

3.3 Datenerhebung und Dokumentenlog

Die Datenerhebung folgt dem Prinzip der Replikations- und Nachvollziehbarkeitslogik: Jeder Kodier- und Scorewert muss auf eine konkrete Textstelle in einem konkreten Dokument zurückführbar sein. Dies schafft einen ‚Audit Trail' analog zu Ansätzen aus Assessment- und Impact-Assessment-Literatur, die Artefakte, Checklisten und Scoring als transparente Nachweissysteme strukturieren (Stahl et al., 2023, S. 5-7).

Die Dokumentrecherche ist als systematischer Web- und Dokumentensuchprozess innerhalb offizieller Unternehmenskanäle konzipiert. Konkret werden pro Unternehmen mindestens folgende Bereiche geprüft: (a) Corporate-/Unternehmenswebsite (Bereiche wie ‚Responsible AI', ‚Digital Ethics', ‚Innovation/AI', ‚Compliance/Ethics', ‚Sustainability/ESG'), (b) veröffentlichte Policies und Codes (z. B. Code of Conduct, Supplier Code, Data/Privacy Policies) sowie (c) Nachhaltigkeits-, Jahres bzw. ESG-Berichte, sofern sie KI-bezogene

Governance enthalten. Ergänzend kann eine interne Seitensuche der Unternehmensdomain mit standardisierten Suchbegriffen (z. B. ‚AI-principles‘, ‚KI-Richtlinie‘, ‚algorithmic‘, ‚ethics‘, ‚governance‘, ‚transparency‘) eingesetzt werden; die verwendeten Suchbegriffe werden für die Replikation in einem Suchlog dokumentiert.

Für jedes gefundene Dokument wird ein Eintrag im zentralen Dokumentenlog getätigt, der als primäres Ergebnisartefakt der Suche dient. Dabei umfasst der Dokumentenlog mindestens: Dokumenttitel, veröffentlichendes Unternehmen, Erfassungsdatum, URL, Sprache sowie zusätzlich Dokumenttyp und eine Inklusion/Exklusion-Einschätzung. Diese Felder sind so gewählt, dass (a) die Quellenlage auditierbar ist (welches Dokument von welcher Stelle), (b) Entscheidungen der Dokumentpriorisierung begründbar sind (warum dieses Dokument gegenüber anderen als ‘stärkstes’ gewählt wurde) und (c) Veränderungen der Quellenlage nachvollzogen werden können (z. B. wenn Richtlinien nach dem Stichtag aktualisiert werden).

Um Replizierbarkeit auch bei dynamischen Webinhalten herzustellen, folgt die Erhebung einer Freeze- und Archivierungslogik: Der Stichtag definiert den eingefrorenen Datenstand; alle zum Stichtag herangezogenen Dokumente werden lokal archiviert (z. B. als PDF-Export oder gespeicherte HTML-Version) und über eine konsistente Dateinamenkonvention referenziert (z. B. Unternehmens-ID_Dokumentname_Abrufdatum). Eine solche Freeze-Regel soll idealerweise verhindern, dass Kodierentscheidungen durch nachträgliche Dokumentupdates oder ‚leise‘ Textänderungen instabil werden.

Die Erhebung berücksichtigt zudem das Problem, dass Unternehmen Dokumente über mehrere Ebenen verteilen können (eigene AI-Principles, ESG-Passagen, Compliance-Richtlinien). Eine unternehmensweite Aggregationslogik soll genau dies adressieren: Wenn mehrere Dokumente pro Unternehmen existieren, wird pro Wert bzw. Governance-Kriterium jeweils der höchste evidenzbasierte Grad über alle berücksichtigten Dokumente herangezogen (Maximalprinzip). Die Dokumentenlogik muss bei der Werteerfassung daher nicht nur ‚Dokument A existiert‘, sondern auch ‚Dokument A trägt Evidenz für Wert X‘ bereitstellen.

3.4 Codebuch

Das Codebuch ist das zentrale Instrument zur Sicherstellung von Messvalidität, Vergleichbarkeit und Auditierbarkeit. Es operationalisiert die in Kapitel 2 hergeleiteten Konstrukte so, dass Textstellen aus Unternehmensdokumenten konsistent auf Werte- und Governance-Codes abgebildet werden können. Eine zweigeteilte Architektur soll dem gerecht werden: (1) eine Wertetaxonomie (VAL_01-VAL_18) zur Erfassung normativer Werte/Prinzipien und (2) eine Governance-Rubrik (GOV_01-GOV_07) zur Erfassung der Operationalisierungstiefe.

3.4.1 Entwicklung und theoretische Anker des Codebuchs

Die Wertetaxonomie wird deduktiv aus international etablierten Referenzrahmen abgeleitet und durch empirische Konsenskartierungen als Synonym- und Clusterbasis plausibilisiert. Als definitorische Primäranker dienen insbesondere (a) die EU HLEG *Ethics Guidelines for Trustworthy AI* mit ihrer Trias und den sieben Anforderungen (u. a. human agency and oversight, transparency, accountability) (EU HLEG, 2019, S. 2-5), (b) die OECD *Recommendation on AI* mit fünf Prinzipien für verantwortungsvolle Steuerung vertrauenswürdiger KI (OECD, 2019, S. 7-9) sowie (c) die UNESCO *Recommendation on the Ethics of Artificial Intelligence* mit einem expliziten Kapitel zu „Values and principles“ und daran anschließenden Policy-Action-Bereichen (UNESCO, 2021, S. 18-20).

Als empirische Plausibilisierung werden Meta- bzw. Mapping-Studien herangezogen, die wiederkehrende Wertecluster in KI-Ethikleitlinien dokumentieren: Jobin et al. (2019) berichten eine globale Konvergenz um fünf Prinzipien (u. a. Transparenz; Gerechtigkeit/Fairness; Non-maleficence; Responsibility; Privacy), zugleich aber erhebliche Divergenz in Interpretation und Implementierung (S. 3-7). Fjeld et al. (2020) kartieren thematische Cluster in rights- und ethics-basierten KI-Prinzipiendokumenten und bieten dadurch eine strukturierende Grundlage für Synonyme und Themenfamilien (S. 4-6). Ergänzend dokumentiert Corrêa et al. (2023) in einer breiten Review-Perspektive wiederkehrende Prinzipien und stellt damit weiteres Vergleichsmaterial zur Plausibilisierung von Wertelisten bereit (S. 6-8).

Die Governance-Rubrik ist konzeptionell an der Literatur zu AI-Governance als Organisations- und Prozesssystem ausgerichtet. Birkstedt et al. (2023) schlagen, vor dem Hintergrund fragmentierter Begriffsverwendung, eine Arbeitsdefinition vor, nach der AI-Governance als System von Regeln, Praktiken und Prozessen verstanden werden kann, das sicherstellt, dass der KI-Einsatz mit Strategie, Zielen, Werten, rechtlichen Anforderungen, ethischen Prinzipien und Stakeholder-Erwartungen kompatibel ist (S. 25-26). Diese Definition ist für die Operationalisierung leitend, weil sie Governance explizit als Systemarchitektur und nicht als reines Ethikstatement versteht.

3.4.2 Aufbau des Codebuchs und Codefamilien

Die Wertetaxonomie umfasst 18 Codes, die samt Abgrenzungs- und Grenzfalllogik als Freeze-Basis in Tab. 3-1 dokumentiert sind:

VAL_ID	**Bezeichnung**	**Kurzdefinition**
VAL_01	Human Agency & Oversight	Menschen behalten Kontrolle/ Überwachung über KI

VAL_02	Accountability & Responsibility	Menschliche Zuständigkeit/ Verantwortung für KI-Entscheidungen bzw. deren Outcomes
VAL_03	Transparency	Nachvollziehbarkeit über Einsatz, Zweck und Entscheidungslogik von KI-Systemen
VAL_04	Explainability	Erklärbarkeit von KI-Entscheidungen bzw. deren Outputs
VAL_05	Fairness & Non-Discrimination	Vermeidung unfairer Benachteiligung und Bias
VAL_06	Privacy & Data Protection	Schutz personenbezogener Daten/ Datensparsamkeit
VAL_07	Security & Cybersecurity	Schutz vor Angriffen, Manipulation, Leakage
VAL_08	Safety & Harm Prevention	Vermeidung von Schäden (physisch, psychisch, sozial)
VAL_09	Robustness & Reliability	Technische Zuverlässigkeit, Stabilität und Fehlerresistenz
VAL_10	Contestability & Redress	Anfechtbarkeit, Beschwerde, Widergutmachung von KI-Entscheidungen bzw. deren Outcomes
VAL_11	Inclusiveness & Accessibility	Einbezug, Barrierefreiheit und Teilhabe von KI-Systemen
VAL_12	Sustainability & Environmental Well-being	Ökologische Verantwortung bzw. Fußabdruck (Energy, CO2) von KI-Systemen
VAL_13	Social Benefit & Human Well-being	KI soll gesellschaftlichen Nutzen stiften
VAL_14	Lawfulness & Compliance	Rechtskonformität (inkl. Regulierung)

VAL_15	Ethical Use & Integrity	Moralische Integrität, ethische Grenzen für KI werden eingehalten
VAL_16	Data Quality & Governance	Datenqualität. Herkunft, Stewardship
VAL_17	IP & Confidentiality	Schutz geistigen Eigentums, Vertraulichkeit bei KI-Systemen
VAL_18	Human Rights	Einbezug von Menschenrechten als regulatorischer oder ethischer Anker

Tab. 3-1: Wertekatalog, eigene Darstellung

Für mehrere Codes sind Boundary Rules als explizite Trennschärfe vorgesehen (z. B. VAL_03 Transparency vs. VAL_04 Explainability; VAL_02 Accountability als Wert vs. GOV_01 Zuständigkeiten als Governance-Mechanismus; VAL_10 Contestability & Redress als Anspruch vs. GOV_06 Eskalationswege als Prozessmechanik).

Die Governance-Rubrik umfasst sieben Kriterien auf einer ordinalen Rubrik von 0 bis 3 (0 = nicht vorhanden; 1 = benannt; 2 = dokumentiert; 3 = implementiert & nachweisbar). Die sieben Kriterien werden in Tab. 3-2 dargestellt. Die Güteannahme dahinter ist, dass Governance-Tiefe nicht durch die rhetorische Intensität eines Ethikstatements entsteht, sondern durch Rollen- und Verantwortlichkeitszuordnung, Prozessroutinen, Prüfmechanismen, Lern- und Eskalationsstrukturen sowie regelmäßige Berichtswege; also durch organisatorische Mittel zur Durchsetzung bzw. Implementierung.

GOV_ID	**Bezeichnung**	**Minimale Evidenz**
GOV_01	Zuständigkeiten	Rollentitel + klarer Bezug zu KI-Governance
GOV_02	Prozesse	Mind. ein Prozessschritt + Trigger + Verantwortliche
GOV_03	Tools/Checks	Name des Tools ODER klar benannter Checktyp/Assessment + Prüfgegenstand + wann/wofür eingesetzt

GOV_04	Audits	Auditart + Frequenz oder Verantwortliche
GOV_05	Schulungen	Mind. Zielgruppe + Pflicht/ Regelmäßigkeit
GOV_06	Eskalationswege	Stufenlogik oder Mechanik (Ticket, Hotline, Committee)
GOV_07	Incident-Reporting	KPI/ Reportgegenstand + Empfänger + Frequenz

Tab. 3-2: Governancerubriken, eigene Darstellung

3.4.3 Kodierregeln und Evidenzlogik

Zentral ist eine KI-Bezugsregel: Ein Wert wird nur dann gezählt, wenn der KI-Kontext erkennbar ist (z. B. explizit ‚AI', ‚KI', ‚algorithmic systems', ‚machine learning' oder ‚foundation models'). Allgemeine Unternehmenswerte ohne KI-Anker werden nicht kodiert, um eine künstliche Werteübererfassung insbesondere aus allgemeinen ESG- oder Complianceberichten zu vermeiden. Diese Regel ist eine direkte Bias-Mitigation gegen ‚Value Inflation' durch generische Corporate-Value-Kommunikation.

Eine Verbindlichkeitsrubrik (Bindigkeitsgewicht) soll zudem die reine Präsenz eines Werts um eine Intensitätsdimension ergänzen. Hintergrund ist, dass Wertebezüge in Dokumenten graduell vorhanden sein können: von unverbindlichen Selbstbekundungen bis zu prozessualen Standards mit Kontrolllogik. Die Verbindlichkeitsrubrik ist wie in Tab. 3-3 dargestellt operationalisiert.

BIND_ID	**Bezeichnung**	**Regel**
BIND_1	Statement/Prinzip	umfasst Selbstbekundungen (‚We commit to…', ‚Wir bekennen uns…') ohne Pflicht- oder Mechanikcharakter.
BIND_2	Policy-Regel	umfasst klare Verhaltensnormen mit Pflichtsignal (‚must/shall', ‚müssen', ‚verpflichtend', ‚required')
BIND_3	Standard/ Prozessvorgabe	umfasst konkrete Prozess- oder Standardvorgaben (z. B. Freigabeprozesse, Auditpflichten, Gate-Reviews)

Tab. 3-3: Bindigkeitsgewichte, eigene Darstellung

Für die Aggregation gilt pro Unternehmen und Wert ein Maximalprinzip: Wenn mehrere Textstellen unterschiedliche Bindigkeitsgrade nahelegen, wird der höchste nachweisbare Grad verwendet.

Für die Governance-Rubrik wird eine strenge Evidenzschwelle definiert: Score 0 bedeutet: keinerlei Hinweis. Score 1 bedeutet: Benennung als Absicht ohne konkrete Rollen/Prozesse/Tools. Score 2 bedeutet: Dokumentation, d. h. Rollen sind benannt oder Prozesse/Tools werden so beschrieben, dass ein Ablauf erkennbar wird. Score 3 bedeutet: Implementierung mit Nachweis- bzw. Outputbezug (z. B. regelmäßige Review-Zyklen, geübte Eskalationsmechanik, Reportingartefakte). Für jeden Governance-Score ist eine Belegpflicht vorgesehen: Dokument-ID, Abschnitt/Seite und eine kurze Evidenznotiz werden systematisch erfasst.

3.4.4 Pilotierung, Freeze-Logik und Umgang mit Grenzfällen

Um Regeln zu schärfen und Grenzfälle strukturiert zu behandeln, ist ein Pilot-Coding-Prozess vorgesehen mit Umfang von 8 Unternehmen (20% der Grundgesamtheit), bewusst branchenheterogen gewählt, um typische Mehrdeutigkeiten sichtbar zu machen. Der Pilot folgt einer sequenziellen Logik: Zunächst wird ein Codebook-Freeze (‚V0') mit Datum/Version hergestellt. Danach wird pro Pilot-Unternehmen (subjektiv) ein Dokument als Stichprobe ausgewählt und in einer ersten Runde strikt nach Codebuch kodiert (‚Blind Coding' im Sinne: keine spontanen Neuregeln während des Kodierens). Unsicherheiten werden als Grenzfälle geloggt und erst nach Abschluss der Pilotierung in Regeln übersetzt. Änderungen werden im Change-Log dokumentiert (inkl. Angabe, ob ein Re-Coding erforderlich ist), anschließend wird ein Mini-Re-Coding von zwei Pilot-Unternehmen durchgeführt, um die Stabilität der neuen Regeln zu prüfen. Erst wenn Grenzfälle selten werden und die Kodierung konsistent möglich ist, wird das Codebuch für die Vollkodierung gelockt (‚vFinal for Full Coding').

Diese formalisierte Pilotlogik adressiert eine in der KI-Ethikliteratur wiederkehrende Herausforderung: Viele Begriffe sind „essentially contested", und Labels können scheinbar konvergieren, obwohl Interpretationen und Umsetzungsvorstellungen divergieren (Jobin et al., 2019, S. 17-20). Die Freeze- und Grenzfalllogik soll verhindern, dass diese Ambiguitäten in nicht nachvollziehbare ‚Bauchgefühlscodes' übersetzt werden.

Dimension	**Kodierobjekt**	**Zentrale Regel**	**Evidenzanforderung**	**Grenzfälle/ Konfliktlösung**
Werte (VAL_01-VAL_18)	Textpassage mit explizitem KI-Bezug	Wert zählt nur bei erkennbarem KI-Kontext; Synonyme erlaubt, aber	Dokument-ID + Abschnitt/Seite +	Grenzfall-Register; Regeln werden nach Coding-Runde übersetzt

		Abgrenzungsregeln beachten (z. B. Transparency vs Explainability)	Evidenznotiz; optional kurze Textreferenz	und versioniert (Freeze → Schärfung → Lock)
Bindigkeit (BIND_1-BIND_3)	Werttragende Passage	Höchster nachweisbarer Bindigkeitsgrad pro Wert und Unternehmen (Maximalprinzip)	Deontische Marker/Standardvorgaben im Text; eindeutige Textstelle	Bei gemischten Signalen gilt: höchste belastbar belegte Stufe; unklare Fälle ins Grenzfall-Register
Governance (GOV_01-GOV_07)	Governance-bezogene Passage	0 = nicht vorhanden; 1 = benannt; 2 = dokumentiert; 3 = implementiert & nachweisbar	Belegpflicht: Dokument-ID + Abschnitt/Seite + Evidenznotiz (kein Score ohne Textstelle)	Konflikte durch Evidenzhierarchie lösen: ‚evidence-first', offene Fragen loggen, Regeln nachziehen

Tab. 3-4: Coding-Protokoll (Kernregeln und Evidenzanforderungen für alle Protokollelemente), eigene Darstellung

3.5 Konvergenz-Index und Operationalisierungs-Index

Die quantifizierende Auswertung basiert auf zwei Indizes, die direkt aus dem kodierten Datensatz abgeleitet werden. Ziel ist eine transparente, replizierbare Verdichtung der qualitativen Befunde, ohne die Trennung von Wertedimension und Governance-Dimension zu verlieren. Während nachfolgend die Messlogik dokumentiert wird, folgen die Ergebnisdarstellung und Interpretation erst in den Folgekapiteln.

3.5.1 Konvergenz-Index für Werte (Unternehmensscore 0-1)

Für jedes Unternehmen wird pro Wert VAL_i, $i \in \{1,2,\ldots,18\}$, zunächst die Präsenz erhoben (0 = nicht vorhanden; 1 = vorhanden). Liegt eine Präsenz vor, wird zusätzlich das Bindigkeitsgewicht $BIND_j \in \{1,2,3\}$, bestimmt. Die Punkte pro Wert ergeben sich als:

$$Punkte(VAL_i) = Präsenz(VAL_i) \times BIND_j$$

Die Rohpunktzahl eines Unternehmens ist die Summe über alle Werte:

$$Werte_Rohpunkte = \Sigma\ Punkte(VAL_i) \text{ für } i = 1\ldots18$$

Die maximal erreichbaren Punkte ergeben sich aus der Anzahl der Werte multipliziert mit dem Maximalgewicht 3:

$$Werte_Maxpunkte = 18 \times 3 = 54$$

Der Konvergenz-Index auf Unternehmensebene ist die Normalisierung:

Konvergenz_Index (0-1) = Werte_Rohpunkte / Werte_Maxpunkte

Diese Logik zielt darauf, sowohl Werteabdeckung als auch Verbindlichkeit zu erfassen.

3.5.2 Konvergenz zwischen Unternehmen (Set-Ähnlichkeit)

Um die Konvergenz von Werte-Sets zwischen Unternehmen vergleichend zu quantifizieren, wird mittels Jaccard-Ähnlichkeit eine paarweise Set-Ähnlichkeit berechnet. Dafür wird pro Unternehmen das Set der vorhandenen Werte gebildet, d. h. A = {VAL_i | Präsenz=1}. Die Jaccard-Ähnlichkeit zweier Unternehmen A und B lautet:

$J(A,B) = |A \cap B| / |A \cup B|$

Damit wird gemessen, wie groß der Anteil geteilter Werte an der Gesamtmenge der von mindestens einem der beiden Unternehmen adressierten Werte ist (Fletcher & Islam, 2018, S. 4-6). Die Methode wird in dieser Arbeit primär für (a) die Visualisierung als Ähnlichkeitsmatrix/Heatmap und (b) als Distanzgrundlage für Clusteranalysen genutzt (Distanz = 1 - J).

3.5.3 Operationalisierungs-Index für Governance-Tiefe (0-100)

Die Governance-Tiefe wird entlang der sieben Governance-Kriterien GOV_01-GOV_07 erfasst. Jedes Kriterium erhält einen Score zwischen 0 und 3 (0 = nicht vorhanden; 3 = implementiert & nachweisbar). Die Rohpunktzahl ergibt sich als Summe aller Kriterien:

$\text{Governance_Rohpunkte} = \Sigma\ \text{Score}(\text{GOV_k})$ für $k = 1 \ldots 7$

Der Maximalwert ist damit $7 \times 3 = 21$. Der normalisierte Index lautet:

$\text{Governance_Index (0-100)} = (\text{Governance_Rohpunkte} / 21) \times 100$

Die Indexlogik ist kompatibel mit der EU-HLEG-Logik, Governance über Anforderungen und Assessment-Fragen zu strukturieren (EU HLEG, 2019, S. 22-25), und mit dem Governance-Verständnis als Prozess- und Artefaktsystem (Birkstedt et al., 2023, S. 1-2). Sie ist zudem anschlussfähig an regulatorische Anforderungen, die explizite Prozess- und Kontrollsysteme verlangen (z. B. Risikomanagementsysteme und Impact-Assessments im EU AI Act) (EU, 2024, S. 19-20).

3.5.4 Sensitivitätsanalyse der Indexgewichte

Da jede Indexbildung normative Gewichtungsentscheidungen enthält, wird ebenfalls eine Sensitivitätsanalyse durchgeführt. Konkret wird geprüft, wie stabil die Befunde gegenüber alternativen Gewichtungsannahmen sind. Beispielsweise könnten in der Governance-Tiefe Audits (GOV_04) und Incident-Reporting (GOV_07) höher gewichtet werden, da diese

Kriterien häufig als besonders relevante Accountability- und Durchsetzungsmechanismen interpretiert werden. Die Sensitivitätsanalyse wird als Robustheitscheck umgesetzt: Es werden alternative Governance-Indizes mit modifizierten Gewichten berechnet und anschließend Rangfolgen, Clusterungen und Zusammenhangsmaße mit dem Basismodell verglichen. Auf Werteebene kann ebenfalls geprüft werden, wie stark sich Ergebnisse ändern, wenn Bindigkeitsgewichte unterschiedlich skaliert werden (z. B. eine flachere Gewichtung 1/1/2 statt 1/2/3), wobei trotzdem die 1/2/3-Logik als Primärannahme fixiert bleibt. (Konkrete Sensitivitätsparameter sind Verfahrensentscheidungen dieser Arbeit; die Notwendigkeit der Sensitivität ist deshalb auch fest verankert.)

Konstrukt	**Operationale Einheit**	**Skala**	**Kernschritte der Berechnung**	**Output**
Wertepräsenz	Unternehmen × Wert (VAL_i)	0/1	KI-Bezug prüfen; Wert nach Definition/Rules kodieren	Präsenzmatrix (40×18)
Bindigkeit	Unternehmen × Wert (VAL_i)	1/2/3	BIND_1 Statement; BIND_2 Policy-Regel; BIND_3 Standard/Prozessvorgabe; Maximalprinzip	gewichtete Wertepunkte
Konvergenz-Index (Unternehmen)	Unternehmen	0-1	Σ(Präsenz×Bindigkeit) / 54	Index je Unternehmen
Jaccard-Ähnlichkeit (paarweise)	Unternehmen × Unternehmen	0-1	$J(A,B) = \lvert A \cap B \rvert / \lvert A \cup B \rvert$	J(A,B)
Governance-Rubrik	Unternehmen × Kriterium (GOV_k)	0-3	0 nicht vorhanden; 1 benannt; 2 dokumentiert; 3 implementiert & nachweisbar; Evidenzpflicht	Governanceprofil (7 Scores)
Governance-Index	Unternehmen	0-100	(Σ GOV_k / 21) × 100	Index je Unternehmen
Sensitivität	Unternehmen	abhängig	alternative Gewichte (z. B. Gov-Kriterien) und Vergleich der Outputs	Robustheitsurteil

Tab. 3-2: Übersicht Rubriken und Indizes (Skalen und Berechnung), eigene Darstellung

3.6 Reliabilität, Validität und Bias-Mitigation

Methodische Glaubwürdigkeit kann bei dieser Arbeit keinesfalls über ‚Pseudo-Genauigkeit' (scheinpräzise Kennzahlen ohne belastbaren Prozess) herzustellen sein, sondern muss über transparente Regeln, Evidenzpflicht und nachvollziehbare Konsistenzchecks systematisch erschlossen werden. Entsprechend werden Gütekriterien entlang von Reliabilität, Validität und Bias-Mitigation operationalisiert.

3.6.1 Reliabilität: Konsistenz der Kodierung

Da die vorliegende Untersuchung auf öffentlich zugänglichen Unternehmensdokumenten basiert und als regelgeleiteter Einzelcoderprozess angelegt ist, wurde auf eine formale Intercoder-Reliabilitätsmessung bewusst verzichtet. Dies ist hier vertretbar, weil der zentrale Qualitätsanspruch nicht in der Simulation statistischer Exaktheit bei begrenzter Fall- und Materiallogik liegt, sondern in der maximalen Transparenz und Prüfbarkeit des Kodierprozesses. Als Mindeststandard wird dagegen Intracoder-Stabilität abgesichert. Die Reliabilitätsabsicherung erfolgt dafür prozessual: Erstens wurden die Kodierregeln in einer branchenheterogenen Pilotphase an acht Unternehmen geschärft, um typische Mehrdeutigkeiten und Grenzfälle systematisch sichtbar zu machen. Zweitens wurden Regeländerungen nicht ad hoc vorgenommen, sondern über Freeze-, Change-Log- und Lock-Mechanismen versioniert dokumentiert. Drittens wurde nach relevanten Regelupdates ein gezieltes Mini-Re-Coding von zwei Pilotunternehmen durchgeführt, um die Stabilität der geschärften Regeln zu prüfen. Viertens stellt der Audit Trail über Entscheidungsprotokoll, Grenzfallregister sowie die Evidenzpflicht mit Dokument-ID, Abschnitt bzw. Seite und Evidenznotiz sicher, dass jede Kodierentscheidung nachvollziehbar und im Zweifel revidierbar bleibt. Die methodische Belastbarkeit dieser Arbeit beruht damit nicht primär auf Personenübereinstimmung, sondern auf der systematischen Stabilisierung, Offenlegung und Rückprüfbarkeit des Kodierverfahrens. Dadurch entsteht eine prozessuale Reliabilität: Nicht die Person wird messbar zuverlässig, sondern der Kodierprozess wird als überprüfbares System stabilisiert.

3.6.2 Validität: Konstrukt-, Inhalts- und Transparenzvalidität

Die Konstruktvalidität wird dadurch adressiert, dass die Konstrukte ‚Werte-Konvergenz' und ‚Governance-Tiefe' in der Methode getrennt operationalisiert werden. Die Trennung folgt der in Kapitel 2 angelegten Ebenenlogik und der Literaturkritik, dass Prinzipienlabels häufig nicht in Implementierungsmechanismen übersetzt werden (siehe u.a. Morley et al., 2020, S. 13-17; Hagendorff, 2020, S. 6-8). Entsprechend wird die Wertepräsenz (VAL) nicht als Proxy für Governance interpretiert, sondern separat gemessen (GOV).

Inhaltsvalidität wird über die Abstützung der Wertetaxonomie an etablierten internationalen Rahmenwerken und Konsenskartierungen plausibilisiert. EU HLEG, OECD und UNESCO dokumentieren jeweils umfangreiche Werte- und Prinzipienlandschaften (EU HLEG, 2019, S. 21-22; OECD, 2019, S. 7-9; UNESCO, 2021, S. 18-20), während Meta-Mappings zeigen, dass bestimmte Cluster wiederkehrend sind (Jobin et al., 2019, S. 3-7; Fjeld et al., 2020, S. 66). Damit wird begründet, dass die Taxonomie keine idiosynkratische Werteliste darstellt, sondern an international verbreitete Diskurse anschließt.

Transparenzvalidität (Traceability) wird als methodisches Kernkriterium umgesetzt: Jeder Score erhält eine konkrete Textstelle als Evidenz; ohne Textstelle kein Score (evidence-first). Diese Logik ist mit Audit- und Assessment-Perspektiven kompatibel, in denen die Nachvollziehbarkeit von Scorings über Artefakte und Dokumentationsketten als Qualitätsmerkmal gilt (z.B. Stahl et al., 2023, S. 5-9).

3.6.3 Bias-Mitigation: Selektions- und Interpretationsrisiken

Die Methode antizipiert drei zentrale Biasquellen. Erstens besteht ein Selektionsbias zugunsten kommunikationsstarker Unternehmen: Wenn nur öffentliche Dokumente betrachtet werden, können Unternehmen mit geringer Offenlegung schlechter erscheinen, unabhängig von tatsächlicher Praxis. Dies wird nicht vollständig eliminierbar, aber durch ‚No findings'-Dokumentation und transparente Einschlussregeln mitigiert.

Zweitens besteht ein PR-Bias bzw. das Risiko symbolischer Entkopplung: Dokumentierte Ethik kann strategisch eingesetzt werden (Ethics-Washing), ohne dass wirksame Governance vorliegt (Bietti, 2021, S. 1-3; Hagendorff, 2020, S. 6-8). Die Methode reagiert darauf zweifach: (a) durch die ‚PR-vs-Substanz'-Operationalisierung (deontische Sprache, Governance-Mechanik, definierte Werte) und (b) durch die separate Governance-Messung (Governance-Tiefe), die bei reiner Rhetorik nicht ‚automatisch' hoch ausfallen kann.

Drittens besteht ein Interpretationsbias durch umkämpfte Begriffe (contested concepts) und durch semantische Überlappungen (z. B. Accountability als Wert vs. Verantwortlichkeitsmechanismus). Hier setzt die Methode auf Abgrenzungsregeln, Grenzfallregister, Codebuchversionierung und Re-Coding-Schleifen. Zusätzlich reduziert die Bindigkeitsrubrik das Risiko, dass reine ‚Buzzword-Werte' als funktional gleichwertig zu konkreten Standards gewertet werden.

Schließlich wird die Gefahr eines ‚tick-box'-Charakters von Assessments reflektiert: Audit- und Assessmentregime können, wenn sie zu stark standardisiert und industriegeführt sind, Machtasymmetrien stabilisieren oder Verantwortungs-Lasten verschieben, ohne strukturelle Probleme zu adressieren (AI Now Institute, 2023, S. 3-4). Deshalb wird der Governance-Index

in der Arbeit als Transparenz- und Vergleichsinstrument genutzt, nicht als Nachweis tatsächlicher Compliance oder als Auditurteil.

3.7 Datenanalyse

Die Datenanalyse ist als mehrstufiger Plan angelegt, der zunächst deskriptive Muster sichtbar macht und darauf aufbauend Ähnlichkeits- und Zusammenhangsanalysen durchführt. Ergebnisse werden erst in Kapitel 4 berichtet; Kapitel 3 dokumentiert ausschließlich den Analyseplan.

3.7.1 Deskriptive Analysen und Visualisierung

Auf Werteebene werden zunächst Häufigkeiten und Verteilungen beschrieben: (a) Prävalenz jedes Werts über alle Unternehmen (Anteil Unternehmen mit Präsenz=1), (b) Verteilung der Bindigkeitsgrade pro Wert (z. B. wie häufig Werte als Statement vs. Policy-Regel vs. Prozessstandard auftauchen) und (c) Verteilung des Konvergenz-Index über Unternehmen. Ergänzend wird eine Werte×Unternehmen-Heatmap erstellt, die die Präsenzmatrix (40×18) visualisiert und so Muster der Werteabdeckung sichtbar macht. Die heatmapbasierte Darstellung soll explizit als Mittel dienen, um Prinzipien-Landkarten und Konvergenz visuell interpretierbar zu machen, analog zu Mapping-Studien im Feld (Jobin et al., 2019, S. 17-20; Fjeld et al., 2020, S. 14-16).

Auf Governanceebene werden (a) die sieben Kriterien als Profil je Unternehmen dargestellt (tabellarische Profile), (b) die Verteilung der Einzelkriterien (z. B. wie häufig Reporting vs. Audits genannt werden) und (c) die Verteilung des Governance-Index. Eine Governance×Unternehmen-Heatmap dient dazu, Governance-Reifeunterschiede und typische Muster (z. B. starke Prozessbeschreibung, aber schwaches Reporting) sichtbar zu machen.

3.7.2 Clusteranalysen: Profilbildung nach Werten und Governance

Eine hierarchische Clusteranalyse ist vorgesehen, um Unternehmen nach Ähnlichkeit der Werte-Konfigurationen und/oder Governance-Profile zu gruppieren. Für die Wertecluster wird die Jaccard-Ähnlichkeit als Distanzbasis genutzt (Distanz = 1 − J). Die Clusteranalyse erfolgt agglomerativ-hierarchisch; als Linkage-Kriterium wird ein Verfahren gewählt, das für Jaccard-Distanzen geeignet ist (z. B. Average Linkage). (Die Linkage-Parametrisierung ist eine methodische Detailentscheidung dieser Arbeit; die Kombination von Jaccard + Cluster ist als Kernlogik fixiert.) Die Ergebnisdarstellung erfolgt in Kapitel 4 typischerweise über Cluster-Tabellen; in der Interpretation (Kapitel 5) wird ausdrücklich vermieden, Cluster als ‚Qualitätsranking' zu deuten, sondern als Muster der dokumentierten Governance- bzw. Werteprofile.

Für Governancecluster kann alternativ direkt auf den sieben Kriterien (0-3) oder auf einem standardisierten Governanceprofil geclustert werden. Da die Kriterien ordinal sind, werden Distanz- und Skalierungsentscheidungen vorab festgelegt (Verfahrensentscheidung): die ordinale Skala wird als intervallnahe Annäherung behandelt (z. B. euklidische Distanz auf standardisierten Kriterien). Ziel ist nicht mathematische Perfektion, sondern ein robustes, transparentes Profiling, das mit Sensitivitätschecks flankiert wird.

3.7.3 Zusammenhangsanalysen: Konvergenz und Governance-Tiefe

Zur Beantwortung von RQ3 wird der Zusammenhang zwischen Konvergenz-Index (0-1) und Governance-Index (0-100) analysiert. Hierfür wird eine Spearman-Rangkorrelation genutzt, da sie robuste Aussagen über monotone Zusammenhänge erlaubt, ohne Normalverteilungsannahmen vorauszusetzen. Außerdem wird die Analyse nach Branchen-/Sektorclustern stratifiziert, um zu prüfen, ob Zusammenhangsmuster branchenspezifisch erscheinen (z. B. stärker regulierte Branchen vs. weniger regulierte). In der Interpretation wird klar zwischen statistischem Zusammenhang und Kausalität getrennt; das Design ist querschnittlich-dokumentbasiert und daher nicht kausal-inferenziell.

3.7.4 Sensitivität und Robustheit der Muster

Die in Abschnitt 3.5.4 beschriebene Sensitivitätsanalyse wird in der Auswertung konsequent eingebunden: Für alternative Gewichtungen der Governance-Kriterien werden zentrale Outputs (Rangreihen, Clusterzugehörigkeiten, Korrelationen) erneut berechnet und mit dem Basismodell verglichen. Damit kann in Kapitel 4 berichtet werden, ob Muster gewichtungsstabil sind oder ob sie wesentlich von normativen Gewichtungsannahmen abhängen. Diese Vorgehensweise ist als Robustheitsabsicherung fest vorgesehen und ist besonders relevant, weil die Literatur zu KI-Governance und Assessments eine Fragmentierung von Tools und eine teils unklare Standardisierungslage beschreibt (Stahl et al., 2023, S. 1; AI Now Institute, 2023, S. 2-3).

3.8 Limitationen der Methode

Die Methode ist bewusst als dokumentbasierte Inhaltsanalyse konzipiert. Daraus ergeben sich Limitationen, die transparent zu berücksichtigen sind. Erstens misst die Studie primär öffentlich dokumentierte Normativität und Governance-Transparenz, nicht zwingend gelebte Praxis. Damit besteht ein inhärentes Risiko, dass dokumentierte KI-Ethik/Governance von tatsächlichen Entwicklungs- und Nutzungspraxen entkoppelt ist. Die Literatur diskutiert diese Problematik sowohl im KI-Kontext als Ethics-Washing bzw. strategische Instrumentalisierung von Ethikvokabular (Bietti, 2021, S. 12-14; Hagendorff, 2020, S. 1-2) als auch in angrenzenden Feldern als Entkopplung durch selektive oder vage Offenlegung (Roszkowska-Menkes et al., 2024, S. 18). Die Arbeit kann dieses Risiko methodisch nur leicht begrenzen (durch Substanzkriterien und Governance-Index), nicht vollständig auflösen.

Zweitens variiert das Transparenzniveau zwischen Unternehmen. Selbst wenn Governance-Strukturen existieren, werden sie möglicherweise nicht öffentlich dokumentiert. ‚No findings' können daher Untertransparenz oder geringere Kommunikationsaktivität widerspiegeln. Die in der Methode verankerte Logik, ‚No findings' zu dokumentieren statt zu exkludieren, erhöht die Ehrlichkeit der Datenbasis, löst aber das Grundproblem der Public-Evidence-Beschränkung nicht.

Drittens können Sprach- und Übersetzungsfragen die Kodierung beeinflussen, weil deontische Marker, juristische Begriffe und Governancevokabular in Deutsch und Englisch unterschiedlich stark normativ klingen können. Die Methode minimiert dies über KI-Bezugsregeln, die Bindigkeitsrubrik (BIND_1-BIND_3) und die Evidenzpflicht; dennoch bleibt eine Restunsicherheit, insbesondere bei abstrakten Werten (z. B. ‚human-centered') ohne Mechanik.

Viertens enthalten die Indizes normative Gewichtungsentscheidungen: Die Wahl, Bindigkeit in 1/2/3 zu gewichten und Governance-Kriterien gleich zu behandeln, ist eine Modellannahme. Die Methode adressiert dies über Sensitivitätsanalysen, aber nicht über eine ‚objektiv richtige' Gewichtung. Daher werden die Indizes als heuristische, vergleichende Messinstrumente interpretiert, nicht als absolute Qualitätsurteile über Unternehmen.

Fünftens ist die Generalisierbarkeit eingeschränkt: Die Untersuchung bezieht sich auf DAX-40-Unternehmen zum festgelegten Stichtag. Aussagen über andere Indizes, private Unternehmen oder andere Zeitpunkte sind nur in dem Maße möglich, wie die Dokumentenlandschaft strukturell vergleichbar ist. Allerdings schafft die Stichtags- und Archivierungslogik eine hohe Replizierbarkeit: Bei identischem Stichtag, identischen Einschlussregeln, identischem Codebuch und dokumentierter Erhebung sollte eine Wiederholung der Studie zu vergleichbaren Datensätzen führen.

Zuletzt liegt eine weitere methodische Grenze darin, dass keine formale Intercoder-Reliabilität mit einer zweiten unabhängig kodierenden Person ausgewiesen wurde. Dies schränkt die Möglichkeit ein, Personenübereinstimmung im engeren statistischen Sinn nachzuweisen. Für die vorliegende Untersuchung ist dieser Verzicht jedoch vertretbar, weil sie nicht auf verdeckten Sinngehalten, sondern auf öffentlich zugänglichen Dokumenten, expliziten Kodierregeln und einer strikten evidence-first-Logik basiert. Die methodische Absicherung wurde daher bewusst auf prozessuale Nachvollziehbarkeit statt auf formale Kennzahlen konzentriert: Das Codebuch wurde in einer Pilotphase geschärft, Regelanpassungen wurden über Freeze- und Change-Logik kontrolliert dokumentiert, zentrale Grenzfälle wurden in einem Entscheidungsprotokoll festgehalten, und nach relevanten Regelupdates wurde ein gezieltes Mini-Re-Coding durchgeführt. Dadurch wird die Reliabilität nicht über die Übereinstimmung mehrerer Personen, sondern über die Stabilisierung, Offenlegung und Rückprüfbarkeit des

Kodierverfahrens abgesichert. Gleichwohl bleibt festzuhalten, dass eine zusätzliche unabhängige Zweitkodierung die methodische Robustheit weiter erhöht hätte und in Folgestudien eine sinnvolle Erweiterung darstellen würde.

4. Ergebnisse

Nachfolgend werden die empirischen Befunde dieser Masterarbeit präsentiert. Dieser Abschnitt liefert dafür eine deskriptive und datenbasierte Darstellung der Stichprobenstruktur, der Werte-Konvergenz, der Governance-Tiefe und der Zusammenhänge zwischen normativen Werten und konkreten Governance-Maßnahmen. Alle Angaben beziehen sich auf die zum Stichtag 4. Januar 2026 erhobenen Dokumente der DAX-40-Unternehmen und basieren ausschließlich auf dokumentierten Ergebnissen. Die Analysen unterscheiden zwischen der Präsenz ethischer Werte in KI-Richtlinien (Werteebene) und der Operationalisierung dieser Werte durch institutionalisierte Governance-Mechanismen (Governanceebene). Für beide Ebenen werden Indizes gebildet und deskriptive, paarweise sowie clusterbasierte Auswertungen vorgenommen.

4.1 Stichprobenbeschreibung

Die Grundgesamtheit umfasst die DAX-40-Unternehmen zum Stichtag 04.01.2026. Die Ergebnisauswertung basiert ausschließlich auf öffentlich zugänglichen Dokumenten mit KI-bezogener normativer Substanz. Berücksichtigt wurden je Unternehmen - je nach verfügbarer Evidenz - eigenständige KI-Richtlinien, Responsible-AI-Berichte sowie KI-relevante Passagen aus Codes of Conduct, Compliance-Policies oder ESG-/Nachhaltigkeitsberichten. Dokumente konnten in deutscher oder englischer Sprache vorliegen. Für jedes Unternehmen wurden ausschließlich solche Dokumente berücksichtigt, die eine erkennbare normative Substanz im Hinblick auf den Einsatz, die Entwicklung oder die Steuerung von Künstlicher Intelligenz aufweisen. Die Analyse erfolgt auf Company-Level-Basis. Das bedeutet, dass für jedes Unternehmen sämtliche einschlägigen Dokumente zusammengeführt und zu einem aggregierten Werte- und Governance-Profil verdichtet wurden. Pro Wertedimension sowie pro Governance-Kriterium wurde jeweils der höchste evidenzbasierte Kodierungsgrad berücksichtigt, sofern mehrere Dokumente desselben Unternehmens entsprechende Aussagen enthielten. Die Ergebnisse bilden somit die maximal erreichte Ausprägung je Kategorie auf Unternehmensebene ab.

Für die Werteebene wurden 18 Wertedimensionen (VAL_01 bis VAL_18) ausgewertet. Ein Wert zählt nur dann als kodiert, wenn ein expliziter KI-Bezug vorliegt (KI-Anker-Regel). Zusätzlich wurde die Bindigkeit der Werteerwähnung in drei Gewichtungsstufen erfasst (BIND_1 = Statement/Prinzip, BIND_2 = Policy-Regel, BIND_3 = Standard-/Prozessvorgabe). Für die Governanceebene wurden sieben Kriterien (GOV_01 bis GOV_07) systematisch

kodiert und auf einer vierstufigen Rubrik bewertet (0 = nicht vorhanden, 1 = benannt, 2 = dokumentiert, 3 = implementiert und nachweisbar). Auf beiden Ebenen gilt das Maximalprinzip: Pro Wert bzw. Kriterium zählt je Unternehmen die höchste evidenzbasiert belegbare Ausprägung innerhalb des berücksichtigten Dokumentensets.

Im Datensatz zeigen sich zwei unterschiedliche Formen von Abdeckung, die für die folgenden Ergebnisabschnitte relevant sind. Erstens existiert auf Werteebene eine substanzielle Zahl leerer Value-Sets: Für 14 der 40 Unternehmen konnte im Rahmen der definierten Einschlusslogik kein KI-bezogener Wert auf Company-Level kodiert werden; in der Logik der Arbeit handelt es sich dabei nicht um Missing Data, sondern um dokumentierte Null-Evidenz. Zweitens ist die Governanceebene als Rubrik grundsätzlich für alle 40 Unternehmen auswertbar, da das Nicht-Vorhandensein eines Mechanismus als Score 0 abgebildet wird; die empirische Streuung ergibt sich somit aus der Spannweite zwischen Absenz, Benennung, dokumentierter Mechanik und nachweisbarer Implementierung.

Zur deskriptiven Kontextualisierung wurden die Unternehmen sektoralen Clustern zugeordnet. Die Verteilung über die 40 Unternehmen hinweg stellt sich wie folgt dar:

- Consumer (n = 5)
- Finance (n = 6)
- Industrie (n = 12)
- Materials/Chemicals (n = 6)
- Tech (n = 7)
- Utilities (n = 3)
- Other/Hybrid (n = 1)

Diese sektorale Struktur dient ausschließlich der deskriptiven Einordnung und bildet die Grundlage für die in Abschnitt 4.3 dargestellten Branchenkennzahlen.

Die vollständige Stichprobenliste einschließlich Unternehmens-IDs, Sektorzuordnung und Sampling-Notizen ist im Anhang dokumentiert (vgl. Anhang A1). Der vollständige Dokumentenlog (Audit-Trail) mit Dokument-ID, Dokumenttyp, Sprache, URL, Inklusionsstatus und Relevanznotizen ist ebenfalls im Anhang ausgewiesen (vgl. Anhang A2). Eine ergänzende Unternehmensübersicht nach Sektoren, einschließlich Werte- und Governance-Kennzahlen auf Unternehmensebene, befindet sich im Anhang (vgl. Anhang A14). Diese Anhangsmaterialien dienen der Transparenz und Replizierbarkeit; die Ergebnisdarstellung im Haupttext fokussiert auf die verdichteten Befunde. Eine Zusammenfassung der Auswertungen pro Unternehmen wird in Tab. 4-5 dargestellt.

4.2 Konvergenzbefunde

Dieser Abschnitt berichtet über die empirischen Konvergenzbefunde auf Werteebene. Die Darstellung folgt einer zweistufigen Logik: Zunächst werden die Häufigkeiten und

Bindigkeitsmuster der einzelnen Wertedimensionen über alle Unternehmen hinweg dokumentiert. Anschließend werden Konvergenzbefunde über Unternehmenspaare (Jaccard-Ähnlichkeiten) sowie Strukturbefunde aus der Clusteranalyse der Werte-Konfigurationen dargestellt. Detailtabellen (vollständige Company-Level-Matrizen, Indexlisten sowie vollständige paarweise Ähnlichkeitsdaten) werden aus Platz- und Lesbarkeitsgründen im Anhang geführt und im Fließtext nur referenziert

4.2.1 Prävalenz und Bindigkeit der Werte

Die Wertetaxonomie umfasst 18 ethische Werte, die in den Dokumenten binär kodiert wurden und zusätzlich hinsichtlich ihrer normativen Verbindlichkeit in drei Gewichtungsstufen bewertet wurden. Tab. 4-1 fasst die Prävalenzen der einzelnen Werte über alle 40 Unternehmen hinweg zusammen und zeigt, wie häufig höhere Bindigkeitsniveaus vergeben wurden.

value_id	n_companies_present	share_companies_present	mean_points_present	count_binding_1	share_binding_1_given_present	count_binding_2	share_binding_2_given_present	count_binding_3	share_binding_3_given_present
VAL_01	20	50,0%	2,400	3	15,0%	6	30,0%	11	55,0%
VAL_02	19	47,5%	2,263	3	15,8%	8	42,1%	8	42,1%
VAL_03	25	62,5%	1,880	10	40,0%	8	32,0%	7	28,0%
VAL_04	18	45,0%	2,000	6	33,3%	6	33,3%	6	33,3%
VAL_05	23	57,5%	2,043	7	30,4%	8	34,8%	8	34,8%
VAL_06	22	55,0%	2,227	6	27,3%	5	22,7%	11	50,0%
VAL_07	19	47,5%	2,105	6	31,6%	5	26,3%	8	42,1%
VAL_08	21	52,5%	2,048	6	28,6%	8	38,1%	7	33,3%
VAL_09	21	52,5%	2,286	5	23,8%	5	23,8%	11	52,4%
VAL_10	3	7,5%	2,667	0	0,0%	1	33,3%	2	66,7%
VAL_11	11	27,5%	1,727	6	54,5%	2	18,2%	3	27,3%
VAL_12	13	32,5%	1,615	7	53,8%	4	30,8%	2	15,4%
VAL_13	18	45,0%	1,111	16	88,9%	2	11,1%	0	0,0%
VAL_14	22	55,0%	2,136	4	18,2%	11	50,0%	7	31,8%
VAL_15	24	60,0%	1,708	9	37,5%	13	54,2%	2	8,3%
VAL_16	18	45,0%	2,333	5	27,8%	2	11,1%	11	61,1%
VAL_17	7	17,5%	1,857	2	28,6%	4	57,1%	1	14,3%
VAL_18	13	32,5%	1,692	6	46,2%	5	38,5%	2	15,4%

Tab. 4-1: Prävalenz und Bindungsniveaus der kodierten Werte über alle untersuchten Unternehmen, eigene Darstellung

In der Häufigkeitsverteilung über alle Unternehmen hinweg sind insbesondere Transparency (VAL_03) mit 62,5% sowie Ethical Use & Integrity (VAL_15) mit 60,0% als am häufigsten kodierte Werte sichtbar. Ebenfalls in der oberen Häufigkeitsgruppe liegen Fairness & Non-Discrimination (VAL_05) (57,5%) sowie Privacy & Data Protection (VAL_06) und Lawfulness & Compliance (VAL_14) (je 55,0%). Werte im mittleren Häufigkeitsbereich betreffen u. a. Safety & Harm Prevention (VAL_08) und Technical Robustness & Reliability (VAL_09) (je 52,5%) sowie Human Agency & Oversight (VAL_01) (50,0%). Im unteren

Häufigkeitsbereich zeigen sich besonders Contestability & Redress (VAL_10) (7,5%) und IP & Confidentiality (VAL_17) (17,5%), während Inclusiveness & Accessibility (VAL_11) (27,5%) und Human Rights (VAL_18) (32,5%) in der unteren bis mittleren Prävalenzgruppe liegen.

Über die Häufigkeit hinaus differenziert Tab. 4-1 die Werte nach Bindigkeitsniveaus. Empirisch fallen zwei Muster auf. Erstens weisen mehrere häufig kodierte Werte einen hohen Anteil an BIND_3-Evidenzen auf. Dies gilt etwa für Human Agency & Oversight (VAL_01), bei dem 55,0% der Präsenzfälle auf BIND_3 entfallen, sowie für Technical Robustness & Reliability (VAL_09) (52,4%) und Privacy & Data Protection (VAL_06) (50,0%). Besonders ausgeprägt ist der Anteil von BIND_3 bei Data Quality & Governance (VAL_16) (61,1%). Zweitens finden sich Werte, die - sofern sie präsent sind - überwiegend auf BIND_1 kodiert werden. Dies ist insbesondere für Social Benefit & Human Well-being (VAL_13) sichtbar, das in 88,9% der Präsenzfälle auf BIND_1 verbleibt. Auch Sustainability & Environmental Well-being (VAL_12) und Inclusiveness & Accessibility (VAL_11) weisen Mehrheiten auf BIND_1 auf (53,8% bzw. 54,5%). Diese Befunde beschreiben eine im Datensatz sichtbare Varianz zwischen stärker prozessualisierten bzw. regelhaften Wertformulierungen und eher prinzipiellen Wertstatements.

4.2.2 Breite der Werteprofile auf Unternehmensebene

Auf Unternehmensebene variiert die Anzahl kodierter Wertedimensionen deutlich. Der Werteumfang reicht im Datensatz von 0 bis 18 kodierten Werten. Den höchsten Wert erreicht Deutsche Telekom mit 18 von 18 möglichen Werten, gefolgt von Fresenius und SAP mit jeweils 17 sowie Allianz und Merck mit jeweils 16 Werten. Weitere hohe Werte zeigen Bayer, BMW und Siemens mit jeweils 15 sowie BASF und RWE mit jeweils 14 Werten. Am unteren Ende stehen 14 Unternehmen, bei denen in den ausgewerteten Dokumenten kein einziger KI-bezogener Wert identifiziert wurde. Zwischen diesen Polen finden sich Unternehmen mit breiten, mittleren und schmalen Wertesets, was die Heterogenität der dokumentierten Ethik-Kommunikation im DAX unterstreicht.

Die vollständige Company-Level-Wertematrix einschließlich Summen- und Sektorinformationen ist im Anhang dokumentiert (vgl. Anhang A13); eine alternative Darstellung der Wertematrix mit value_present und value_points je Unternehmen und Wert findet sich ebenfalls im Anhang (vgl. Anhang A8). Eine vollständige Indexübersicht je Unternehmen (Wertepunkte, Maximalpunkte, Konvergenz-Index und Governance-Index) ist im Anhang ausgewiesen (vgl. Anhang A10).

4.2.3 Paarweise Werte-Konvergenz

Zur Messung der inhaltlichen Ähnlichkeit der Werte-Sets wurde die paarweise Jaccard-Ähnlichkeit berechnet. Der Jaccard-Koeffizient bildet die Schnittmenge geteilter

Werte (bei binärer Präsenz/Absenz pro Wert) relativ zur Vereinigung der Werte ab und misst damit Konvergenz als thematisches Overlap der Werte-Konfigurationen, nicht als Bindigkeit oder Governance-Tiefe. Empirisch ergibt sich im Gesamtdatensatz (DAX-40 inklusive leerer Value-Sets) eine deutlich null-dominierte Struktur.

Für 91 Paarungen ist kein Jaccard-Wert berechenbar, da beide Unternehmen ein leeres Value-Set aufweisen und damit die Vereinigung der Wertemengen leer ist. Für die verbleibenden 689 Paarungen liegt die Jaccard-Ähnlichkeit im Mittel bei 0,272; der Median beträgt 0,000. Der Wertebereich reicht von 0,000 bis 1,000. Bezogen auf die vollständige Off-Diagonal-Matrix (40×39 Paare) entfallen 910 von 1.560 Off-Diagonal-Paaren auf Jaccard-Ähnlichkeit 0 (einschließlich der strukturell nicht berechenbaren Paare, die in der Matrixdarstellung als Null-Übereinstimmungen erscheinen). Damit ist im Gesamtdatensatz mehr als die Hälfte der Unternehmenspaare durch fehlende gemeinsame Wertedimensionen - oder durch fehlende Kodierbarkeit auf beiden Seiten - gekennzeichnet. Die vollständige Jaccard-Ähnlichkeitsmatrix ist im Anhang dokumentiert (vgl. Anhang A11); das Long-Format der paarweisen Ähnlichkeiten und Distanzen findet sich ebenfalls im Anhang (vgl. Anhang A12).

Wird die paarweise Konvergenz ausschließlich für jene 26 Unternehmen betrachtet, bei denen mindestens ein Wert kodiert wurde, verschiebt sich das Konvergenzbild deutlich. Innerhalb dieser Teilstichprobe liegt der Median der Jaccard-Ähnlichkeiten bei ca. 0,588; der Mittelwert beträgt ca. 0,577. Die oberen 5% der Paarungen erreichen Jaccard-Werte von ≥ 0,867. Diese Konstellation beschreibt im Datensatz eine zweistufige Befundlogik: Einerseits variiert, ob überhaupt ein kodierbares Werte-Set vorliegt, andererseits zeigen Unternehmen mit kodierbaren Werte-Sets untereinander teilweise hohe Ähnlichkeiten in der Zusammensetzung ihrer Werte-Konfigurationen.

Auf Ebene einzelner Paarbeispiele ist die höchste Übereinstimmung zwischen Allianz und Merck sichtbar (Jaccard-Ähnlichkeit = 1,000). Ebenfalls sehr hohe Werte ergeben sich zwischen Deutsche Telekom und Fresenius sowie zwischen Deutsche Telekom und SAP (je 0,944). Weitere hohe Überschneidungen zeigen sich zwischen Allianz und SAP sowie zwischen Merck und SAP (je 0,941) sowie zwischen Allianz und Siemens beziehungsweise Merck und Siemens (je 0,938). Solche Spitzenwerte sind im Datensatz als Fälle maximal bzw. nahezu maximal überlappender Werte-Sets dokumentiert und dienen hier als exemplarische Illustration des oberen Ähnlichkeitsbereichs. Die vollständigen Paarwerte sind im Anhang ausgewiesen (vgl. Anhang A12). Generell verdeutlicht diese Teilanalyse, dass dort, wo Werte vorhanden sind, erhebliche Überschneidungen bestehen. Die Werte-Konvergenz ist damit zweistufig: Zunächst die Frage nach der Existenz kodierbarer Werte und anschließend die Frage nach deren inhaltlichem Overlap.

4.2.4 Clusteranalyse der Werteprofile

Ergänzend zur paarweisen Ähnlichkeit wurden die Werte-Konfigurationen mittels hierarchischer Clusteranalyse strukturiert. Das Werte-Clustering basiert auf der binären Präsenz der Wertedimensionen und nutzt die Jaccard-Distanzen als Ähnlichkeitsmaß. In die Werte-Clusteranalyse konnten 26 Unternehmen einbezogen werden; 14 Unternehmen sind aufgrund leerer Value-Sets ausgeschlossen. Die vollständigen Clusterzuordnungen je Unternehmen für k=3/4/5 sowie die Ausschlussflags sind im Anhang dokumentiert (vgl. Anhang A15); der technische Linkage-Output (Merge-/Linkage-Log) ist im Anhang ausgewiesen (vgl. Anhang A16).

Die hierarchische Clusterung basiert auf Jaccard-Distanzen (1 - Jaccard-Ähnlichkeit). Bei drei Clusterlösungen (k = 3) zeigt sich ein stark konzentriertes Muster: 24 der 26 Unternehmen befinden sich in einem dominanten Hauptcluster, während zwei Unternehmen jeweils ein Einzelcluster bilden. Dieses Grundmuster bleibt auch bei vier und fünf Clustern erhalten. Bei k = 4 entsteht neben dem Hauptcluster ein kleines Dreier-Cluster, während zwei weitere Unternehmen Einzelcluster bleiben. Bei k = 5 spaltet sich dieses kleine Cluster weiter in Einzelcluster auf. Mit anderen Worten: Die Werte-Landschaft ist nicht stark ausdifferenziert, sondern durch einen breiten Kern kanonischer Werte geprägt, der von fast allen Unternehmen geteilt wird. Abweichungen finden sich nur bei wenigen Randfällen. Methodisch ergibt sich daraus, dass sich kein ‚bestes' k im Bereich von drei bis fünf Clustern identifizieren lässt. Die Struktur des Datenraums bleibt robust, nur die Randkonfigurationen variieren je nach Wahl des Schnitts. Damit ist für die Ergebnisdarstellung zentral, dass sich im Datensatz weniger eine Landschaft gleich großer, klar abgegrenzter Wertetypen zeigt, sondern vielmehr ein stabiler, großer Kerncluster, ergänzt um wenige Randkonfigurationen. Die konkrete Zusammensetzung der Randkonfigurationen ist in der Clusterzuordnung auf Unternehmensebene nachvollziehbar (vgl. Anhang A15).

Inhaltlich wird der große Cluster durch die wiederkehrende Kombination mehrerer häufig kodierter Kernwerte bestimmt: Transparenz, Human Agency & Oversight, Safety & Harm Prevention, Privacy & Data Protection, Ethical Use & Integrity, Technical Robustness & Reliability, Fairness & Non-Discrimination sowie Accountability & Responsibility. Deutlich seltener erscheinen Contestability & Redress, IP & Confidentiality sowie (in geringerem Maß) Inclusiveness & Accessibility. Diese Randwerte sind es, die einzelne Unternehmen zu peripheren Clusterzugehörigkeiten führen. Für die inhaltliche Profillinie der Cluster (Wertanteile je Cluster und k) wird auf den Profilanhang verwiesen, der die Wertedimensionen nach Clustergröße, Cluster-ID und Prävalenzanteilen ausweist (vgl. Anhang A18). Die Clusteranalyse unterstreicht damit die Konvergenz im Kern und die geringe Zahl abweichender Werteprofile. Insgesamt lässt sich im Datensatz damit eine robuste

Kern-Rand-Struktur in den Werte-Konfigurationen beschreiben, während sich die Feinstruktur der Randfälle über unterschiedliche k-Schnitte hinweg graduell verändert

4.3 Governance-Tiefe

Nachfolgend werden die Ergebnisse zur Governance-Tiefe dargestellt. Im Zentrum stehen (i) die Verteilung der Governance-Scores auf Kriterienebene, (ii) die verdichtete Operationalisierung auf Unternehmensebene über den Governance-Index sowie (iii) sektorale Unterschiede in deskriptiven Kennzahlen. Abschließend wird der Zusammenhang zwischen Werte-Index und Governance-Index auf Unternehmensebene berichtet. Detaillierte Company-Level-Matrizen sowie technische Cluster-Outputs werden im Anhang geführt.

4.3.1 Verteilung der Governance-Kriterien

Die Governance-Rubrik umfasst sieben Kriterien: Zuständigkeiten (GOV_01), Prozesse (GOV_02), Tools/Checks (GOV_03), Audits (GOV_04), Schulungen (GOV_05), Eskalationswege (GOV_06) und Incident-Reporting (GOV_07). Jeder Wert wurde mit einem Score von 0 (nicht vorhanden) bis 3 (implementiert und nachweisbar) bewertet. Tab. 4-2 zeigt die Verteilung der Scores über alle 40 Unternehmen. Die Verteilung der Score-Ausprägungen zeigt deutliche Unterschiede zwischen den Kriterien. Besonders sichtbar ist dies über den Anteil höherer Ausprägungen (Score 2 oder 3), der dokumentierte bzw. nachweisbar implementierte Governance-Mechanik abbildet.

gov_crit_id	count_score 0	count_score 1	count_score 2	count_score 3	share_score2_3
GOV_01	24	2	14	0	35,0%
GOV_02	16	4	19	1	50,0%
GOV_03	18	1	20	1	52,5%
GOV_04	30	5	4	1	12,5%
GOV_05	25	8	4	3	17,5%
GOV_06	30	5	4	1	12,5%
GOV_07	33	6	1	0	2,5%

Tab. 4-2: Verteilung der Governance-Scores je Kriterium, eigene Darstellung

Die Governance-Verteilungen zeigen eine starke Spreizung zwischen den Kriterien. Prozesse (GOV_02) und Tools/Checks (GOV_03) weisen die höchsten Anteile an höheren Ausprägungen (Score 2 oder 3) auf. Bei rund der Hälfte der Unternehmen sind diese Kriterien dokumentiert oder implementiert. Zuständigkeiten (GOV_01) folgen mit 35 % Anteil an Score 2/3. Deutlich niedriger fällt die Operationalisierung von Audits (GOV_04), Schulungen (GOV_05) und Eskalationswegen (GOV_06) aus; nur knapp 12-18 % der Unternehmen erreichen hier Score 2 oder 3. Incident-Reporting (GOV_07) bildet das Schlusslicht: Lediglich ein Unternehmen weist eine dokumentierte Reporting-Struktur auf, während 33 Unternehmen gar keine entsprechende Regelung offenlegen. Insgesamt wird sichtbar, dass

Governance-Mechanismen in den erhobenen Richtlinien selten über die Benennung hinausgehen und nur wenige Unternehmen Audits, Schulungen oder Eskalationswege nachweisbar implementiert haben.

4.3.2 Governance-Tiefe auf Unternehmensebene

Zur Verdichtung der Governance-Tiefe wird der Governance-Index als Summenmaß über alle sieben Kriterien genutzt. Die Rohsumme der Kriterien (maximal 21 Punkte) wird auf eine Skala von 0 bis 100 transformiert. Auf Unternehmensebene reicht die Governance-Rohsumme im Datensatz von 0 bis 16 Punkten; entsprechend reicht der Governance-Index von 0,00 bis 76,19.

Die höchsten Governance-Indexwerte erzielen Merck (76,19), Deutsche Telekom (71,43) und SAP (66,67). Es folgen Allianz und Münchener Rück mit jeweils 52,38 sowie Zalando und Infineon mit jeweils 47,62. Insgesamt 15 Unternehmen verzeichnen einen Governance-Rohwert von 0 und damit einen Indexwert von 0. Sie verfügen demnach über keinerlei dokumentierte Governance-Mechanismen entlang der definierten Kriterien. Die übrigen Unternehmen verteilen sich über das gesamte Spektrum, wobei der Großteil der positiven Werte im unteren bis mittleren Bereich liegt (10-40). Diese Verteilung beschreibt eine deutliche Streuung der öffentlich dokumentierten Governance-Tiefe zwischen vollständiger Abwesenheit der kodierten Mechanismen und vergleichsweise umfassender, kriterientiefer Dokumentation. Eine vollständige Indexübersicht je Unternehmen ist im Anhang dokumentiert (vgl. Anhang A10); die vollständige Company-Level-Governance-Matrix (Score je Unternehmen und Kriterium) ist ebenfalls im Anhang ausgewiesen (vgl. Anhang A9).

Vergleicht man die Verteilung der Governance-Indexwerte mit den Wertesets, wird eine Ausdifferenzierung sichtbar: Einige Unternehmen verfügen über umfangreiche Wertesets und gleichzeitig hohe Governance-Scores (etwa Deutsche Telekom, Merck und SAP), andere weisen zwar viele Werte, aber kaum Governance-Mechanismen auf (z. B. GEA Group, die in der entsprechenden Berechnung 0 Punkte im Governance-Index hat). Umgekehrt gibt es wenige Unternehmen mit moderatem Werteumfang, aber verhältnismäßig hohen Governance-Scores. Dieses Nebeneinander deutet darauf hin, dass die Operationalisierungstiefe nicht zwangsläufig aus der reinen Anzahl adressierter Werte abgeleitet werden kann - ein Befund, der in den Korrelationsanalysen genauer untersucht wird.

4.3.3 Branchenvergleich von Werte- und Governance-Index

Die Verfügbarkeit einer Branchenvariable (sector_cluster) erlaubt eine deskriptive Betrachtung der Indexverteilungen nach Sektoren. Tab. 4-3 berichtet sektorweise deskriptive Kennzahlen sowohl zur Wertepräsenz (durchschnittliche und mediane Anzahl präsenter

Werte pro Unternehmen) als auch zur Governance-Tiefe (mittlerer und medianer Governance-Index). Dabei handelt es sich um deskriptive Gruppenkennzahlen; insbesondere in Sektoren mit kleinen Fallzahlen ist die Aussage primär als Strukturinformation zu lesen.

sector_cluster	n_companies	mean_n_values_present	median_n_values_present	mean_governance_index	median_governance_index
Consumer	5	4,00	0	16,19	0,00
Finance	6	10,50	11	34,92	40,48
Industrie	12	7,67	9	14,29	7,14
Materials/Chemicals	6	8,50	10	25,40	16,67
Other/Hybrid	1	0,00	0	0,00	0,00
Tech	7	8,43	12	24,49	23,81
Utilities	3	10,67	14	30,16	19,05

Tab. 4-3: Branchenweise deskriptive Kennzahlen zu Wertepräsenz und Governance-Index, eigene Darstellung

Auf Werteebene zeigen Finance (M=10,50; Median=11,00) und Utilities (M=10,67; Median=14,00) die höchsten Kennzahlen der Wertepräsenz, gefolgt von Tech (M=8,43; Median=12,00) und Materials/Chemicals (M=8,50; Median=10,00). Consumer weist mit M=4,00 und Median=0,00 eine deutlich niedrigere Wertepräsenz auf. Other/Hybrid liegt bei n=1 mit 0,00 und ist daher als Einzelfallstruktur zu interpretieren. Auf Governanceebene zeigt Finance den höchsten mittleren Governance-Index (M=34,92; Median=40,48), gefolgt von Utilities (M=30,16; Median=19,05). Materials/Chemicals (M=25,40; Median=16,67) und Tech (M=24,49; Median=23,81) liegen im mittleren Bereich, während Industrie (M=14,29; Median=7,14) und Consumer (M=16,19; Median=0,00) niedrigere Werte aufweisen

Die Medianwerte zeigen, dass die Verteilungen innerhalb der Sektoren teilweise stark schief sind: So haben im Consumer-Sektor drei von fünf Unternehmen keine kodierten Werte oder Governance-Mechanismen, während einzelne Akteure höhere Werte erreichen. Die sektorale Auswertung dient als deskriptiver Anhaltspunkt; sie ersetzt keine inferenzstatistische Gruppenprüfung und sollte aufgrund der teils geringen Gruppengrößen mit Vorsicht interpretiert werden.

Ergänzende sektorale Detailauswertungen (z.B. sektorweise Korrelationswerte) sind im Anhang dokumentiert (vgl. Anhang A27, Anhang A28). Eine vollständige Unternehmensübersicht nach Sektoren mit unternehmensweisen Kennzahlen (Anzahl Werte, Werteanteil und Governance-Index) befindet sich ebenfalls im Anhang (vgl. Anhang A14).

4.3.4 Clusteranalyse der Governance-Profile

Neben Indexwerten wurden Governance-Profile zusätzlich über hierarchische Clusteranalysen strukturiert. Im Unterschied zum Werte-Clustering konnten hier alle 40 Unternehmen in die Clusterbildung einbezogen werden, da auch die Absenz eines Mechanismus als Score 0 in die Profile eingeht.

Bereits bei einer Aufteilung in drei Cluster (k = 3) ergibt sich eine deutliche Segmentierung: Im größten Cluster (n=19) liegen die Mittelwerte und Mediane über nahezu alle Kriterien hinweg sehr niedrig; die Mediane sind in allen sieben Kriterien 0, und der Anteil höherer Ausprägungen (Score 2/3) liegt in diesem Cluster durchgängig bei 0. Ein zweites, sehr kleines Cluster (n=3) hebt sich hiervon deutlich ab: Hier liegen Prozesse, Tools/Checks, Audits, Eskalationswege und Schulungen überwiegend im Bereich hoher Scores, während Reporting zwar niedriger ausfällt, aber nicht vollständig absent ist. Das dritte Cluster (n=18) bildet eine intermediäre Konfiguration: Prozesse und Tools/Checks sind dort vergleichsweise stark ausgeprägt (Median jeweils 2; hohe Anteile Score 2/3), während Audits, Eskalationswege und Reporting deutlich zurückbleiben. Diese Segmentierung beschreibt empirisch eine feinere Differenzierung der Governance-Tiefe, die über eine reine Präsenzmessung hinausgeht. Bei k = 4 und k = 5 bleibt dieses Grundmuster erhalten. Die beiden Pole - ein großer Cluster mit minimaler Governance und ein kleiner Cluster mit weitreichender Implementierung - bleiben stabil, während der mittlere Block sich mit zunehmender Clusterzahl weiter differenziert.

Diese Segmentierung erklärt, warum die Governance-Landschaft stärker gestreut ist als die Werte-Landschaft: Die ordinalen 0-3-Scores differenzieren feiner, und Unterschiede zwischen Benennung, Dokumentation und Implementierung treten deutlicher hervor als bei der binären Werteanalyse.

Die vollständigen Clusterzuordnungen (inkl. k=4 und k=5) sind im Anhang dokumentiert (vgl. Anhang A15). Die Governance-Clusterprofile nach k, Kriterium sowie Mittel-/Median-Score und Anteil hoher Scores sind im Anhang ausgewiesen (vgl. Anhang A19). Weitere technische Clusteroutputs sowie crosstab-basierte Übersichten zu Clusterlösungen sind ebenfalls im Anhang dokumentiert (vgl. Anhang A17, Anhang A23, Anhang A25).

4.3.5 Zusammenhang zwischen Werte- und Governance-Index

Zur Prüfung des Zusammenhangs zwischen der Werteausprägung und der Governance-Tiefe wurde eine Spearman-Rangkorrelation berechnet. Sie basiert auf 40 vollständigen Unternehmensfällen. Tab. 4-4 berichtet die Ergebnisse sowohl für die gewichtete Indexvariante (unter Einbezug der Bindigkeitsniveaus) als auch für eine präsenzbasierte Variante (Präsenz 0/1), jeweils mit p-Wert, Fallzahl und Bootstrap-Konfidenzintervall.

Der gewichtete Werte-Index (Konvergenz-Index) korreliert mit dem Governance-Index ausgesprochen positiv (ρ = 0,919, $p < 0{,}001$), das 95-%-Bootstrap-Konfidenzintervall reicht von 0,807 bis 0,974. Wird statt des gewichteten Index eine reine Präsenzvariante des Werte-Index verwendet (ohne Gewichtung der Bindigkeitsgrade), bleibt der positive Zusammenhang bestehen (ρ = 0,889, $p < 0{,}001$; 95-%-KI = [0,746; 0,963]). Beide Indexvarianten führen damit zu derselben empirischen Grundbeobachtung: Unternehmen mit höheren Werte-Indexwerten weisen im Datensatz tendenziell auch höhere Governance-Indexwerte auf. Dieser Befund ist jedoch nicht deterministisch. Wie die Clusteranalyse zeigt, existieren Unternehmen mit hohen Werteausprägungen und niedriger Governance-Tiefe und umgekehrt. Die Korrelationsanalyse liefert somit einen generalisierten Trend, kein zwingendes Muster auf Einzelfallebene.

values_index_variant	rho	p_value	n_complete_cases	ci_95_lower	ci_95_upper
values_index_weighted_0_1_recalc	0,919	0,00000	40	0,807	0,974
values_index_presence_0_1	0,889	0,00000	40	0,746	0,963

Tab. 4-4: Spearman-Rangkorrelation zwischen Werte- und Governance-Index, eigene Darstellung

Die vollständige Datengrundlage der Zusammenhangsanalyse ist im Anhang dokumentiert (vgl. Anhang A26).

4.4 Werte-Governance-Mapping

Nachfolgend soll empirisch sichtbar gemacht werden, wie sich die Wertedimensionen zu den beobachteten Mustern der Governance-Operationalisierung verhalten. Dabei wird Mapping hier nicht als zusätzliche, neu berechnete Co-Occurrence-Analyse verstanden, sondern als strukturierte Ergebnisdarstellung der bereits vorliegenden Verdichtungen: (i) Bindigkeitsniveaus innerhalb der Werte (BIND_1-BIND_3), (ii) Governance-Kriterienprofile (GOV_01-GOV_07) sowie (iii) die Zuordnungsmuster zwischen Werte- und Governance-Clustern. Im Ergebnis entsteht eine nachvollziehbare Brücke zwischen der Benennung ethischer Werte und ihrer dokumentierten organisatorischen Übersetzung über Rollen, Prozesse, Tools/Checks, Audits, Schulungen, Eskalationswege und Reporting

4.4.1 Bindigkeitsprofile als Operationalisierungssignal auf Werteebene

Die Analyse der Bindungsgrade lässt sich als Brücke zwischen der reinen Werte-Kommunikation und der tatsächlichen organisatorischen Verankerung lesen. Werte können auf drei Ebenen auftreten: als allgemeines Statement (BIND 1), als Policy-Regel (BIND 2) oder als Prozess- bzw. Standardvorgabe (BIND 3). Die Bindigkeitsniveaus in Tab. 4-1 zeigen, dass Operationalisierung bereits innerhalb der Werteerwähnung in unterschiedlicher Intensität sichtbar wird. Werte mit hohen Anteilen von BIND_3 sind im Datensatz häufiger als Standard-/Prozessvorgaben formuliert und damit stärker an konkrete Vollzugsschritte gekoppelt

Dies ist insbesondere bei Data Quality & Governance (VAL_16) (61,1% BIND_3), Human Agency & Oversight (VAL_01) (55,0% BIND_3), Technical Robustness & Reliability (VAL_09) (52,4% BIND_3) sowie Privacy & Data Protection (VAL_06) (50,0% BIND_3) dokumentiert. In den Dokumenten dieser Unternehmen werden rechtliche Anforderungen und Datenqualitätsfragen somit überwiegend als konkret implementierte Prozesse oder Standards beschrieben. Diese Werte sind also nicht nur deklarative Leitprinzipien, sondern werden in den Richtlinien häufig mit Rollen, Verantwortlichkeiten, Kontrollmechanismen oder technischen Standards unterlegt.

Bei anderen Werten dominiert hingegen Bindungsniveau 1. Social Benefit (VAL 13) erscheint bei 15 Unternehmen, davon in 80 % lediglich als allgemeines Leitbild. Ähnlich verhält es sich bei Ethical Use & Integrity (VAL 15), wo die Hälfte aller Präsenzfälle auf BIND 1 entfällt. Auch Sustainability (VAL 12) weist einen hohen Anteil an bloßen Bekundungen (43 %) auf und ist nur in zwei Fällen mit konkreten Prozessvorgaben verknüpft. Dies deutet darauf hin, dass diese Werte zwar relativ häufig erwähnt, aber selten in konkrete Governance-Mechanismen übersetzt werden. Bei Contestability & Redress (VAL 10) wird kein einziger Fall von Bindungsniveau 3 beobachtet; zwei der drei Nennungen bleiben auf Statement-Ebene, die dritte als Policy-Regel. Die Operationalisierung dieses Wertes (etwa durch Beschwerdeverfahren oder Wiedergutmachungsprozesse) findet in den ausgewerteten Dokumenten kaum statt.

Diese Bindigkeitsmuster beschreiben im Datensatz eine Spannweite zwischen prozessualisierten Wertformulierungen (BIND_3) und prinzipiellen Wertstatements (BIND_1), ohne dass damit bereits eine Bewertung der tatsächlichen Umsetzung verbunden wäre.

4.4.2 Governance-Kriterien als Operationalisierungsmechanik

Eine weitere Möglichkeit, die Brücke zwischen Werten und Maßnahmen zu betrachten, ist die Gegenüberstellung mit den Governance-Kriterien. So weisen Werte mit hohem Bindigkeitsgrad häufig auch eine Anbindung an Prozesse (GOV 02) und Tools/Checks (GOV 03) auf. Beispielsweise gehen hohe Ausprägungen bei Lawfulness & Compliance oft mit dokumentierten Risiko-Assessments, Compliance-Prozessen oder technischen Prüfinstrumenten einher. Data Quality & Governance wird in den Richtlinien häufig durch spezifische Datenmanagement-Prozesse, Qualitätskontrollen und klare Zuständigkeiten operationalisiert. Auch Technical Robustness & Reliability ist in vielen Fällen mit technischen Prüfverfahren, Testprotokollen und Audits gekoppelt. Demgegenüber zeigen die Governance-Kriterien Audits, Schulungen, Eskalationswege und Incident-Reporting nur in wenigen Unternehmen höhere Ausprägungen. Dies deutet darauf hin, dass auch bei Werten mit hohen Bindigkeitsgraden die Unterstützung durch Audits oder Schulungen nicht

selbstverständlich ist; viele Unternehmen benennen zwar Verantwortlichkeiten und Prozesse, verzichten aber auf flankierende Schulungsprogramme oder Eskalationsmechanismen.

Umgekehrt sind Werte mit niedrigen Bindigkeitsgraden häufig nicht mit Governance-Mechanismen verknüpft. Bei Social Benefit, Ethical Use & Integrity und Sustainability besteht eine große Kluft zwischen dem normativen Bekenntnis und der organisationalen Verankerung. Diese Werte werden oftmals als übergeordnete Leitbilder angeführt, ohne dass Rollen, Prozesse, Tools oder Schulungen spezifiziert würden. Auch Inclusiveness & Accessibility wird zwar in 17 Unternehmen adressiert, aber nur in der Hälfte der Fälle mit konkreten Prozessvorgaben versehen. Die Ergebnisse weisen daher auf ein heterogenes Bild der Operationalisierung hin: Einige Werte sind stark in Governance-Strukturen eingebettet, andere verbleiben auf der Ebene allgemeiner Erklärung.

Damit ist die im Datensatz sichtbarste Operationalisierungsmechanik auf der Governanceebene primär prozess- und prüfbezogen, während explizite Reporting-Strukturen im Sinne der verwendeten Rubrik nur in sehr wenigen Fällen belegbar sind.

Dieser Befund lässt sich in der Ergebnislogik der Rubrik so lesen: Wo Operationalisierung empirisch sichtbar wird, geschieht dies vor allem über dokumentierte Abläufe (Prozesslogik), konkrete Prüf- und Kontrollmechanismen (Tool-/Checklogik) sowie in kleineren Anteilen über Schulungsangebote. Dagegen bleiben Audits, Eskalationswege und insbesondere Reporting in vielen Unternehmen entweder unbenannt oder auf niedrigem Konkretisierungsniveau.

4.4.3 Zuordnungsmuster zwischen Werte- und Governance-Clustern

Ein spezifischer Mapping-Befund ergibt sich aus der Kreuzung der Clusterlösungen von Werte- und Governanceebene. Die Werte-Clusteranalyse basiert auf 26 Unternehmen (Unternehmen mit mindestens einem kodierten Wert); die Governance-Clusteranalyse umfasst 40 Unternehmen. Die Kreuztabellen beziehen sich entsprechend auf die 26 Unternehmen, für die Werte-Clusterzuordnungen vorliegen. Die vollständigen Kombinationstabellen aus Werte- und Governance-Clusterzuordnungen sind im Anhang dokumentiert (vgl. Anhang A21); die vollständigen Clusterzuordnungen je Unternehmen finden sich im Anhang (vgl. Anhang A15).

Für k=3 zeigt sich, dass der dominante Werte-Hauptcluster (n=24) nicht in einen einzelnen Governance-Cluster übergeht, sondern über alle drei Governance-Cluster verteilt ist. Konkret entfallen innerhalb dieses Werte-Clusters 18 Unternehmen auf Governance-Cluster 3, 3 Unternehmen auf Governance-Cluster 1 und 3 Unternehmen auf Governance-Cluster 2. Die beiden singleton-Werte-Cluster (je n=1) sind jeweils dem Governance-Cluster 1 zugeordnet. Damit ist empirisch dokumentiert, dass ähnlich strukturierte Werte-Sets (im Sinne der

Werte-Clustering-Konfiguration) im Datensatz mit unterschiedlichen Governance-Profilgruppen koexistieren.

Dieses Zuordnungsmuster bleibt auch bei feineren k-Schnitten in der Grundlogik erhalten. Bei k=4 verteilt sich der große Werte-Cluster (n=21) auf vier Governance-Cluster (mit Fallzahlen 11, 5, 3 und 2 je nach Governance-Cluster-ID). Bei k=5 zeigt sich für den Werte-Kerncluster (n=21) ebenfalls eine Verteilung auf mehrere Governance-Cluster (Fallzahlen 7, 5, 4, 3 und 2). Die kleinere Werte-Clustergruppe bei k=4 (n=3) verteilt sich auf mehrere Governance-Cluster; bei k=5 gilt dies analog für das verbleibende Zweier-Cluster (n=2). Über alle k-Schnitte hinweg ist damit deskriptiv festzuhalten, dass eine hohe Ähnlichkeit der Werte-Konfiguration nicht automatisch mit einer eindeutigen Zugehörigkeit zu einer bestimmten Governance-Profilgruppe einhergeht.

Im Datensatz sind die Governance-Cluster selbst klar durch ihre Profilstruktur differenziert (vgl. Anhang A19). Das Mapping-Ergebnis beschreibt somit nicht nur die Existenz mehrerer Governance-Profile, sondern insbesondere deren Koexistenz innerhalb eines dominanten Werte-Kernclusters. Dieser Befund bildet eine empirische Brücke zur späteren Diskussion der ‚principle-to-practice'-Differenz, ohne sie im Ergebnisteil zu interpretieren.

4.5 Sensitivitätsanalysen

Zur Überprüfung der Robustheit der Ergebnisse wurden Sensitivitätsanalysen durchgeführt. Diese Analysen verändern gezielt einzelne Parameter der Indexberechnung, um zu prüfen, wie stabil Rangordnungen, Cluster und Zusammenhänge gegenüber alternativen Gewichtungen oder Definitionen sind. Berechnet wurden ausschließlich Varianten, die sich ohne zusätzliche Annahmen direkt aus dem Datenbestand ableiten lassen. Nicht berücksichtigt wurden z. B. alternative Bindigkeitsgewichtungen, für die keine explizite Regelgrundlage vorlag. Die Definition der geprüften Sensitivitätsvarianten ist im Anhang dokumentiert (vgl. Anhang A29). Vollständige Indexwerte je Variante sowie Cluster-Crosstabs sind im Anhang ausgewiesen (vgl. Anhang A30, Anhang A31)

4.5.1 Variantenübersicht

Die Baseline-Variante des Konvergenz-Index multipliziert die Präsenz jedes Werts (0/1) mit dem jeweiligen Bindigkeitsgrad (1/2/3). Als alternative Spezifikation wurde eine Presence-only-Variante berechnet, die die Bindigkeitsgrade ausblendet und lediglich die Anzahl der adressierten Werte zählt (V_VAL_02_PRESENCE_ONLY) sowie zwei Governance-Varianten mit erhöhter Gewichtung spezifischer Kriterien: (i) doppelte Gewichtung von Audits und Reporting (V_GOV_02_AUDIT_REPORTING_X2) und (ii) doppelte Gewichtung von Audits und Eskalationswegen (V_GOV_03_AUDIT_ESCALATION_X2). Eine alternative gewichtete Werte-Indexvariante,

die ein anderes BIND->Points-Mapping erfordern würde, ist nicht erforscht worden; entsprechend wurden keine neuen Punktwerte angenommen oder ergänzend konstruiert.

4.5.2 Stabilität des Werteindex

Der Vergleich der beiden Varianten zeigt eine hohe, aber nicht vollständige Stabilität der Rangordnung. Der Spearman-Rangkorrelationskoeffizient zwischen beiden Ranglisten beträgt ρ = 0,9599. Der Top-10-Overlap, also der Anteil der Unternehmen, die in beiden Varianten unter den zehn ranghöchsten Unternehmen liegen, beträgt 0,7. Der mediane absolute Rangwechsel liegt bei einem Platz; der maximale beobachtete Rangwechsel beträgt 12 Plätze. Als maximaler Shift ist dokumentiert, dass Zalando von Rang 6 (Baseline) auf Rang 18 (V_VAL_02_PRESENCE_ONLY) verschoben wird. Auf Governance-Seite bleibt die Rangordnung in dieser Variante unverändert, da die Governance-Indexlogik in dieser Variante nicht modifiziert wird. Diese Abweichungen lassen sich rechnerisch dadurch erklären, dass die V_VAL_02_PRESENCE_ONLY alle Bindigkeitsabstufungen ausblendet und damit Informationsdichte verliert. Unternehmen mit gleicher Wertpräsenz, aber unterschiedlicher normativer Verbindlichkeit, werden in dieser Variante stärker angenähert. Gleichwohl bleibt die grundlegende Struktur der Rangliste erhalten, und die positiven Korrelationsbefunde mit dem Governance-Index bleiben bestehen (ρ = 0,889; siehe Tabelle 4-4).

4.5.3 Stabilität des Governance-Index

Beide Varianten führen zu minimalen Veränderungen in der Rangordnung. Für die Variante V_GOV_02_AUDIT_REPORTING_X2 beträgt die Rangkorrelation zur Baseline ρ = 0,9983; der Top-10-Overlap liegt bei 0,9, der mediane Rangwechsel bei 0 und als maximaler Shift ist dokumentiert, dass Commerzbank von Rang 9 (Baseline) auf Rang 7 (Variante) verschoben wird. Für die Variante V_GOV_03_AUDIT_ESCALATION_X2 liegt die Rangkorrelation bei ρ = 0,9991; hier beträgt der Top-10-Overlap 1,0, und weder der mediane noch der maximale Rangwechsel übersteigt 2 Plätze. Als dokumentierter Maximalfall verschiebt sich BMW von Rang 11 auf Rang 13.

Ergänzend zur Baseline-Korrelation (vgl. Tab. 4-4) wird der Werte-Governance-Zusammenhang auch für die Sensitivitätsvarianten berichtet. Unter erhöhter Gewichtung von Audits und Reporting beträgt der Spearman-Koeffizient ρ=0,9202; unter erhöhter Gewichtung von Audits und Eskalationswegen ρ=0,9226. Damit bleibt Richtung und Größenordnung des Zusammenhangs über die geprüften Varianten hinweg grundsätzlich stabil; die Unterschiede liegen im Datensatz in der Feinstruktur der Koeffizienten. Diese hohe Stabilität ist rechnerisch darauf zurückzuführen, dass die alternativen Gewichtungen nur Teilkomponenten des Governance-Index betreffen, während die übrigen Kriterien unverändert in die Summe eingehen. Zusätzliche Gewichte verändern vor allem relative Feinabstände, nicht aber die Grundstruktur der Verteilungen.

4.5.4 Stabilität der Clusterlösungen

Die Sensitivität der Clusterlösungen wurde über den Adjusted Rand Index (ARI) bewertet, der die Übereinstimmung zwischen zwei Clusterzuordnungen misst (1 = vollständige Übereinstimmung). Für die Werte-Cluster zeigt sich zwischen Baseline und V_VAL_02_PRESENCE_ONLY über alle geprüften Clusterlösungen hinweg vollständige Übereinstimmung (ARI = 1,000 für k = 3, 4 und 5). Dies ist konsistent mit der Tatsache, dass die Werte-Cluster bereits in der Baseline auf binären Mustern beruhen und die V_VAL_02_PRESENCE_ONLY daher keine strukturelle Veränderung einführt.

Die Governance-Cluster reagieren sensibler auf alternative Gewichtungen. Bei erhöhter Gewichtung von Audits und Incident-Reporting beträgt der Adjusted Rand Index zur Baseline 0,3740 für k = 3, 0,5757 für k = 4 und 0,9717 für k = 5. Eine höhere Gewichtung von Audits und Eskalationswegen führt zu stabileren Ergebnissen: ARI = 1,000 bei k = 3, 0,8355 bei k = 4 und 0,9149 bei k = 5. Diese Befunde bedeuten, dass die Governance-Cluster bei alternativen Gewichtungen nicht vollständig zusammenfallen: Vor allem die Aufteilung des mittleren Clusters variiert je nach Gewichtungsannahme, während sich die Kernpole (niedrige vs. hohe Governance) als robust erweisen. Für die Interpretation ist wichtig, dass solche Gewichtungsentscheidungen nur relative Gruppenabstände betreffen; die Rangordnung der einzelnen Unternehmen bleibt weitgehend stabil (siehe 4.5.2).

4.6 Zusammenfassung

Es wurde gezeigt, dass die DAX-40-Unternehmen bei der öffentlichen Dokumentation ihrer KI-Ethik einen heterogenen Eindruck vermitteln. Während einige Unternehmen ein breites Set an Werten adressieren und diese durch institutionalisierte Governance-Mechanismen untermauern, bleibt bei vielen die Ethik-Kommunikation fragmentiert oder gänzlich absent. Die Analyse hat deutlich gemacht, welche Werte besonders häufig sind, welche selten vorkommen und in welchen Bereichen die Operationalisierung am weitesten fortgeschritten ist. Zudem wurde anhand von Jaccard-Ähnlichkeiten, Clusterstrukturen und Indizes sichtbar, dass Konvergenz auf der Werteebene nicht automatisch zu tiefer Governance-Verankerung führt. Die Sensitivitätsanalysen bestätigen die Robustheit der wesentlichen Befunde, weisen aber zugleich auf die Sensitivität einzelner Clusterlösungen hin. Kapitel 5 wird diese Ergebnisse in ihren theoretischen Kontext einordnen, ihre Implikationen für Forschung und Praxis diskutieren und mögliche Ursachen für die beobachteten Muster erörtern. Tab. 4-5 fasst die Analyse- und Berechnungsergebnisse pro Unternehmen noch einmal zusammen.

company_id	company_name	sector_cluster	n_values_present	share_values_present	convergence_index_0_1	gov_index_0_100
1	Adidas	Consumer	0	0	0,00	0,00
2	Airbus	Industrie	13	0,72	0,41	19,05
3	Allianz	Finance	16	0,89	0,61	52,38
4	BASF	Materials/Chemicals	14	0,78	0,48	28,57
5	Bayer	Materials/Chemicals	15	0,83	0,57	42,86
6	Beiersdorf	Consumer	9	0,50	0,41	33,33
7	BMW	Industrie	15	0,83	0,44	38,10
8	Brenntag	Materials/Chemicals	0	0,00	0,00	0,00
9	Commerzbank	Finance	14	0,78	0,52	42,86
10	Continental	Industrie	8	0,44	0,24	9,52
11	Daimler Truck	Industrie	6	0,33	0,11	4,76
12	Deutsche Bank	Finance	14	0,78	0,30	38,10
13	Deutsche Börse	Finance	6	0,33	0,13	19,05
14	Deutsche Post	Other/Hybrid	0	0,00	0,00	0,00

15	Deutsche Telekom	Utilities	18	1,00	0,91	71,43
16	E.ON	Utilities	0	0,00	0,00	0,00
17	Fresenius	Tech	17	0,94	0,85	33,33
18	Fresenius Medical Care	Tech	0	0,00	0,00	0,00
19	GEA Group	Industrie	13	0,72	0,56	42,86
20	Hannover Rück	Finance	5	0,28	0,09	4,76
21	Heidelberg Materials	Materials/Chemicals	0	0,00	0,00	0,00
22	Henkel	Materials/Chemicals	6	0,33	0,20	4,76
23	Infineon	Tech	13	0,72	0,43	47,62
24	Mercedes-Benz Group	Industrie	12	0,67	0,39	19,05
25	Merck	Materials/Chemicals	16	0,89	0,72	76,19
26	MTU Aero Engines	Industrie	0	0,00	0,00	0,00
27	Münchener Rück	Finance	8	0,44	0,28	52,38

28	Porsche Automobil Holding	Industrie	0	0,00	0,00	0,00
29	Qiagen	Tech	0	0,00	0,00	0,00
30	Rheinmetall	Industrie	0	0,00	0,00	0,00
31	RWE	Utilities	14	0,78	0,54	19,05
32	SAP	Tech	17	0,94	0,87	66,67
33	Scout24	Tech	0	0,00	0,00	0,00
34	Siemens	Industrie	15	0,83	0,43	38,10
35	Siemens Energy	Industrie	0	0,00	0,00	0,00
36	Siemens Healthineers	Tech	12	0,67	0,48	23,81
37	Symrise	Consumer	0	0,00	0,00	0,00
38	Volkswagen	Industrie	10	0,56	0,19	0,00
39	Vonovia	Consumer	0	0,00	0,00	0,00
40	Zalando	Consumer	11	0,61	0,59	47,62

Tab. 4-5: Zusammenfassung der Ergebnisse pro Unternehmen, eigene Darstellung

5. Diskussion

Kapitel 5 diskutiert die in Kapitel 4 berichteten Befunde vor dem Hintergrund der aufgearbeiteten Forschungsliteratur. Ziel ist nicht, die Ergebnisse erneut zu referieren, sondern ihren Bedeutungsgehalt analytisch herauszuarbeiten: Was lässt sich aus der beobachteten Wertearchitektur und ihrer (un)gleichen Governance-Verankerung über den Stand unternehmensseitiger KI-Ethik im DAX ableiten? Welche Spannungen zwischen normativer Selbstbeschreibung und institutioneller Umsetzung werden sichtbar, und wie sind diese Spannungen in der Forschung - insbesondere in der Debatte um ‚principles vs. practices' - zu verorten?

Die Diskussion folgt dabei konsequent der zweidimensionalen Logik der Arbeit: Auf der einen Ebene steht die Konvergenz ethischer Werte als öffentliche, KI-bezogene Normsemantik; auf der anderen Ebene steht die Operationalisierungstiefe als dokumentierte Governance-Architektur (Rollen, Prozesse, Tools/Checks, Audits, Trainings, Eskalationswege und Reporting). Die zentrale interpretative Leitfrage lautet damit nicht, ob Unternehmen ‚Ethik betreiben', sondern ob und wie die in Dokumenten artikulierten Werte in nachweisnahe Organisationsmechanismen übersetzt werden und welche Konsequenzen daraus für Vertrauen, Steuerbarkeit und regulatorische Anschlussfähigkeit entstehen.

5.1 Einordnung in die Literatur

Ein erster, analytisch zentraler Befund der Ergebnisse ist die Gleichzeitigkeit von Konvergenz und Fragmentierung auf der Werteebene. Kapitel 4 zeigt einen wiederkehrenden Kern häufig adressierter Werte (u. a. Transparenz, Ethical Use/Integrity, Fairness/Nichtdiskriminierung, Datenschutz sowie Rechtmäßigkeit/Compliance) und zugleich einen Randbereich deutlich seltener explizit adressierter Wertdimensionen (u. a. Contestability/Redress, Inklusion/Accessibility, Menschenrechte). Diese Struktur ist für die Einordnung in die Literatur deshalb wichtig, weil sie zwei Lesarten zulässt: Einerseits kann sie als empirisches Indiz eines sich stabilisierenden Wertekanons interpretiert werden. Andererseits kann sie als Hinweis darauf gelesen werden, dass bestimmte Werte (besonders jene, die konfliktgeladen oder schwer operationalisierbar sind) in Corporate-Policy-Artefakten eher randständig bleiben.

Die internationale Forschung liefert hierfür zunächst eine robuste Baseline: Mehrere kartierende Arbeiten berichten seit den späten 2010er Jahren eine wachsende Annäherung von KI-Ethikleitlinien und Responsible-AI-Principles an einen normativen Kern wiederkehrender Themen, zugleich aber eine erhebliche Divergenz in Bedeutungszuschreibungen und Umsetzung. Jobin et al. (2019) zeigen in ihrer Auswertung von 84 Ethikleitlinien eine „emerging convergence" um fünf Prinzipien (u. a. Transparenz, Fairness, Privacy, Verantwortung), betonen jedoch zugleich, dass diese Konvergenz nicht als Konsens über Definitionen, Zielkonflikte oder Implementationsmechanismen missverstanden

werden darf (S. 7). Diese Diagnose passt in die DAX-Befunde in zweifacher Hinsicht: Erstens ist die in Kapitel 4 empirisch sichtbare Häufung genau jener Kernwerte konsistent mit dem international wiederkehrenden Vokabular. Zweitens spiegelt die gleichzeitige Randständigkeit bestimmter Werte (etwa Contestability/Redress oder Menschenrechte) eine Logik wider, die die Literatur ebenfalls diskutiert - nämlich, dass Corporate-Guidelines tendenziell auf Werte fokussieren, die als anschlussfähig an technische oder compliance-nahe Übersetzungen gelten, während politisch konfliktträchtigere oder schwer messbare Werte weniger prominent artikuliert werden (Jobin et al., 2019, S. 14-16).

Fjeld et al. (2020) verdichten diese Baseline, indem sie über 36 prominente Prinzipiendokumente hinweg acht Themenfelder als besonders konsensfähig ausweisen (u. a. Fairness/Nichtdiskriminierung, Transparenz/Erklärbarkeit, Privacy, Accountability, Safety/Security) (S. 4). Für die Diskussion ist daran zweierlei anschlussfähig: Zum einen stützen die Fjeld-Ergebnisse die Interpretation, dass der in Kapitel 4 identifizierte Wertekern nicht zufällig ist, sondern in einen größeren, international standardisierten Responsible-AI-Diskurs eingebettet liegt. Zum anderen weisen Fjeld et a. (2020) ausdrücklich darauf hin, dass Prinzipien nur ein Startpunkt sind und Wirkung erst durch die Einbettung in Governance-Ökosysteme (Policies, Routinen, professionelle Praktiken) entfaltet wird - eine Brücke, die in der vorliegenden Arbeit durch die getrennte Messung von Werteebene und Governanceebene empirisch operationalisiert wird (S. 5).

Die neuere Meta-Analyse von Corrêa et al. (2023) verschärft diese Einordnung, indem sie einerseits ebenfalls einen global resonierenden Prinzipienkanon mit hohen Häufigkeiten ausweist (u. a. Transparenz/Erklärbarkeit/Auditierbarkeit, Reliability/Safety/Security, Fairness/Nichtdiskriminierung, Privacy, Accountability/Liability), andererseits aber den überwiegend „soft law“-Charakter vieler Leitlinien und deren generische, teils oberflächliche Ausgestaltung betont (S. 12). Der Befund, dass Label-Konvergenz nicht automatisch normative Stärke oder praktische Wirksamkeit bedeutet, spiegelt sich in Kapitel 4 insbesondere dort, wo Bindigkeitsgrade differenziert ausfallen: Einige Werte werden eher auf Standard-/Prozessniveau formuliert (also näher an Requirements), andere verbleiben als allgemeine Leitbilder. In der Terminologie, die in Kapitel 2 als definitorische Leitplanke angelegt ist (Werte, Prinzipien, Anforderungen/Requirements), lässt sich dies als empirischer Hinweis lesen, dass nicht alle Wertdimensionen gleichermaßen in organisational übersetzbare Anforderungen übergehen.

Damit wird die Diskussion an einem zentralen Punkt anspruchsvoller: Der Befund einer partiellen Wertekonvergenz ist allein noch kein Beleg für substanzielle ethische Governance, sondern zunächst ein Befund über semantische Angleichung. Genau hier setzt die ‚principles alone‘-Kritik an, die in den diversen Forschungsarbeiten immer wieder hervorkommt.

Mittelstadt (2019) argumentiert, dass High-level-Prinzipien in der KI-Ethik aus strukturellen Gründen häufig vage bleiben: Begriffe wie Fairness oder Würde sind „essentially contested concepts“, deren Konflikte nicht durch abstrakte Konsensformeln gelöst werden, sondern erst in der konkreten Spezifikation - und dann oft politisch und organisatorisch virulent werden (S. 5-7). Zudem betont Mittelstadt (2019), dass wirksame Übersetzung von Prinzipien institutionelle Voraussetzungen erfordert (z.B. robuste Accountability-Mechanismen, erprobte Übersetzungspraktiken, klare Zuständigkeiten), die im KI-Feld gegenüber etablierten Domänen wie der Medizinethik häufig fehlen (S. 9-10). Diese Perspektive korrespondiert mit der DAX-Empirie dort, wo Kapitel 4 eine heterogene Governance-Tiefe sichtbar macht: Selbst wenn Werte semantisch konvergieren, ist ihre institutionelle Übersetzung nicht automatisch uniform.

Hagendorff (2020) verschärft diese Kritik, indem er die Wirksamkeit von KI-Ethik-Guidelines generell skeptisch bewertet und betont, dass Leitlinien teils als Soft-Governance oder PR fungieren können, während Durchsetzungs- und Implementationsmechanismen schwach bleiben (S. 1-2). Für die vorliegende Arbeit ist daran besonders relevant, dass nicht die Existenz wiederkehrender Prinzipien bestritten, sondern gerade die Diskrepanz zwischen prinzipienbasierter Rhetorik und institutioneller Wirkung problematisier wird (Hagendorff, 2020, S. 6-8). Die in Kapitel 4 berichtete Differenz zwischen häufig genannten Werten und selektiver bzw. ungleich tiefer Governance-Verankerung lässt sich vor diesem Hintergrund als konkrete, unternehmensbezogene Ausprägung jener ‚principle-to-practice‘-Problemlage interpretieren, die die Literatur auf Aggregatebene diagnostiziert.

Ergänzend warnt Gabriel (2020) vor einem „Schein-Konsens“ in Ethikcodes: Die hohe Abstraktion der Prinzipiensprache kann normative Divergenzen überdecken und zugleich Implementierbarkeit offenlassen (S. 18-19). Für die Diskussion ist dieser Punkt deshalb relevant, weil er erklärt, warum die DAX-Werteebene bei den Unternehmen relativ konvergent erscheinen kann, ohne dass dies automatisch eine konvergente Praxisarchitektur impliziert. Der Konsens kann semantisch stabil sein, während die eigentlichen Konflikte in der Operationalisierung (Trade-offs, Priorisierungen, Zuständigkeit für Abweichungen, Redress) auftreten, und genau diese Operationalisierung ist empirisch die heterogenere Ebene (Gabriel, 2020, S. 7-13).

An dieser Stelle gewinnt die spezifische Messlogik der Arbeit interpretative Trennschärfe. Die in Kapitel 4 berichteten Jaccard-Ähnlichkeiten messen primär die Überlappung von Wertesets als binäre Präsenzlogik, nicht jedoch die Bindigkeit oder die Governance-Tiefe. Damit ist der Befund einer hohen Ähnlichkeit unter den Unternehmen mit mindestens einem kodierten Wert als Indiz eines gemeinsamen Vokabulars und einer ‚Kanonisierung‘ bzw. Konvergenz von Prinzipien zu lesen, aber nicht als Proxy für Umsetzungsreife. Umgekehrt ist die Null-

Dominanz im Gesamtdatensatz nicht zwingend als ethischer Dissens bzw. Divergenz zu deuten, sondern stark durch die ungleiche Publikations- und Dokumentationsreife getrieben: Ein erheblicher Anteil der Unternehmenspaare teilt aufgrund leerer bzw. nicht kodierbarer Wertesets keine gemeinsame Wertdimension. Vor dem Hintergrund der evidenzbasierten Einschlusslogik der Studie ist dies weniger als ‚Abwesenheit von Ethik' zu lesen, sondern als Befund über öffentlich nicht belegbare Wertekommunikation im KI-Kontext.

Die zweite, theoretisch besonders fruchtbare Einordnung betrifft die Asymmetrie zwischen Wertekonvergenz und Governance-Divergenz. Gerade hier schließt die Arbeit eng an einen Befund an, der in der Literaturlandschaft zunehmend als Kernproblem verstanden wird: Werte und Prinzipien sind weit verbreitet, doch die Übersetzung in überprüfbare, organisationsfähige Mechanismen bleibt selektiv. de Laat (2021) zeigt dies in einer Dokumentenanalyse von 24 KI-intensiven Unternehmen: Fast alle betonen einen Kern aus Fairness, Transparenz/Erklärbarkeit, Safety, Privacy und Accountability, aber ein großer Anteil führt keine öffentlich nachweisbaren Governance- und Implementierungsschritte aus (S. 1147-1149). Gleichzeitig dokumentiert de Laat (2021), dass dort, wo Umsetzung sichtbar wird, häufig tool- und artefaktbasierte Operationalisierungsmuster auftreten (S. 1153-1163). Diese Struktur ist für die DAX-Diskussion in zweifacher Hinsicht relevant: Erstens bestätigt sie die Erwartung, dass Werte-Konvergenz als solche kein hinreichender Hinweis auf Governance-Reife ist. Zweitens liefert sie eine plausible Erklärung, warum in den DAX-Dokumenten oft zunächst Prozesse und Tools sichtbar werden, während audit- und accountability-nahe Artefakte (z.B. unabhängige Assurance, Redress, systematisches Reporting) selektiver dokumentiert sind.

Damit wird die Debatte um ‚Ethics-Washing' analytisch anschlussfähig, ohne dass vorschnell einzelne Unternehmen etikettiert werden müssten. Ethics-Washing gilt hierbei nicht als moralische Zuschreibung, sondern als strukturtheoretische Hypothese über Entkopplung: Ethikkommunikation kann instrumentell eingesetzt werden, um Legitimität zu stiften, während institutionelle Durchsetzung schwach bleibt. Bietti (2021) definiert „Ethics-Washing" als instrumentelle Nutzung von Ethikrhetorik zur Legitimation von Selbstregulierung bzw. zur Abschirmung gegen externe Regulierung, z.B. durch Ethikräte ohne reale Entscheidungsmacht oder interne Ethikfunktionen ohne Einfluss (S. 2, 8-9). Wichtig ist dabei Biettis nuancierter Gegenpunkt: Kritik an Ethics-Washing sollte nicht in eine pauschale Abwertung von Ethik („ethics bashing") kippen, sondern in bessere Governance-Arrangements übersetzt werden, also in Institutionen, die Macht, Transparenz und externe Checks adressieren (Bietti, 2021, S. 9-10). Für die vorliegende Untersuchung bedeutet das: Die empirisch sichtbare Asymmetrie zwischen Werte- und Governanceebene kann als risikobehaftete Struktur interpretiert werden, da Legitimitätskommunikation leichter zu

standardisieren ist als die institutionelle Tiefenstruktur, ohne dass daraus zwingend eine intentionale Täuschung folgt.

Aus Marketingsicht ist dieses Konzept dennoch relevant, weil es Vertrauen und Reputation berührt. Peukert und Kloker (2020) zeigen empirisch, dass wahrgenommenes Ethics-Washing das Vertrauen von Konsumenten in Unternehmen senken kann (S. 8-9). Der Effekt wird insbesondere über erhöhte Risikowahrnehmung und Konsumentenverwirrung vermittelt. Auch wenn deren Studie nicht KI-Governance im DAX explizit misst, liefert sie eine belastbare ‚So-what'-Brücke: Wenn Stakeholder Ethikkommunikation als überhöht bzw. nicht durch Evidenz gedeckt wahrnehmen, kann dies Vertrauen beschädigen (Peukert & Kloker, 2020, S. 2). Übertragen auf die DAX-Ergebnisse lässt sich daraus konservativ ableiten, dass eine Diskrepanz zwischen normativer Selbstbeschreibung und nachweisbarer Governance nicht nur ein internes Steuerungsproblem, sondern auch ein potenzielles Vertrauensrisiko darstellt, insbesondere in Konstellationen, in denen KI-Anwendungen als risikobehaftet wahrgenommen werden.

Die alternative, weniger moralisch aufgeladene Erklärung dieser Diskrepanz ist die Transparenz- bzw. Dokumentationshypothese: Governance kann existieren, ohne öffentlich sichtbar zu sein. Diese Hypothese wird durch Forschung zu selektiver Offenlegung (selective disclosure) und Entkopplung (decoupling) plausibilisiert. Roszkowska-Menkes et al. (2024) zeigen am Beispiel der Nachhaltigkeitsberichterstattung, dass externe negative Ereignisse häufig selektiv berichtet werden und dass selbst Standards und Third-Party-Assurance selektive Offenlegung nicht zuverlässig verhindern (S. 14-15). Für die Diskussion ist daran weniger die inhaltliche Domäne (Sustainability) entscheidend als die Logik: Dokumente können systematisch eine andere Realität abbilden als gelebte Praxis, und Transparenzregime erzeugen nicht automatisch vollständige Offenlegung (Roszkowska-Menkes et al., 2024, S. 18). Übertragen auf KI-Governance bedeutet dies: Die in dieser Arbeit gemessene Governance-Tiefe ist strikt als ‚öffentlich belegte Governance' zu interpretieren. Gerade deshalb ist der Befund, dass ein Teil der Unternehmen keine kodierbaren KI-Werte dokumentiert, analytisch ambivalent: Er kann fehlende Offenlegung oder frühe Reifegrade anzeigen. Diese Arbeit kann diese Alternativen (bewusst) nicht trennscharf entscheiden.

Die Auditing-Literatur ergänzt diese Einordnung, indem sie präzisiert, was es heißt, von Audit oder Assurance zu sprechen. Mökander et al. (2021) definieren „Ethics-Based Auditing" (EBA) als strukturierten Prozess zur Prüfung automatisierter Entscheidungssysteme entlang des Lebenszyklus und betonen, dass Audits Governance über „procedural regularity" und Transparenz stützen können (S. 1,4). Zugleich diagnostizieren sie Grenzen und Risiken: Ohne verifizierbare Kriterien, Unabhängigkeit, Ressourcen und institutionelles Backing kann EBA selbst anfällig für „bluewashing" bzw. symbolische Formen werden; zudem bestehen

normative Trade-offs und technische Limits, die Auditierbarkeit in der Praxis herausfordern (Mökander et al., 2021, S. 3, 23). Für die DAX-Befunde heißt das: Dass Audit- und Reporting-Mechanismen in den Dokumenten selektiv sichtbar sind, ist nicht nur ein ‚fehlender Haken' in einer Checkliste, sondern kann strukturell damit zusammenhängen, dass Audits anspruchsvoll sind, Haftungsnähe erzeugen und eine robuste Organisations- und Nachweisinfrastruktur voraussetzen.

In ähnlicher Richtung argumentieren Radclye et al. (2023) in ihrer Analyse des EU-HLEG-Self-Assessment-Tools ALTAI: Operationalisierung über Checklisten und Controls ist ein Schritt vom Prinzip zur Praxis, bleibt jedoch ohne integrierte Grundrechtsfolgenabschätzung, ohne risikogewichtete Scoring-Logik und ohne Peer-Benchmarking bzw. unabhängige Audit-Ökosysteme begrenzt (S. 7). Diese Perspektive hilft, die in Kapitel 4 beobachtete Governance-Heterogenität nicht als binäres ‚vorhanden/nicht vorhanden', sondern als Reife- und Evidenzgradient zu verstehen: Ein Governance-System kann in frühen Stufen durchaus Prozesse und Tools dokumentieren, ohne bereits robuste Assurance-, Eskalations- und Reportingstrukturen nach außen hin evidenzfähig zu machen.

Ein weiterer, für die Einordnung wichtiger Punkt betrifft die Beziehung zwischen Werteartikulierung und Governance-Tiefe. Kapitel 4 berichtet einen positiven Zusammenhang zwischen beiden Dimensionen und zeigt in Sensitivitätsanalysen, dass die Grundstruktur dieses Zusammenhangs nicht von einer singulären Indexspezifikation abhängt. Interpretativ bedeutet dies: Die Befunde sprechen eher gegen ein flächendeckendes Bild totaler Entkopplung, sondern für eine Tendenz, dass Werteartikulation und Governance-Ausbau häufig gemeinsam steigen. Zugleich ist dieser Zusammenhang nicht kausal zu lesen. Er kann ebenso durch Publikationsreife als intervenierende Variable erklärt werden: Unternehmen, die umfangreich und verbindlich über KI sprechen, dokumentieren mit höherer Wahrscheinlichkeit auch Governance-Elemente. Gerade deshalb bleibt die zentrale Pointe der Arbeit bestehen: Prinzipiennennung ist kein valider Proxy für Operationalisierungstiefe. Erst die getrennte Analyse beider Ebenen macht die analytische Lücke sichtbar, die die Literatur als principle-to-practice gap diskutiert (Jobin et al., 2019, S. 10; Fjeld et al., 2020, S. 5; Mittelstadt, 2019, S. 4; de Laat, 2021, S. 1147).

Insgesamt lassen sich die Ergebnisse damit als differenzierte Position zwischen Konvergenz und Ethics-Washing einordnen. Die DAX-Dokumente zeigen (sofern kodierbare Werte vorliegen) eine deutliche Annäherung an einen international bekannten Kanon verantwortlicher KI-Prinzipien. Gleichzeitig offenbart die Governance-Ebene eine heterogene, selektive und komponentenweise ungleich entwickelte Operationalisierung: In mehreren Fällen ist Wertekommunikation weiter fortgeschritten als dokumentierte institutionelle Verankerung. Die Arbeit trägt damit zur Literatur bei, indem sie eine häufig behauptete

Differenz zwischen normativer Semantik und Governance-Praxis für einen klar definierten Unternehmenskontext (DAX, Stichtag 04.01.2026, öffentlich zugängliche Dokumente) systematisch abbildet und zugleich die interpretative Ambivalenz - Entkopplung vs. fehlende Transparenz - explizit offenhält.

5.2 Praktische Implikationen

Aus den Befunden und ihrer literaturgestützten Einordnung ergibt sich für die Unternehmenspraxis vor allem eine Leitimplikation: Responsible-AI-Governance sollte als evidenzfähiges System gestaltet werden, das die Übersetzung von Werten in überprüfbare Organisationsmechanismen systematisch ermöglicht. Die Operationalisierungsrubrik der Studie (0 = nicht vorhanden, 1 = benannt, 2 = dokumentiert, 3 = implementiert & nachweisbar) legt dafür einen pragmatischen Reifepfad nahe: Nicht der semantische Umfang eines Wertekanons ist entscheidend, sondern die Fähigkeit, Werte über Rollen, Prozesse, Artefakte und Rückkopplungsmechanismen in wiederholbare Praxis zu überführen.

Ein erster Good-Practice-Baustein betrifft die institutionelle Klarheit von Rollen, Verantwortlichkeiten und Entscheidungskompetenzen. Kapitel 4 zeigt, dass Zuständigkeiten als Governance-Kriterium zwar in Teilen sichtbar werden, die Tiefe jedoch variiert. Die Literatur macht deutlich, dass Accountability als governancefähiger Wert erst dann organisatorisch tragfähig wird, wenn sie entlang des Lebenszyklus konkretisiert ist, inklusive Verantwortlichkeit für Designentscheidungen, Monitoring und Redress. Fjeld et al. (2020) operationalisieren Accountability explizit als Bündel aus Design-Monitoring-Redress (S. 28-29); Mökander et al. (2021) verankern Auditing zudem in einer Rollenlogik, die Management, Organisation und unabhängige Audit-Funktionen unterscheidet (S. 8-9). Praktisch ergibt sich daraus die Implikation, Verantwortlichkeiten nicht nur abstrakt zuzuweisen, sondern in konkrete Mandate, Entscheidungsrechte und Schnittstellenregeln zu überführen, die eine nachvollziehbare Verantwortungszurechnung erlauben.

Ein zweiter Baustein liegt in der Etablierung lebenszyklusorientierter Prozesse mit klaren Prüfpunkten, die Werte in wiederkehrende Handlungsanforderungen übersetzen. Morley et al. (2020) beschreiben als zentrale Reifefrage der Responsible-AI-Debatte den Übergang vom „what“ (Prinzipien) zum „how“ (Methoden, Tools, Prozesse), wobei die Fähigkeit zur systematischen Risikominderung noch im Aufbau sei (S. 1). In ähnlicher Richtung bietet der Responsible-AI-Pattern-Katalog von Lu et al. (2024) ein explizites Musterrepertoire: Governance-Patterns (u. a. Verantwortungsarchitekturen, Oversight), Prozess-Patterns entlang des Entwicklungslebenszyklus (u. a. Verifikation, Monitoring, dynamic risk assessment) sowie Product-Patterns (u. a. Traceability, Validatoren, Mode-Switcher/Kill Switch) (S. 8-13). Für die DAX-Praxis impliziert dies, dass Governance nicht als einmalige Policy-Veröffentlichung zu verstehen ist, sondern als Prozessfamilie mit iterativen Reviews,

riskobasierten Freigaben und post-deployment Monitoring, also als kontinuierliche Organisationsroutine.

Ein dritter Baustein betrifft die Artefakt- und Toolchain-Logik, die Governance evidenzfähig macht. Kapitel 4 weist darauf hin, dass Tools/Checks in den Dokumenten häufiger sichtbar werden als Audits oder Reporting. Die Gefahr einer rein instrumentellen Tool-Orientierung besteht jedoch darin, dass Tools ohne Prozess- und Verantwortungsintegration zu fragmentierten Einzelmaßnahmen werden. Die Literatur liefert hier zwei komplementäre Impulse. Erstens dokumentiert de Laat (2021), dass eine Minderheit von Unternehmen implementierungsnahe Tools offenlegt und damit Responsible-AI-Principles in technische Praktiken überführt (z.B. Model Cards, Datasheets, Factsheets, Fairness- und XAI-Toolkits) (S. 1147-1152). Zweitens zeigen Ortega-Bolaños et al. (2024) in einer Übersichtsarbeit eine breite Landschaft von Operationalisierungstools und betonen die Notwendigkeit, Tools entlang von Prinzipien, Einsatzphasen und konkreten Controls zu typologisieren (S. 7, 15). Praktisch folgt daraus, dass Governance-reife Unternehmen Toolchains nicht nur bereitstellen, sondern ihre Verwendung standardisieren (z.B. tool-supported Checkpoints, verpflichtende Dokumentationsartefakte pro Use Case, Versionierung und Audit Trails) und so aus punktuellen Tools organisationsfähige Evidenzketten machen.

Ein vierter Baustein betrifft Audit- und Assessment-Mechanismen als Brücke von Prinzipien zu Praxisnachweis. Kapitel 4 deutet an, dass auditnahe Evidenz selektiver sichtbar ist. Zugleich sind Audits in der Literatur ein zentraler Hebel gegen symbolische Selbstregulierung. Mökander et al. (2021) formulieren hierfür Designkriterien (u. a. Holistic, Traceable, Accountable, Continuous) und betonen die Notwendigkeit proportionaler Sanktionen sowie organisationaler und institutioneller Verankerung (S. 17-21, 23). Raji et al. (2020) schließen an diese Logik an, indem sie interne Auditprozesse und Artefakte als Accountability-Infrastruktur skizzieren und damit zeigen, wie Audits als organisationsinterne Routine gestaltet werden können (S. 2, 6). Ergänzend liefert Reisman et al. (2018) mit dem Konzept von Algorithmic Impact Assessments (AIA) eine prozessuale Blaupause, die Transparenz, Self-Assessment, Stakeholder-Kommentierung, Due-Process-Challenge-Phasen und Erneuerungszyklen verbindet (S. 7-10). Für die Praxis ergibt sich daraus die Implikation, Assurance nicht nur als ‚Audit erwähnt' zu behandeln, sondern als auditierbare Prozessarchitektur mit klar definiertem Scope, Frequenz, Verantwortlichkeit, Dokumentationspflicht und Review-/Redress-Mechanismen.

Ein fünfter Baustein betrifft Trainings- und Qualifizierungsmechanismen als Voraussetzung skalierbarer Governance. Kapitel 4 führt Schulungen als eigenes Governance-Kriterium und legt nahe, dass Trainings in der öffentlichen Dokumentation nur selektiv sichtbar sind. In der Literatur wird Kompetenzaufbau wiederholt als notwendige Bedingung genannt, um Prinzipien

in alltägliche Entscheidungen zu übersetzen (Morley et al., 2020, S. 18-20; Hagendorff, 2020, S. 13-16). Good Practice bedeutet hier, Trainings nicht als einmalige Awareness-Maßnahme zu behandeln, sondern als rollenspezifische Kompetenzarchitektur (z.B. unterschiedliche Curricula für Product Owner, Data Scientists, Compliance/Risk, Einkauf, Legal), die konkrete Methoden (z.B. Dokumentationsartefakte, Risiko-Checks, Trade-off-Entscheidungen) vermittelt und zugleich an Governance-Prozesse gekoppelt ist (z.B. verpflichtend vor Freigaben oder bei Systemänderungen).

Ein sechster Baustein liegt in Eskalations-, Beschwerde- und Redress-Mechanismen. Kapitel 4 zeigt, dass Contestability/Redress als Wert eher randständig bleibt und dass Eskalationswege sowie Incident-Reporting in vielen Fällen schwach dokumentiert sind. Gerade diese Kombination ist governance-theoretisch sensibel, weil Accountability in der Literatur nicht nur als Zuständigkeit, sondern als Fähigkeit zur Korrektur, Abhilfe und Konsequenzsetzung verstanden wird. Fjeld et al. (2020) integrieren Redress als Bestandteil von Accountability (S. 28-29); Mökander et al. (2021) verankern Complaints und periodische Audits als Bestandteil eines lifecycle-orientierten Auditmodells (S. 13); Reisman et al. (2018) betonen Due-Process-Challenge-Phasen als Governance-Komponente (S. 7). Good Practice bedeutet hier, Eskalation nicht lediglich als ‚Kontaktadresse' zu benennen, sondern als prozessualisierten Pfad zu gestalten: Wer darf Systeme stoppen oder de-eskalieren, wie werden Beschwerden dokumentiert, wie werden Korrekturmaßnahmen entschieden, und wie werden Wiederholungen verhindert?

Ein siebter Baustein betrifft Reporting, Transparenz und Incident-Management als Rückkopplungsschleife. Kapitel 4 weist Reporting/Incident-Reporting als Governance-Kriterium aus, das in vielen Fällen nicht stark belegt bzw. institutionell verankert wird. Die Literatur macht jedoch deutlich, dass gerade diese Rückkopplung die Differenz zwischen symbolischer Governance und organisationsfähiger Steuerung markiert: Mökander et al. (2021) betonen procedural transparency, standardisierte Dokumentation und kontinuierliches Monitoring als Auditvoraussetzungen (S. 16-17); Radclye et al. (2023) diskutieren die Bedeutung von Auditability, Traceability und unabhängiger Überprüfbarkeit als Bedingungen wirkungsnaher Assessment-Ökosysteme (S. 7). Für die Praxis ergibt sich daraus, dass Transparenz nicht bei Wertformulierungen endet, sondern über Berichtsformate, Monitoring-Indikatoren, dokumentierte Incidents, Lessons Learned und (wo möglich) externe Kommunikation anschlussfähig wird.

Zusammenfassend lassen sich die praktischen Implikationen als Verschiebung von einer Werte- zu einer Evidenzlogik verdichten. Die Ergebnisse legen nahe, dass DAX-Unternehmen, sofern sie KI-Werte artikulieren, eine konvergente Responsible-AI-Sprache verwenden. Good Practice besteht vor diesem Hintergrund darin, diese Sprache in eine

konsistente Architektur aus Verantwortlichkeiten, Lebenszyklusprozessen, Artefaktketten, Audit/Assessment-Mechanismen, Qualifizierung, Redress und Reporting zu übersetzen. So, dass Governance nicht nur behauptet, sondern nachvollziehbar und wiederholbar wird. Gerade weil diese Arbeit Unterschiede in der dokumentierten Tiefe sichtbar macht, ist die praktische Pointe weniger ‚noch mehr Werte', sondern ‚klarere Übersetzungs- und Nachweisarchitekturen'.

5.3 Regulatorische Anschlussfähigkeit

Die vorliegenden Ergebnisse sind nicht als Rechtsprüfung zu lesen; dennoch sind sie regulatorisch anschlussfähig, weil die Operationalisierungsrubrik der Studie explizit jene Governance-Komponenten erfasst, die in risikobasierten Regimen typischerweise als Kernanforderungen erscheinen: Verantwortlichkeiten, Prozesspflichten, (technische) Kontrollen, Dokumentation, Monitoring und Incident-Mechanismen. Diese Anschlussfähigkeit wird besonders deutlich im Bezug zum Rechtsrahmen des EU AI Act (EU, 2024, S. 19) und dessen konkretisierender Darstellung in der Übersicht zu High-Risk-Systemen durch die Bundesnetzagentur (n/a, S. 1-2).

Die Bundesnetzagentur-Zusammenfassung hebt für High-Risk-Systeme insbesondere Prozess- und Nachweispflichten hervor: Risk-Management-System, Daten- und Daten-Governance, technische Dokumentation, Logging/Record-Keeping, Transparenz/Instructions for use, Human Oversight, Accuracy/Robustness/Cybersecurity sowie Post-Market-Monitoring und Serious-Incident-Reporting (Bundesnetzagentur, n/a, S. 3-5). Genau diese Bausteine lassen sich strukturell auf die Governance-Kriterien der Studie abbilden. Wenn Kapitel 4 beispielsweise zeigt, dass Prozesse und Tools/Checks häufiger dokumentiert werden als Audits, Eskalationswege und Reporting, dann ist dies regulatorisch insofern relevant, als riskobasierte Regime typischerweise gerade die Rückkopplungsmechanismen (Monitoring, Incident-Logik, Nachweis und Auditierbarkeit) als zentrale Bedingung für Steuerbarkeit und Aufsicht adressieren.

Der EU AI Act selbst lässt sich als Rahmen verstehen, der Rollen und Pflichten differenziert (u. a. provider-/deployer-bezogene Verantwortlichkeiten), Governance über Risk-Management- und Qualitätssystemlogiken institutionalisiert und Reporting/Registrierungs- und Incident-Mechanismen vorsieht (EU, 2024, S. 19-20, 101-102). Für die Diskussion bedeutet dies: Die in Kapitel 4 gemessene Governance-Tiefe kann als Indikator dafür gelesen werden, wie weit öffentliche Unternehmensdokumente bereits eine Struktur erkennen lassen, die prinzipiell in risikobasierte Compliance-Architekturen integrierbar ist. Zugleich bleibt die zentrale Einschränkung bestehen, dass die Studie öffentliche Evidenz erfasst und damit Anschlussfähigkeit primär als ‚dokumentierte Anschlussfähigkeit' diskutiert.

Neben regulatorischen Pflichten bieten standardisierungsnahe Frameworks eine zweite Anschlussfolie, weil sie Governance als Managementsystem strukturieren. Der Rahmen des National Institute of Standards and Technology arbeitet mit den Funktionen MAP, MEASURE und MANAGE und betont Trustworthiness-Charakteristika, kontinuierliches Monitoring, Change Management und Incident-Kommunikation (NIST, 2023, S. 12-17). Diese Systematik passt in die Logik der Governance-Rubrik: MAP und MEASURE sind ohne definierte Zuständigkeiten und Prozesse nicht organisationsfähig; MANAGE benötigt technische und organisatorische Controls, Eskalationswege sowie Dokumentations- und Reportingmechanismen (NIST, 2023, S. 25, 33-34, 37-38). Insofern lässt sich die DAX-Governance-Heterogenität auch als Unterschied in der Nähe zu einer Managementsystem-Logik interpretieren: Unternehmen, deren Dokumente prozess- und evidenzorientierte Steuerungsbausteine enthalten, erscheinen strukturell anschlussfähiger an risikomanagement-orientierte Rahmen, während reine Prinzipienkommunikation weniger direkt in Prüf- und Nachweissysteme übergeht.

Auf europäischer Ebene bildet ALTAI eine dritte Anschlussfolie, weil es Trustworthy-AI-Anforderungen in konkrete Fragen und Controls übersetzt (u. a. differenzierte Formen von Human Oversight, Robustheits-/Safety-Mechanismen, Datenschutz- und Data-Governance-Elemente sowie Auditability/Traceability) (EU HLEG, 2020, S. 4-7). Die Analyse von Radclye et al. (2023) macht jedoch zugleich sichtbar, dass Selbstassessments ohne integrierte Grundrechtsfolgenabschätzung, ohne Peer-Benchmarking und ohne risikogewichtete Scoringlogik begrenzt bleiben (S. 7). Regulatorische Anschlussfähigkeit ist damit nicht nur eine Frage der Existenz von Checklisten, sondern der Einbettung in ein Governance-Ökosystem, das Vergleichbarkeit, unabhängige Überprüfbarkeit und risikobasierte Priorisierung ermöglicht (Radclye et al., 2023, S. 1).

Eine zusätzliche, eher normativ-strukturierende Anschlussfolie bietet die UNESCO-Empfehlung zur Ethik der KI sowie die Readiness Assessment Methodology (RAM). RAM betont insbesondere Due-Diligence- und Oversight-Mechanismen, die Rolle von Ethical Impact Assessments sowie die Forderung nach Evidenz und Referenzen in Readiness-Dimensionen (Kettemann, n/a, S. 18-19; UNESCO, 2023, S. 3-4). Obwohl RAM primär auf staatliche Readiness zielt, lässt sich der dahinterliegende Gedanke, Governance als evidenzbasierte, mehrdimensionale Umsetzungsfähigkeit zu verstehen, als analytischer Spiegel für Unternehmenspraxis nutzen: Auch Unternehmen benötigen jenseits von Prinzipien nachvollziehbare Strukturen für Wirkung, Kontrolle, Beteiligung und Korrektur.

Schließlich verdeutlicht die sektorale Governance-Literatur, dass regulatorische Anschlussfähigkeit häufig lebenszyklusorientiert organisiert ist. Zhou und Gattinger (2024) beschreiben im MedTech-Kontext Governance als dynamisches Regime mit Change-Control-

Logiken, Stakeholder-Prozessen und Post-Market-Überwachung (S. 456-457). Für die Diskussion liefert dies keine direkte Übertragungsregel, aber einen interpretativen Hinweis: Dort, wo Unternehmen bereits Lebenszyklus-Governance, Monitoring und Change-/Re-Review-Trigger dokumentieren, ist eine Brücke zu regulatorisch geprägten Managementsystemlogiken tendenziell leichter zu schlagen (Zhou & Gattinger, 2024, S. 458-459).

Insgesamt zeigt sich damit eine doppelte Anschlussfähigkeit: Die in dieser Arbeit verwendete Governance-Rubrik ist inhaltlich gut kompatibel mit zentralen Kategorien risikobasierter Regulierung und standardisierungsnaher Risk-Management-Frameworks. Gleichzeitig wird sichtbar, dass Anschlussfähigkeit nicht allein durch Wertekanonisierung entsteht, sondern durch die Dokumentation und Institutionalisierung überprüfbarer Governance-Mechanismen, insbesondere dort, wo Monitoring, Incident-Reporting, Auditierbarkeit und Redress im Zentrum stehen. Gerade diese Elemente erscheinen in Kapitel 4 als vergleichsweise selektiv dokumentiert, was die Brücke von normativer Sprache zu regulatorischer Prüfbarkeit als zentrale Reifeaufgabe markiert.

5.4 Limitationen und Ausblick

Die Interpretation der Befunde ist durch mehrere Grenzen eingeschränkt, die für die wissenschaftliche Einordnung zentral sind. Eine erste Limitation liegt in der Datenbasis: Die Untersuchung stützt sich ausschließlich auf öffentlich zugängliche Dokumente und wendet eine strenge Einschlusslogik an, nach der nur KI-spezifische normative Substanz und evidenzfähige Governance-Mechaniken kodiert werden. Damit misst die Studie nicht die Gesamtheit interner Responsible-AI-Governance, sondern die öffentlich belegte Werte- und Governance-Architektur zum Stichtag 04.01.2026. Dieser Fokus ist methodisch konsequent und für Stakeholder-Transparenz hoch relevant, begrenzt aber die Aussage darüber, was intern tatsächlich implementiert ist. Die in Kapitel 4 berichteten Nullprofile sind daher nicht als Beleg fehlender Ethikrichtlinien zu interpretieren, sondern als dokumentierte Null-Evidenz innerhalb einer spezifischen, evidenzbasierten Such- und Einschlusslogik. Eine Ambivalenz, die de Laat (2021) auch in internationalen Firmenanalysen thematisiert, wenn er zeigt, dass selbst „committed“ Unternehmen häufig keine öffentlich nachweisbaren Implementierungsartefakte offenlegen (S. 1147).

Eine zweite Limitation ergibt sich aus der Heterogenität der analysierten Dokumenttypen und Kommunikationsformate. Responsible-AI-Websites, Codes-of-Conduct-Passagen oder ESG-Dokumente erfüllen unterschiedliche Funktionen und Adressatenlogiken. Obwohl die Company-level-Aggregation (Maximalprinzip) diese Heterogenität teilweise abfedert, bleibt die Vergleichbarkeit begrenzt, weil Unterschiede in Dokumentform und Publikationsstrategie das Ausmaß öffentlich sichtbarer Substanz beeinflussen können. Diese Grenze ist nicht als

methodische Schwäche, sondern als empirisch relevanter Teil des Forschungsgegenstands zu verstehen: Gerade Unterschiede in Publikations- und Dokumentationsreife sind selbst ein governance- und legitimitätsrelevantes Signal. Sie machen jedoch zugleich deutlich, dass Indizes die ‚kommunizierte' Ebene stärker abbilden als die ‚gelebte' Organisationspraxis.

Eine dritte Limitation betrifft die Interpretationsspielräume in der Kodierung umkämpfter Begriffe und die Gefahr, Labelkonvergenz zu überdeuten. Mittelstadt (2019) und Gabriel (2020) betonen, dass zentrale Werte wie Fairness oder Transparenz konzeptionell umkämpft sind und erst in lokaler Spezifikation ihre Konflikte entfalten (S. 5,7; S. 18-19). Auch Corrêa et al. (2023) heben hervor, dass gleich benannte Prinzipien in unterschiedlichen Dokumenten abweichend definiert und operationalisiert werden können (S. 13-14). Diese Arbeit zur Untersuchung der DAX40-Unternehmen adressiert dieses Risiko methodisch durch die Trennung von Wertepräsenz, Bindigkeit und Governance-Tiefe. Gleichwohl bleibt die semantische Varianz innerhalb von Codes ein grundsätzliches Problem dokumentenbasierter Inhaltsanalysen. Die Befunde sind daher vor allem als strukturelle Muster (Kern vs. Rand, Bindigkeitsdifferenzen, Governance-Komponentendifferenzen) und nicht als vollständige Rekonstruktion tatsächlicher Wert- bzw. Prinzipiensysteme einzelner Organisationen zu lesen.

Eine vierte Limitation betrifft die Indexlogik. Jaccard-Ähnlichkeiten messen Set-Überlappung und sind in der Gesamtstichprobe stark durch leere bzw. nicht kodierbare Wertesets beeinflusst. Sie bilden damit primär eine Kombination aus Werte-Überlappung und Publikations-/Evidenzlage ab. Der Konvergenzindex integriert Bindigkeitsgrade und wird dadurch aussagekräftiger, kann aber ebenfalls keine unmittelbare Aussage über Wirksamkeit liefern, sondern nur über dokumentierte, normative Verbindlichkeit. Der Governance-Index misst Operationalisierungstiefe anhand evidenzbasierter Kriterien, bleibt aber notwendigerweise von der Sichtbarkeit entsprechender Artefakte abhängig. Aus Sicht der Auditing-Literatur ist dies ein strukturelles Problem: Gerade Nachweis- und Auditierbarkeitskriterien sind anspruchsvoll und erfordern Artefaktketten, die nicht immer öffentlich gemacht werden, um Haftungs- oder Sicherheitsrisiken zu vermeiden (Mökander et al., 2021, S. 17-21, 23). Damit ist nicht auszuschließen, dass die Studie Governance-Reife in Fällen unterschätzt, in denen Substanz existiert, aber nicht öffentlich dokumentiert ist.

Eine fünfte Grenze ist die Querschnittlogik der Untersuchung. Der Stichtagsbezug stärkt Replizierbarkeit und reduziert die Verzerrung durch dynamische Webinhalte, erfasst aber keine Entwicklungsdynamiken. Gerade vor dem Hintergrund regulatorischer und technologischer Bewegungen ist plausibel, dass Unternehmen Responsible-AI-Governance in kurzer Zeit ausbauen oder umlabeln. Die Befunde sind daher als Momentaufnahme der öffentlich dokumentierten Governance-Ausprägungen zu lesen, mit dem analytischen Vorteil,

dass diese Momentaufnahme die Struktur des Feldes offenlegt (Kernkanon vs. Randwerte, Werte- vs. Governance-Asymmetrie), aber ohne Anspruch, Pfade oder Kausalmechanismen über Zeit nachzuweisen.

Aus diesen Limitationen ergeben sich mehrere präzise Anschlussfragen für zukünftige Forschung. Ein erster Forschungspfad liegt in der Validierung der Dokumentenbefunde durch organisationsinterne Triangulation. Interviews oder Fallstudien könnten klären, welche internen Governance-Strukturen existieren, die öffentlich nicht sichtbar sind, und welche organisationalen Gründe (z.B. Haftungsmanagement, Sicherheitsüberlegungen, Wettbewerbslogik) hinter selektiver Offenlegung stehen. Damit ließe sich die in Kapitel 4 und in dieser Diskussion herausgearbeitete Ambivalenz zwischen Entkopplungs- und Transparenzhypothese empirisch weiter auflösen.

Ein zweiter Forschungspfad betrifft externe Evidenz und Gegenprüfung. Roszkowska-Menkes et al. (2024) zeigen mit ihrem Counter-Accounting-Ansatz, dass selektive Offenlegung durch den Abgleich externer Ereignisdaten mit Reportinhalten sichtbar gemacht werden kann (S. 18). Übertragen auf KI-Governance könnte zukünftige Forschung dokumentierte Policies mit extern beobachtbaren Ereignissen (z.B. öffentlich dokumentierte KI-Incidents, regulatorische Verfahren, Kontroversen) spiegeln, um die Differenz zwischen Dokument und Praxis systematisch zu prüfen. Ein solcher Ansatz wäre besonders geeignet, nicht nur Governance-Existenz, sondern Governance-Wirkung über die Zeit anzunähern, ohne interne Daten vollständig vorauszusetzen.

Ein dritter Forschungspfad liegt in longitudinalen Designs. Wiederholte Kodierungen in mehrjährigen Wellen könnten Reifepfade sichtbar machen: Welche Werte gewinnen an Bindigkeit? Welche Governance-Komponenten (z.B. Audits, Reporting, Redress) werden nachgezogen? Wie stabil bleiben Cluster- und Zusammenhangsmuster? Gerade weil die Sensitivitätsanalysen in Kapitel 4 nahelegen, dass die Grundstruktur der Befunde robuster ist als feine Rang- oder Clusterzuordnungen, wäre ein Längsschnitt geeignet, robuste Trends von momentanen Grenzfällen zu unterscheiden.

Ein vierter Forschungspfad betrifft die Erweiterung der Vergleichsgruppe über den DAX hinaus. Vergleichsstudien könnten prüfen, ob die beobachtete Asymmetrie zwischen Werte- und Governance-Konvergenz in anderen Unternehmenspopulationen ähnlich ausgeprägt ist oder ob spezifische Kontextfaktoren (z.B. Unternehmensgröße, Internationalitätsgrad, Regulierungsdichte) systematisch mit Publikations- und Governance-Reife korrespondieren. Gerade weil die vorliegende Studie den Befund einer stark ungleichen öffentlichen Wertekommunikation im DAX sichtbar macht, ist es forschungslogisch naheliegend zu prüfen, ob dies ein index-/größenspezifisches oder ein allgemeineres Muster ist.

Ein fünfter, inhaltlich besonders aktueller Ausblick betrifft generative KI. Neuere Literatur zeigt, dass sich das ethische Issue-Portfolio im GenAI-Kontext teilweise verschiebt. Hagendorff (2024) kartiert eine große Bandbreite normativer Herausforderungen und betont u. a. die hohe Prävalenz von Risiken wie Bias/Fairness, Halluzinationen/Verlässlichkeit, Copyright/Autorschaft und schädliche Inhalte (S. 5). Stahl und Eke (2024) kritisieren zudem den ad-hoc-Charakter des Diskurses zu ChatGPT und plädieren für systematische, methodisch gestützte Issue-Landkarten sowie diverse Stakeholder-Engagement-Formate (S. 9-10). Al-Kfairy et al. (2024) ergänzen, dass Deepfakes und synthetische Medien neue Dimensionen von Vertrauens- und Stabilitätsrisiken eröffnen und Governance-Lösungen u. a. über Policies, Trainings, Stakeholder-Dialoge und unabhängige Audits/Evaluationen diskutiert werden (S. 6). Für künftige Forschung folgt daraus, dass Corporate AI-Governance nicht nur als Fortschreibung klassischer Responsible-AI-Principles untersucht werden sollte, sondern als dynamisches Feld, in dem neue Issue-Kategorien und neue Evidenzlogiken entstehen. Eine Anschlussstudie könnte daher prüfen, ob und wie DAX-Unternehmen GenAI-spezifische Risiken in ihre Werte- und Governance-Architekturen integrieren und ob dadurch bislang randständige Werte (z.B. Wahrheit/Disinformation, IP/Autorschaft, gesellschaftliche Resilienz) an Prominenz gewinnen.

Zusammenfassend verdichtet sich die Diskussion zu einer kontrollierten, aber klaren Kernaussage: Im DAX zeigt sich, unter den Unternehmen mit öffentlich artikulierten KI-Werten, eine deutliche Konvergenz der normativen Sprache, während die dokumentierte Praxisarchitektur der Governance heterogener bleibt. Damit bestätigt die Studie im Unternehmenskontext eine zentrale Diagnose der Forschung: Die Herausforderung liegt weniger im Auffinden immer neuer Prinzipien, sondern in der Übersetzung bestehender Prinzipien in institutionell robuste, evidenzfähige und rückkopplungsstarke Governance-Mechanismen (Jobin et al., 2019, S.14-16; Mittelstadt, 2019, S. 9-10; Hagendorff, 2020, S. 15-16; de Laat, 2021, S. 1173-1174; Mökander et al., 2021, S. 3). Gerade weil die Befunde zugleich einen positiven Zusammenhang zwischen Werteartikulation und Governance-Tiefe erkennen lassen, ermöglicht die Studie eine differenzierte Einordnung: Nicht ‚Ethics-Washing oder Substanz' als binäre Alternative, sondern ein Reife- und Evidenzgradient, in dem semantische Konvergenz häufig schneller erreicht wird als institutionelle Umsetzung, und in dem die Qualität von Responsible-AI-Governance zunehmend daran hängt, ob Unternehmen den Schritt von Prinzipien zu nachweisbarer Praxis systematisch vollziehen.

6. Fazit

Die Arbeit zeigt, in welchem Ausmaß ethische Kernwerte in öffentlich zugänglichen KI-Richtlinien der DAX-Unternehmen konvergieren und wie tief diese Werte organisatorisch operationalisiert sind. Das Erkenntnisinteresse lag damit in einer Lücke, die für den deutschen

Unternehmenskontext bislang nur unzureichend geschlossen war: der Differenz zwischen normativer Wertekommunikation einerseits und nachweisbarer KI-Governance andererseits. Auf Grundlage einer vergleichenden Inhaltsanalyse mit quantifizierenden Elementen zeigt diese Untersuchung für den Stichtag 4. Januar 2026, dass sich die KI-Ethik-Landschaft im DAX weder als vollständig homogen noch als bloß fragmentiert beschreiben lässt. Vielmehr tritt eine zweigeteilte Struktur hervor, in der sich ein wiederkehrender Kanon öffentlich artikulierter Werte abzeichnet, während die organisatorische Übersetzung dieser Werte deutlich ungleichmäßiger ausfällt.

Damit beantwortet die Arbeit die erste Forschungsfrage dahingehend, dass im DAX eine erkennbare, aber nicht durchgängige Konvergenz ethischer KI-Werte vorliegt. Unter jenen Unternehmen, bei denen überhaupt kodierbare KI-bezogene Werte dokumentiert sind, zeigt sich ein klarer Kern wiederkehrender Prinzipien. Besonders sichtbar sind Transparenz, Ethical Use beziehungsweise Integrity, Fairness beziehungsweise Nichtdiskriminierung, Datenschutz sowie Rechtmäßigkeit und Compliance. Ebenfalls regelmäßig adressiert werden Sicherheit, Robustheit und menschliche Aufsicht. Zugleich bleiben andere Wertdimensionen deutlich randständiger. Die Wertearchitektur ist daher nicht als einheitlicher Vollkonsens zu lesen, sondern als Kern-Rand-Struktur. Einige wenige Prinzipien bilden einen breit geteilten normativen Kanon, während andere nur selektiv aufgegriffen werden. Zugespitzt bedeutet dies: Es gibt im DAX eine semantische Annäherung in der Sprache verantwortlicher KI, aber keinen flächendeckenden Gleichstand aller Unternehmen. Denn schon auf der Werteebene trennt sich das Feld zunächst in Unternehmen mit öffentlich erkennbarer KI-Normarchitektur und solche, bei denen eine solche innerhalb der definierten Einschlusslogik nicht kodierbar war.

Die zweite Forschungsfrage nach der Tiefe der Governance-Operationalisierung beantwortet die Arbeit deutlich zurückhaltender. Die Ergebnisse machen sichtbar, dass die Übersetzung von Werten in organisationale Mechanismen wesentlich heterogener ist als die Wertekommunikation selbst. Wo Governance in den Dokumenten erkennbar wird, materialisiert sie sich vor allem in Prozessen und Tools beziehungsweise Checks; Zuständigkeiten folgen mit Abstand. Audits, Schulungen und Eskalationswege sind dagegen erheblich selektiver dokumentiert, und Incident-Reporting bleibt weitgehend randständig. Im Kern zeigt die Untersuchung damit, dass die öffentliche KI-Governance im DAX häufig auf einer mittleren Ebene der Operationalisierung stehen bleibt: Werte werden nicht selten benannt und teilweise auch in Prozesse überführt, doch tiefer institutionalisierte Nachweis-, Kontroll-, Lern- und Rückkopplungsmechanismen sind deutlich ungleichmäßiger ausgeprägt. Hinzu kommt, dass sich auch auf der Werteebene Unterschiede im Bindigkeitsgrad zeigen. Einige Werte treten häufiger in prozessualisierter und verbindlicher Form auf, während andere überwiegend den Charakter allgemeiner Leitbilder behalten. Die Governance-Tiefe ist somit

nicht nur zwischen Unternehmen, sondern auch zwischen einzelnen Wertdimensionen ungleich verteilt.

Für die dritte Forschungsfrage ergibt sich ein differenziertes Bild. Einerseits zeigt die Arbeit einen starken positiven Zusammenhang zwischen Werteartikulation und Governance-Tiefe: Unternehmen mit breiteren und verbindlicher formulierten Wertesets weisen tendenziell auch höhere Governance-Werte auf. Andererseits macht die Untersuchung ebenso deutlich, dass dieser Zusammenhang nicht als direkte oder gar deterministische Übersetzung verstanden werden darf. Ähnliche Werteprofile können mit unterschiedlichen Governance-Profilen koexistieren, und der dominante Werte-Kerncluster verteilt sich über mehrere Governance-Cluster hinweg. Gerade hierin liegt ein zentraler Befund der Arbeit: Prinzipiennennung ist kein valider Proxy für Governance-Reife. Die Werteebene beschreibt in erster Linie eine Konvergenz der normativen Sprache, nicht automatisch eine Konvergenz der organisatorischen Umsetzung. Damit bestätigt die Untersuchung zugleich die für die Arbeit leitende Annahme einer principle-to-practice-Differenz, ohne diese auf eine einfache Formel zu reduzieren. Die DAX-Unternehmen bewegen sich weder in einem Zustand flächendeckender Entkopplung noch in einem Zustand konsistenter Vollintegration, sondern auf einem Reife- und Evidenzgradienten zwischen semantischer Angleichung und unterschiedlich weit entwickelter Governance-Praxis.

Der zentrale Erkenntnisgewinn der Arbeit besteht darin, diese Differenz für den DAX-Kontext nicht nur normativ zu behaupten, sondern systematisch und empirisch sichtbar zu machen. Wissenschaftlich liegt der Beitrag darin, Wertepräsenz, Bindigkeit und Governance-Tiefe konsequent voneinander zu trennen und damit eine Analyseperspektive zu schaffen, die über eine reine Erfassung von Prinzipienvokabular hinausgeht. Die Arbeit zeigt, dass die Frage nach verantwortlicher KI im Unternehmenskontext nicht sinnvoll beantwortet werden kann, wenn Wertekommunikation und institutionelle Verankerung analytisch ineinander fallen. Der entwickelte Zugriff macht vielmehr deutlich, dass Konvergenz auf der Ebene ethischer Sprache und Heterogenität auf der Ebene organisationaler Umsetzung gleichzeitig bestehen können. Für den deutschen Unternehmenskontext schließt die Arbeit damit eine Lücke, weil sie die DAX-Landschaft als eigenständiges Untersuchungsfeld in einer Weise erschließt, die qualitative Tiefenschärfe mit systematischer Vergleichbarkeit verbindet.

Zugleich liegt in den Ergebnissen ein klarer praktischer Beitrag. Für Unternehmenspraxis und Governance-Debatte macht die Untersuchung deutlich, dass die Reife von KI-Governance nicht primär an der Breite des Wertekanons hängt, sondern an der Belastbarkeit seiner Übersetzungsarchitektur. Entscheidend ist nicht, immer neue Prinzipien zu formulieren, sondern vorhandene Werte in Rollen, Zuständigkeiten, lebenszyklusorientierte Prozesse, standardisierte Tools und Checks, Audit- und Assessment-Mechanismen, Trainings sowie

Eskalations- und Reportingstrukturen zu überführen. In diesem Sinne fungiert die in der Arbeit entwickelte Rubrik nicht nur als Analyseinstrument, sondern auch als pragmatischer Reifekompass. Zugleich schärft die Arbeit den Blick für die Grenzen öffentlicher Ethikkommunikation: Da sie ausschließlich öffentlich zugängliche Dokumente untersucht, sind Nullprofile nicht als Beweis fehlender interner Governance zu lesen, wohl aber als dokumentierte Null-Evidenz. Genau diese öffentliche Nachweisbarkeit ist jedoch für Legitimität, Vertrauen und regulatorische Anschlussfähigkeit von besonderer Bedeutung. Die Arbeit vermeidet daher eine vorschnelle Moralisierung einzelner Diskrepanzen, macht aber zugleich deutlich, dass eine Lücke zwischen normativer Selbstbeschreibung und dokumentierter Governance analytisch relevant bleibt.

Insgesamt verdeutlicht die Arbeit, dass sich die DAX-Unternehmen im Feld der KI-Ethik auf einen gemeinsamen normativen Kern zubewegen, dass diese Konvergenz jedoch sichtbar schneller entsteht als eine entsprechend tiefe institutionelle Umsetzung. Das Fazit der Untersuchung ist deshalb klar: Öffentliche KI-Richtlinien im DAX zeigen eine erkennbare Annäherung im Vokabular verantwortlicher KI, aber keine gleichförmige Ausprägung belastbarer Governance. Die eigentliche Reifeaufgabe liegt folglich nicht in der weiteren Ausweitung ethischer Semantik, sondern in der systematischen Überführung bestehender Prinzipien in nachweisbare, organisationsfähige und rückkopplungsstarke Praxis. Gerade an dieser Schnittstelle entscheidet sich, ob KI-Ethik im Unternehmenskontext kommunikative Selbstbeschreibung bleibt oder zu wirksamer Governance wird.

Literaturverzeichnis

AI Now Institute. (11. April 2023). *Algorithmic accountability: Moving beyond audits*. AI Now Institute. https://ainowinstitute.org/publications/algorithmic-accountability

Al-Kfairy, M., Mustafa, D., Kshetri, N., Insiew, M. & Alfandi, O. (2024). Ethical challenges and solutions of generative AI: An interdisciplinary perspective. *Informatics, 11*, Artikel 58. https://doi.org/10.3390/informatics11030058

Bietti, E. (2021). From ethics washing to ethics bashing: A moral philosophy view on tech ethics. *Journal of Social Computing, 2*(3), 266-283. https://doi.org/10.23919/JSC.2021.0031

Birkstedt, T., Minkkinen, M., Tandon, A. & Mäntymäki, M. (2023). AI governance: Themes, knowledge gaps and future agendas. *Internet Research, 33*, 133-167. https://doi.org/10.1108/INTR-01-2022-0042

Bundesnetzagentur. (n.d.). *High-risk AI systems*. https://www.bundesnetzagentur.de/EN/Areas/Digitalisation/AI/09_HighRisk/start.html

Corrêa, N. K., Galvão, C., Santos, J. W., Del Pino, C., Pinto, E. P., Barbosa, C., Massmann, D., Mambrini, R., Galvão, L., Terem, E. & de Oliveira, N. (2023). Worldwide AI ethics: A review of 200 guidelines and recommendations for AI governance. *Patterns*, *Volume 4, Issue 10,* 100857. https://doi.org/10.1016/j.patter.2023.100857.

de Laat, P. B. (2021). Companies committed to responsible AI: From principles towards implementation and regulation? Philosophy & Technology, 34(4), 1135-1193. https://doi.org/10.1007/s13347-021-00474-3

Díaz-Rodríguez, N., Del Ser, J., Coeckelbergh, M., López de Prado, M., Herrera-Viedma, E. & Herrera, F. (2023). Connecting the dots in trustworthy artificial intelligence: From AI principles, ethics, and key requirements to responsible AI systems and regulation. *arXiv*. https://arxiv.org/abs/2305.02231

EU High-Level Expert Group on Artificial Intelligence [EU HLEG]. (2019). *Ethics guidelines for trustworthy AI*. European Commission. https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai

EU High-Level Expert Group on Artificial Intelligence [EU HLEG]. (2020). *The assessment list for trustworthy artificial intelligence (ALTAI): For self-assessment*. European Commission. https://digital-strategy.ec.europa.eu/en/library/assessment-list-trustworthy-artificial-intelligence-altai-self-assessment

Europäische Union [EU]. (2024). *Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act)*. Official Journal of the European Union. https://eur-lex.europa.eu/eli/reg/2024/1689/oj/eng

Fjeld, J., Achten, N., Hilligoss, H., Nagy, A. C. & Srikumar, M. (2020). *Principled artificial intelligence: Mapping consensus in ethical and rights-based approaches to principles for AI*. SSRN Electronic Journal. https://doi.org/10.2139/ssrn.3518482

Fletcher, S. & Islam, M. Z. (2018). Comparing sets of patterns with the Jaccard index. *Australasian Journal of Information Systems, 22*. https://doi.org/10.3127/ajis.v22i0.1538

Gabriel, I. (2020). Artificial intelligence, values and alignment. *Minds and Machines, 30*(3), 411-437. https://doi.org/10.1007/s11023-020-09539-2

Hagendorff, T. (2020). The ethics of AI ethics: An evaluation of guidelines. *Minds and Machines, 30*, 99-120. https://doi.org/10.1007/s11023-020-09517-8

Hagendorff, T. (2024). Mapping the ethics of generative AI: A comprehensive scoping review. *Minds and Machines, 34*. https://doi.org/10.1007/s11023-024-09694-w

Jobin, A., Ienca, M. & Vayena, E. (2019). The global landscape of AI ethics guidelines. *Nature Machine Intelligence, 1*(9), 389-399. https://doi.org/10.1038/s42256-019-0088-2

Kettemann, M. C. (n.d.). *UNESCO recommendation on the ethics of artificial intelligence: Conditions for the implementation in Germany*. German Commission for UNESCO. https://www.unesco.de/assets/dokumente/Deutsche_UNESCO-Kommission/02_Publikationen/Publikation_UNESCO_Recommendation_on_the_Ethics_of_Artificial_Intelligence.pdf

Lu, Q., Zhu, L., Xu, X., Whittle, J., Zowghi, D. & Jacquet, A. (2024). Responsible AI pattern catalogue: A collection of best practices for AI governance and engineering. *ACM Computing Surveys, 56*, 1-35. https://doi.org/10.1145/3626234

Mittelstadt, B. (2019). Principles alone cannot guarantee ethical AI. *Nature Machine Intelligence, 1*, 501-507. https://doi.org/10.1038/s42256-019-0114-4

Mökander, J., Morley, J., Taddeo, M., Floridi, L. (2021). Ethics-based auditing of automated decision-making systems: Nature, scope, and limitations. *Science and Engineering Ethics, 27*, Artikel 44. https://doi.org/10.1007/s11948-021-00319-4

Morley, J., Floridi, L., Kinsey, L. & Elhalal, A. (2020). From what to how: An initial review of publicly available AI ethics tools, methods and research to translate principles into practices. *Science and Engineering Ethics, 26*, 2141-2168. https://doi.org/10.1007/s11948-019-00165-5

National Institute of Standards and Technology [NIST]. (2023). *Artificial intelligence risk management framework (AI RMF 1.0) (NIST AI 100-1)*. https://doi.org/10.6028/NIST.AI.100-1

Organisation for Economic Co-operation and Development [OECD]. (2019). *Recommendation of the Council on artificial intelligence* (OECD/LEGAL/0449). OECD Legal Instruments. https://legalinstruments.oecd.org/api/print?ids=648&lang=en

Ortega-Bolaños, R., Bernal-Salcedo, J., Ortiz, M., Sarmiento, J., Ruz, G. & Tabares-Soto, R. (2024). Applying the ethics of AI: A systematic review of tools for developing and assessing AI-based systems. *Artificial Intelligence Review, 57*. https://doi.org/10.1007/s10462-024-10740-3

Peukert, C. & Kloker, S. (2020). Trustworthy AI: How Ethics-Washing undermines consumer trust. In *Proceedings of the 15th International Conference on Wirtschaftsinformatik (WI 2020).* https://doi.org/10.30844/wi_2020_j11-peukert

Radclye, C., Ribeiro, M. & Wortham, R. (2023). The assessment list for trustworthy artificial intelligence: A review and recommendations. *Frontiers in Artificial Intelligence, 6*. https://doi.org/10.3389/frai.2023.1020592

Raji, I. D., Smart, A., White, R. N., Mitchell, M., Gebru, T., Hutchinson, B., Smith-Loud, J., Theron, D. & Barnes, P. (2020). Closing the AI accountability gap: Defining an end-to-end framework for internal algorithmic auditing. In *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency (FAT '*20)*. ACM. https://doi.org/10.1145/3351095.3372873

Reisman, D., Schultz, J., Crawford, K. & Whittaker, M. (2018). *Algorithmic impact assessments: A practical framework for public agency accountability*. AI Now Institute. https://ainowinstitute.org/wp-content/uploads/2023/04/aiareport2018.pdf

Roszkowska-Menkes, M., Aluchna, M. & Kaminski, B. (2024). True transparency or mere decoupling? The study of selective disclosure in sustainability reporting. *Critical Perspectives on Accounting, 98*, Artikel 102700. https://doi.org/10.1016/j.cpa.2023.102700

Stahl, B. & Eke, D. (2024). The ethics of ChatGPT - Exploring the ethical issues of an emerging technology. *International Journal of Information Management, 74*, Artikel 102700. https://doi.org/10.1016/j.ijinfomgt.2023.102700

Stahl, B.C., Antoniou, J., Bhalla, N., Brooks, L., Jansen, P., Lindqvist, B., Kirichenko, A., Marchal, S., Rodrigues, R., Santiago, N., Warso, Z., Wright, D. (2023). A systematic review of artificial intelligence impact assessments. *Artif Intell Rev 56*, 12799-12831. https://doi.org/10.1007/s10462-023-10420-8

United Nations Educational, Scientific and Cultural Organization [UNESCO]. (2021). *Recommendation on the ethics of artificial intelligence*. UNESCO. https://en.unesco.org/artificial-intelligence/ethics

United Nations Educational, Scientific and Cultural Organization [UNESCO]. (2023). *Readiness assessment methodology: A tool of the Recommendation on the Ethics of Artificial Intelligence (RAM).* UNESCO. https://unesdoc.unesco.org/ark:/48223/pf0000380455

Zhou, K. & Gattinger, G. (2024). The evolving regulatory paradigm of AI in MedTech: A review of perspectives and where we are today. *Therapeutic Innovation & Regulatory Science, 58*, 456-464. https://doi.org/10.1007/s43441-024-00628-3

Anhang

Anhangverzeichnis

Anhang A1: DAX-Stammliste mit company_id, Name, Sektor, Detailbranche, Land, DAX-Datum, Marktkapitalisierung und Sampling-Notiz. ..... **Fehler! Textmarke nicht definiert.**

Anhang A2: Dokumentenlog mit Dokument-ID, Typ, Quelle, URL, Inklusionsstatus, Ausschlussgrund und Relevanznotizen. .....**Fehler! Textmarke nicht definiert.**

Anhang A3: Codebook der Werte mit IDs, Definitionen und Kodierregeln. .... **Fehler! Textmarke nicht definiert.**

Anhang A4: Codebook der Governance-Kriterien mit Rubrik und Evidenzlogik. .....**Fehler! Textmarke nicht definiert.**

Anhang A5: Dokumentenbezogene VollKodierung der Werte mit Evidenzstellen und Punktelogik. .....**Fehler! Textmarke nicht definiert.**

Anhang A6: Dokumentenbezogene VollKodierung der Governance-Kriterien mit Evidenzstellen und Scores. .....**Fehler! Textmarke nicht definiert.**

Anhang A7: Grenzfall- und Unsicherheitenlog mit Falltyp, betroffenen Codes und Entscheidungsregel. .....**Fehler! Textmarke nicht definiert.**

Anhang A8: Company-Level-Wertetabelle mit value_present und value_points pro Unternehmen und Wert. .....**Fehler! Textmarke nicht definiert.**

Anhang A9: Company-Level-Governance-Tabelle mit Score je Unternehmen und Kriterium. .....**Fehler! Textmarke nicht definiert.**

Anhang A10: Abgeleitete Indizes je Unternehmen: Wertepunkte, Maximalpunkte, Konvergenz-Index und Governance-Index. .....**Fehler! Textmarke nicht definiert.**

Anhang A11: Paarweise Jaccard-Ähnlichkeitsmatrix der Werte-Sets zwischen allen Unternehmen.....**Fehler! Textmarke nicht definiert.**

Anhang A12: Long-Format der paarweisen Jaccard-Ähnlichkeiten und Distanzen. **Fehler! Textmarke nicht definiert.**

Anhang A13: Company-Level-Matrix der Wertepräsenz mit Summen- und Sektorinformationen.....**Fehler! Textmarke nicht definiert.**

Anhang A14: Unternehmensliste nach Sektoren mit Anzahl Werte, Werteanteil und Governance-Index.....**Fehler! Textmarke nicht definiert.**

Anhang A15: Clusterzuordnung je Unternehmen für Werte- und Governance-Lösungen (k=3/4/5) inkl. Ausschlussflags. .....**Fehler! Textmarke nicht definiert.**

Anhang A16: Merge-/Linkage-Log der Werte-Clusteranalyse. ..**Fehler! Textmarke nicht definiert.**

Anhang A17: Merge-/Linkage-Log der Governance-Clusteranalyse. ..... **Fehler! Textmarke nicht definiert.**

Anhang A18: Clusterprofile der Werte-Cluster nach k, Clustergröße, Wert und Präsenzanteil. **Fehler! Textmarke nicht definiert.**

Anhang A19: Clusterprofile der Governance-Cluster nach k, Kriterium sowie Mittel-/Median-Score und Anteil hoher Scores. .....**Fehler! Textmarke nicht definiert.**

Anhang A20: Flag-Tabelle zu kleinen Clustern nach Analyse, k und Clustergröße. .....**Fehler! Textmarke nicht definiert.**

Anhang A21: Übersicht der Kombinationen aus Werte- und Governance-Clustern mit Fallzahlen je k. .....**Fehler! Textmarke nicht definiert.**

Anhang A22: Mitgliedsliste der Werte-Cluster (raw_node_id, company_id, company_name).....**Fehler! Textmarke nicht definiert.**

Anhang A23: Mitgliedsliste der Governance-Cluster (raw_node_id, company_id, company_name).....**Fehler! Textmarke nicht definiert.**

Anhang A25: Long-Format der paarweisen z-standardisierten euklidischen Distanzen für Governance-Profile. .....**Fehler! Textmarke nicht definiert.**

Anhang A26: Unternehmensdatensatz für die Zusammenhangsanalyse mit Werte- und Governance-Indizes.....**Fehler! Textmarke nicht definiert.**

Anhang A27: Sektorweise Spearman-Korrelationen nach Werteindex-Variante. .....**Fehler! Textmarke nicht definiert.**

Anhang A28: Sektorübersicht mit Mittelwerten und Medianen der verwendeten Indizes. **Fehler! Textmarke nicht definiert.**

Anhang A29: Definition der Sensitivitätsvarianten mit Formel, Gewichten und Berechnungsstatus. .....**Fehler! Textmarke nicht definiert.**

Anhang A30: Indexwerte je Unternehmen und Sensitivitätsvariante..... **Fehler! Textmarke nicht definiert.**

Anhang A31: Cluster-Crosstabs zwischen Baseline- und Varianten-Clustern. .....**Fehler! Textmarke nicht definiert.**

Anhang A32: Versionierte Änderungshistorie des Codebooks mit Recode-Impact. **Fehler! Textmarke nicht definiert.**

Anhang A33: Pilot-Kodierung der Werte mit Evidenzankern. .... **Fehler! Textmarke nicht definiert.**

Anhang A34: Re-Kodierung der Werte. .....**Fehler! Textmarke nicht definiert.**

Anhang A35: Post-hoc-Vergleich Pilot vs. Re-Coding auf Werte-Ebene. ... **Fehler! Textmarke nicht definiert.**

Anhang A36: Pilot-Kodierung der Governance-Kriterien mit Evidenzankern. **Fehler! Textmarke nicht definiert.**

Anhang A37: Re-Kodierung der Governance-Kriterien..... **Fehler! Textmarke nicht definiert.**

Anhang A38: Konsolidierte Pilot-Regeln mit Triggern und Testfragen..... **Fehler! Textmarke nicht definiert.**

Anhang A39: Transparenzhinweis zur Nutzung KI-gestützter Systeme..... **Fehler! Textmarke nicht definiert.**

Alle Tabellen sind ebenfalls online abrufbar unter:
https://github.com/flo-kla/masterarbeit

Der vollständige Anhang wird als separates Dokument mit der Bezeichnung „20260501_Vesta_Florian_42305815_Masterarbeit_Anhang.pdf“ verschickt.

Eidesstattliche Erklärung

Hiermit versichere ich an Eides statt, dass ich die Abschlussarbeit selbstständig und ohne Inanspruchnahme fremder Hilfe angefertigt habe. Ich habe dabei nur die angegebenen Quellen und Hilfsmittel verwendet und die aus diesen wörtlich oder inhaltlich entnommenen Stellen als solche kenntlich gemacht. Die Arbeit hat in gleicher oder ähnlicher Form noch keiner anderen Prüfungsbehörde vorgelegen. Ich erkläre mich damit einverstanden, dass die Arbeit mit Hilfe eines Plagiatserkennungsdienstes auf enthaltene Plagiate überprüft wird.

Florian Eric Vesta (geb. Klawun),

Adresse: Treskowallee 24A, 10318 Berlin

Matrikelnummer: 42305815

Berlin, den 1. Mai 2026